

例题

2023年6月23日 0:02

1.证明某个函数是凸函数，即找到即证明如下条件，严格凸函数则证明正定：

(3) $\nabla^2 f(x)$ 是半正定的，记作 $\nabla^2 f(x) \geq 0$.

$$(2) f: \mathbb{R}^3 \rightarrow \mathbb{R}, f(x) = 4x_1^2 + 3x_2^2 + 5x_3^2 + 6x_1x_2 + x_1x_3 - 3x_1 - 2x_2 + 15$$

$$(2) \text{ 函数 } f \text{ 的黑塞矩阵为 } F(x) = \begin{bmatrix} 8 & 6 & 1 \\ 6 & 6 & 0 \\ 1 & 0 & 10 \end{bmatrix}$$

$$\Delta_1 = 8 > 0$$

$$F(x) \text{ 的各阶顺序主子式为 } \Delta_2 = \det \begin{bmatrix} 8 & 6 \\ 6 & 6 \end{bmatrix} = 12 > 0$$

$$\Delta_3 = \det F(x) = 114 > 0$$

对于任意 $x \in \mathbb{R}^3, F(x)$ 都是正定矩阵。因此， f 是 $\mathbb{R}^3$ 上的凸函数。

3.找到一个无约束优化问题的局部极小点，一般是利用二阶充分条件来：

设 $f(x)$ 二阶连续可微，且满足 (1) $\nabla f(x^*) = 0$ (2) $\nabla^2 f(x^*)$ 为正定，
则 x^* 是无约束问题的一个严格局部解。

定理(二阶充分条件) 设 $f(x)$ 在点 $x^* \in \mathbb{R}^n$ 的一个邻域 $N(x^*, \delta)$ 内二次可微。
若在点 x^* 处满足 $\nabla f(x^*) = 0$ ，且 $\forall x \in N(x^*, \delta)$ 都有 $\nabla^2 f(x)$ 半正定，则 x^* 是
函数 $f(x)$ 的局部极小点。

例 求下列函数的极小点： $f(x) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$.

$$\text{解 (1) 求平稳点 } \begin{cases} f_{x_1}(x) = 4(x_1 - 2)^3 + 2(x_1 - 2x_2) = 0 \\ f_{x_2}(x) = -4(x_1 - 2x_2) = 0 \end{cases}$$

解此方程组，得到平稳点 $x^* = (2, 1)^T$.

$$(2) \text{ 判别黑塞矩阵的正定性 } \nabla^2 f(x) = \begin{bmatrix} 12(x_1 - 2)^2 + 2 & -4 \\ -4 & 8 \end{bmatrix}$$

$$\text{在平稳点的黑塞矩阵为 } \nabla^2 f(x^*) = \begin{bmatrix} 2 & -4 \\ -4 & 8 \end{bmatrix}$$

该矩阵是半正定矩阵，故不能直接判断 x^* 是否为局部极小点。

考虑邻域 $N(x^*, \delta)$ 上的点 $x = x^* + \Delta x = \begin{pmatrix} 2 + \Delta x_1 \\ 1 + \Delta x_2 \end{pmatrix}$ ，则

$$H(x) = \begin{bmatrix} 12\Delta x_1^2 + 2 & -4 \\ -4 & 8 \end{bmatrix}$$

容易验证上述矩阵是半正定的，由定理可知 x^* 是局部极小点。

4.最基本无约束优化问题的求解

例 考虑以下无约束优化问题：

$$\min f(x_1, x_2) = 8x_1^2 + 3x_1x_2 + 7x_2^2 - 19x_1 - 17x_2 - 29$$

(1) 求目标函数所有的平稳点；

(2) 平稳点是否为局部极小点？

(3) 该问题是否存在全局极小点？

解 令一阶导数等于零求出平稳点：

$$\nabla f(x) = \begin{pmatrix} 16x_1 + 3x_2 - 19 \\ 3x_1 + 14x_2 - 17 \end{pmatrix} = 0$$

解得平稳点 $x^0 = (1, 1)^T$

再求二阶导数：

$$\nabla^2 f(x) = \begin{pmatrix} 16 & 3 \\ 3 & 14 \end{pmatrix} > 0$$

Hessian矩阵正定，因此平稳点为局部极小点。

又由于目标函数为凸函数，局部极小即为全局极小点。

5.黄金分割法确定函数某个区间内的极小点

例 利用黄金分割法确定函数 $f(x) = x^4 - 14x^3 + 60x^2 - 70x$

在区间 $[0,2]$ 中的极小点。要求将极小点所在区间的长度压缩到 0.3 之内。

经过 N 步压缩, 区间 $[0,2]$ 可被压缩到原区间长度的 $(0.61803)^N$, 即:

$(0.61803)^N \leq 0.3/2$, 求得 $N = 4$, 即经过 4 步压缩即可达到目的。

第1次迭代: 选定两个中间点 a_1 和 b_1 :

$$a_1 = a_0 + \rho(b_0 - a_0) = 0.7639, \quad b_1 = a_0 + (1 - \rho)(b_0 - a_0) = 1.236$$

其中, $\rho = (3 - \sqrt{5})/2$ 。计算对应的目标函数值: $f(a_1) = -24.36$, $f(b_1) = -18.96$

由于 $f(a_1) < f(b_1)$, 因此, 区间被压缩为 $[a_0, b_1] = [0, 1.236]$

第2次迭代: 以 a_1 作为本次迭代中的 b_2 , 确定 $a_2 = a_0 + \rho(b_1 - a_0) = 0.4721$

计算目标函数值: $f(a_2) = -21.10$, $f(b_2) = f(a_1) = -24.36$

第3次迭代: 令 $a_3 = b_2$, 确定 $b_3 = a_2 + (1 - \rho)(b_1 - a_2) = 0.9443$

计算目标函数值: $f(a_3) = f(b_2) = -24.36$, $f(b_3) = -23.59$

由于 $f(b_3) > f(a_3)$, 区间被进一步压缩为 $[a_2, b_3] = [0.4721, 0.9443]$

第4次迭代: 令 $b_4 = a_3$, 确定 $a_4 = a_2 + \rho(b_3 - a_2) = 0.6525$

计算目标函数值: $f(a_4) = -23.84$, $f(b_4) = f(a_3) = -24.36$

由于 $f(a_4) > f(b_4)$, 极小点所在区间压缩为 $[a_4, b_3] = [0.6525, 0.9443]$ 。

区间长度 $b_3 - a_4 = 0.292 < 0.3$, 满足精度指标要求。

在计算是注意 $\rho=0.382$ 对每对对应的a和b, 值大的那个替换原来的, 比如现在的区间是a0和b0, 其中

$f(a_1) < f(b_1)$, 则将b0更换为b1, 区间为[a0,b1], 同时在下一步时直接固定刚刚变化过区间的那一端, 令 $b_2=a_1$ 。

5.最速下降法例题:

梯度法ppt P12

6.最速下降法求二次函数的最小值:

首先注意给出的式子化简为二次型后时候是否是**对称正定**的, 否则需要使用矩阵对称化进行修正, 即前面乘以二分之一, 将中间矩阵加上它的转置。此时的步长 α 有显式表达如下: $g_k = \nabla f(x_k)$

$$\alpha_k = \frac{g_k^T g_k}{g_k^T A g_k} \quad \text{对于一般非线性函数, 可以利用下面的公式近似计算}$$

$$\alpha = \frac{g_k^T g_k}{g_k^T \nabla^2 f(x^{(k)}) g_k}$$

目标函数为正定二次函数 $f(x) = \frac{1}{2} x^T A x + b^T x + c$ 时, 最速下降法的迭代公式为:

$$g_k = A x^{(k)} + b$$

$$x^{(k+1)} = x^{(k)} - \frac{g_k^T g_k}{g_k^T A g_k} g_k, \quad k = 0, 1, \dots$$

对每次迭代的 x_k , 计算其梯度是否为0, 或者计算精度是否满足要求。

7.牛顿法求解无约束优化问题:

基本Newton法

(1) 取初始点 $x^{(0)}$, 置精度要求 ε , 置 $k = 0$.

(2) 如果 $\|\nabla f(x^{(k)})\| \leq \varepsilon$, 则停止计算 ($x^{(k)}$ 作为无约束问题的解);

否则, 求解线性方程组 $\nabla^2 f(x^{(k)}) d = -\nabla f(x^{(k)})$, 得到 $d^{(k)}$.

(3) 置 $x^{(k+1)} = x^{(k)} + d^{(k)}$, $k = k + 1$, 转步骤 (2).

经典牛顿法步长为1, 阻尼牛顿法对步长进行搜索。

注意只有黑塞矩阵正定时才能保证经典牛顿法产生的为下降方向, 不正定时进行修正:

8.共轭梯度法求解无约束优化问题:

对于n维二次型问题, 共轭梯度法能够在n步之内得到结果。

在获得关于某个矩阵的一组共轭向量时可以使用格拉姆施米特正交化方法

$$\alpha_k = -\frac{g^{(k)T} d^{(k)}}{d^{(k)T} S d^{(k)}}$$

注意当矩阵为二次型时, 真正的 α 的求法如上, 上面梯度下降法的写法只是把d换成了负梯度方向。

例 利用基本的共轭方向算法求函数

$$f(x_1, x_2) = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix} \mathbf{x} + \mathbf{x}^T \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \mathbf{x} \in \mathbb{R}^2$$

的极小点, 初始点为 $\mathbf{x}^{(0)} = [0, 0]^T$, 给定 $\mathbf{S}$ 共轭方向为 $\mathbf{d}^{(0)} = [1, 0]^T, \mathbf{d}^{(1)} = \begin{bmatrix} -\frac{3}{8} & \frac{3}{4} \end{bmatrix}^T$ 。

解: 首先 $\mathbf{g}^{(0)} = \mathbf{S}\mathbf{x}^{(0)} + \mathbf{b} = \mathbf{b} = [1, -1]^T, \alpha_0 = -\frac{\mathbf{g}^{(0)T}\mathbf{d}^{(0)}}{\mathbf{d}^{(0)T}\mathbf{S}\mathbf{d}^{(0)}} = -\frac{[1, -1] \begin{bmatrix} 1 \\ 0 \end{bmatrix}}{[1, 0] \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix}} = -\frac{1}{4}$

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \alpha_0 \mathbf{d}^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} -\frac{1}{4} \\ 0 \end{bmatrix}$$

再计算 $\mathbf{g}^{(1)} = \mathbf{S}\mathbf{x}^{(1)} + \mathbf{b} = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} -\frac{1}{4} \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ -\frac{3}{2} \end{bmatrix}, \alpha_1 = -\frac{\mathbf{g}^{(1)T}\mathbf{d}^{(1)}}{\mathbf{d}^{(1)T}\mathbf{S}\mathbf{d}^{(1)}} =$

$$-\frac{\begin{bmatrix} 0 & -\frac{3}{2} \end{bmatrix} \begin{bmatrix} -\frac{3}{8} \\ \frac{3}{4} \end{bmatrix}}{\begin{bmatrix} -\frac{3}{8} & \frac{3}{4} \end{bmatrix} \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} -\frac{3}{8} \\ \frac{3}{4} \end{bmatrix}} = 2, \quad \mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \alpha_1 \mathbf{d}^{(1)} = \begin{bmatrix} -\frac{1}{4} \\ 0 \end{bmatrix} + 2 \begin{bmatrix} -\frac{3}{8} \\ \frac{3}{4} \end{bmatrix} = \begin{bmatrix} -\frac{1}{2} \\ \frac{3}{2} \end{bmatrix}$$

由于函数是一个二维的正定二次型函数, 故 $\mathbf{x}^{(2)} = \mathbf{x}^*$

共轭梯度法的例题在共轭梯度法ppt P19, 共轭梯度法不用一开始就给出共轭方向, 需要利用 β 逐步计算得出。

共轭梯度法解决非二次型问题时, 对矩阵 $\mathbf{S}$ 出现的地方需要进行替换。

9.拟牛顿法解决无约束优化问题

拟牛顿法的思想使用**对称正定矩阵HK**去近似黑塞矩阵的逆, 在构造HK时需要满足拟牛顿条件,

$$\mathbf{H}_{k+1} (\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})) = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$$

为了推导公式方便, 记

$$\mathbf{y}_k = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)}), \mathbf{s}_k = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)},$$

拟Newton 条件可改写成

$$\mathbf{H}_{k+1} \mathbf{y}_k = \mathbf{s}_k \text{ 或 } \mathbf{B}_{k+1} \mathbf{s}_k = \mathbf{y}_k$$

利用DFP算法求解无约束优化问题:

DFP 算法

(1) 令 $k := 0$; 选择初始点 $\mathbf{x}^{(0)}$, 任选一个对称正定实矩阵 $\mathbf{H}_0$ 。

(2) 如果 $\nabla f(\mathbf{x}^{(k)}) = \mathbf{0}$, 停止迭代; 否则, 令 $\mathbf{d}^{(k)} = -\mathbf{H}_k \mathbf{g}^{(k)}$ 。

(3) 计算 $\alpha_k = \arg \min_{\alpha \geq 0} f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})$

(4) 计算 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$

(5) 计算

$$\mathbf{y}_k = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)}), \mathbf{s}_k = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} = \alpha_k \mathbf{d}^{(k)}$$

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \frac{\mathbf{s}_k \mathbf{s}_k^T}{\mathbf{s}_k^T \mathbf{y}_k} - \frac{[\mathbf{H}_k \mathbf{y}_k][\mathbf{H}_k \mathbf{y}_k]^T}{\mathbf{y}_k^T \mathbf{H}_k \mathbf{y}_k}$$

(6) 令 $k := k + 1$, 回到第 2 步。

利用BFGS算法求解无约束优化问题: 在上面的基础上HK的更新方式如下,

注意这两种方法求解 α 时要看是不是二次型好带入公式

$$\mathbf{H}_{k+1}^{\text{BFGS}} = (\mathbf{I} - \rho_k \mathbf{y}_k \mathbf{s}_k^T)^T \mathbf{H}_k^{\text{BFGS}} (\mathbf{I} - \rho_k \mathbf{y}_k \mathbf{s}_k^T) + \rho_k \mathbf{s}_k \mathbf{s}_k^T$$

$$\rho_k = \frac{1}{\mathbf{s}_k^T \mathbf{y}_k}$$

例 利用 BFGS 算法求解二次型函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{x}^T \mathbf{b}$ 的极小点。其中,

$$\mathbf{A} = \begin{bmatrix} 5 & -3 \\ -3 & 2 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

令 $\mathbf{H}_0 = \mathbf{I}_2$, 初始点 $\mathbf{x}^{(0)} = [0, 0]^T$ 。计算结束后, 验证 $\mathbf{H}_2 = \mathbf{A}^{-1}$ 。

BFSS 更优的二次:

$$H_{k+1} = \left(I - \frac{y_k y_k^T}{y_k^T y_k} \right)^T H_k \left(I - \frac{y_k y_k^T}{y_k^T y_k} \right) + \frac{y_k y_k^T}{y_k^T y_k}$$

例: $f(x) = \frac{1}{2} x^T A x - x^T b$, $A = \begin{bmatrix} 5 & -3 \\ -3 & 2 \end{bmatrix}$, $b = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$

初始点: $x_0 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, $x^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$, 验证 $H_0 = A^{-1}$

解:

$$\nabla f(x) = Ax - b$$

$$= \begin{bmatrix} 5x_1 - 3x_2 \\ -3x_1 + 2x_2 - 1 \end{bmatrix}$$

$$\nabla f(x^{(0)}) = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

$$d^{(0)} = -H_0 \nabla f(x^{(0)})$$

$$= \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

由于 $f(x)$ 为二次型函数

故 α_k 可解为:

$$\alpha_k = - \frac{\nabla f(x^{(k)})^T d^{(k)}}{(d^{(k)})^T A d^{(k)}}$$

$$\alpha_0 = - \frac{\begin{bmatrix} 0 & 1 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix}}{\begin{bmatrix} 0 & 1 \end{bmatrix} A \begin{bmatrix} 0 \\ 1 \end{bmatrix}} = - \frac{1}{2}$$

$$x_1 = x_0 + \alpha_0 d_0 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$\nabla f(x^{(1)}) = \begin{bmatrix} -3 \\ 0 \end{bmatrix}$$

$$s_0 = x_1 - x_0 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$y_0 = \nabla f(x^{(1)}) - \nabla f(x^{(0)}) = \begin{bmatrix} -3 \\ 1 \end{bmatrix}$$

更新 H_1 :

$$H_1 = \left(I - \frac{s_0 s_0^T}{s_0^T s_0} \right)^T H_0 \left(I - \frac{s_0 s_0^T}{s_0^T s_0} \right) + \frac{s_0 s_0^T}{s_0^T s_0}$$

$$= \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} + \frac{\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}}{1} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$$

10. 利用拉格朗日乘子法求解有约束最优化问题

首先需要验证可行域是否满足约束规范, 满足其中一条即可, 当约束规范不成立时, 则局部极小点不一定是kkt点

1) $c_i(x) (i \in E \cup I(x^*))$ 是**线性函数**, 称为LFCQ(Linear Function Constraint Qualification);

2) $\nabla c_i(x) (i \in E \cup I(x^*))$ **线性无关**, 称为LICQ(Linear Independence Constraint Qualification)。这时 x^* 称为**正则点**。

KKT条件是x为局部解时的必要条件, x为约束优化问题的局部解, 则x满足kkt条件

注意对条件2进行检测时, 需要对所有的等式约束进行求导, 然后对不等约束中满足**有效约束**的不等式进行求导, 只需对满足以上两种情况的约束进行检测

然后根据拉格朗日方程约束求出所有满足条件的KKT点, 但这些点不一定时局部解, 需要使用**二阶充分条件**来进一步验证

此时需要构建一个LFD集合来验证, 具体的详细解法参考**约束问题的最优化条件 ppt P32 例题**

当这个规划时凸规划时, 可微凸规划问题的KKT条件是全局解的充分条件

11. 给出约束问题的对偶问题

$$d^* = \max_{\lambda, \mu \geq 0} d(\lambda, \mu) = \max_{\lambda, \mu \geq 0} \min_{x \in X} L(x, \lambda, \mu)$$

例 试写出如下约束规划问题的对偶问题:

$$\begin{aligned} \min \quad & f(x) = x_1^2 + x_2^2; \\ \text{s. t.} \quad & c_1(x) = -x_1 + x_2 + 2 \leq 0, \\ & c_2(x) = \frac{1}{2}x_1 + x_2 + 1 \leq 0 \end{aligned}$$

令 $\mu \geq 0$, 定义对偶函数:

$$\begin{aligned} d(\mu) &= \min_x \left\{ x_1^2 + x_2^2 + \mu_1(-x_1 + x_2 + 2) + \mu_2 \left(\frac{1}{2}x_1 + x_2 + 1 \right) \right\} \\ &= -\frac{1}{2}\mu_1^2 - \frac{1}{4}\mu_1\mu_2 - \frac{5}{16}\mu_2^2 + 2\mu_1 + \mu_2. \end{aligned}$$

故对偶问题为

$$\begin{aligned} \max \quad & -\frac{1}{2}\mu_1^2 - \frac{1}{4}\mu_1\mu_2 - \frac{5}{16}\mu_2^2 + 2\mu_1 + \mu_2; \\ \text{s. t.} \quad & \mu_1 \geq 0, \mu_2 \geq 0. \end{aligned}$$

对d(u)中的x进行求导, 导数为0, 将x表示为μ的线性组合然后带入。

例题在约束优化的对偶理论 PPT P18

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) = x_1^2 + x_2^2 \\ \text{s. t.} \quad & h(\mathbf{x}) = x_1 - x_2 - 2 = 0 \\ & g(\mathbf{x}) = (x_1 - 2)^2 + x_2^2 - 1 \leq 0 \end{aligned}$$

第一步, 最小化 $L(\mathbf{x}, \lambda, \mu) = x_1^2 + x_2^2 + \lambda(x_1 - x_2 - 2) + \mu((x_1 - 2)^2 + x_2^2 - 1)$. 将 λ, μ 视为常数, 这时 $L(\mathbf{x}, \lambda, \mu)$ 就只是 $\mathbf{x}$ 的函数。可以通过求导等于零的方式寻找其最小值, 即 $d(\lambda, \mu) = \min_{\mathbf{x}} L(\mathbf{x}, \lambda, \mu)$

$$\begin{cases} 2x_1 + \lambda + \mu(2x_1 - 4) = 0 \\ 2x_2 - \lambda + 2\mu x_2 = 0 \end{cases}, \text{ 可以解得: } \begin{cases} x_1 = \frac{4\mu - \lambda}{2\mu + 2} \\ x_2 = \frac{\lambda}{2\mu + 2} \end{cases}$$

代入拉格朗日目标函数, 可以得到: $d(\lambda, \mu) = -\frac{\lambda^2 + 4\lambda + 2\mu^2 - 6\mu}{2(\mu + 1)}$

第二步, 最大化 $d(\lambda, \mu)$ 此时可以将 $d(\lambda, \mu)$ 看成是一个二元函数求极值的问题, $\mu \geq 0$ 。分别对 λ, μ 求偏导并令其为0, 有:

$$\begin{aligned} -\frac{2\mu^2 + 4\mu - \lambda^2 - 4\lambda - 6}{2(\mu + 1)^2} &= 0 \\ \frac{2\lambda + 4}{2(\mu + 1)} &= 0 \end{aligned}$$

联立求得: $\mu = \sqrt{2} - 1, \lambda = -2$, 代入 $\begin{cases} x_1 = \frac{4\mu - \lambda}{2\mu + 2} \\ x_2 = \frac{\lambda}{2\mu + 2} \end{cases}$ 即可求得 $\mathbf{x}$.

12. 罚函数法求解约束问题

考虑一般的约束优化问题

$$\begin{aligned} \min \quad & f(\mathbf{x}); \\ \text{s. t.} \quad & c_i(\mathbf{x}) = 0, i \in E = \{1, 2, \dots, l\}, \\ & c_i(\mathbf{x}) \leq 0, i \in I = \{l + 1, l + 2, \dots, l + m\}, \\ & \mathbf{x} \in \mathbf{R}^n. \end{aligned}$$

定义如下形式的外罚函数

$$P(\mathbf{x}, \sigma) = f(\mathbf{x}) + \sigma \left[\sum_{i=1}^l (c_i(\mathbf{x}))^2 + \sum_{i=l+1}^{l+m} [\max(0, c_i(\mathbf{x}))]^2 \right]$$

同时注意对不等式约束的讨论

注意内罚函数法只适用于不等式约束的优化问题

例 用内罚函数法求解约束问题

$$\begin{aligned} \min \quad & f(\mathbf{x}) = x_1^2 + 2x_2^2; \\ \text{s. t.} \quad & x_1 + x_2 - 1 \geq 0. \end{aligned}$$

解 构造内罚函数

$$P(\mathbf{x}(r), r) = x_1^2 + 2x_2^2 - r \ln(x_1 + x_2 - 1),$$

利用解析法, 有

$$\nabla_{\mathbf{x}} P(\mathbf{x}(r), r) = \left(2x_1 - \frac{r}{x_1 + x_2 - 1}, 4x_2 - \frac{r}{x_1 + x_2 - 1} \right)^T = \mathbf{0}.$$

$$\text{得 } \mathbf{x}(r) = \left(\frac{1 + \sqrt{1 + 3r}}{3}, \frac{1 + \sqrt{1 + 3r}}{6} \right)^T,$$

$$\text{令 } r \rightarrow 0, \text{ 则 } \mathbf{x}(r) \rightarrow \mathbf{x}^* = \left(\frac{2}{3}, \frac{1}{3} \right)^T, P(\mathbf{x}(r), r) \rightarrow f(\mathbf{x}^*) = \frac{2}{3}.$$

增广拉格朗日函数法, 旨在找到一个合适的参数的使 $\mathbf{x}$ 恰好是无约束的极小点

等式约束的例题在 罚函数法PPT p37, 下面是带修正的

算法(等式约束的ALM)

(1) 给定初始点 $\mathbf{x}^0$, 初始乘子为 λ^1 , 精度要求为 ε , 放大系数为 $\rho, \sigma_1 > 0$, 令 $k = 1$;

(2) 以 $\mathbf{x}^{k-1}$ 为初始点, 求解无约束优化问题

$$\min_{\mathbf{x}} \left\{ \phi(\mathbf{x}, \lambda^k, \sigma_k) = f(\mathbf{x}) + \sum_{i=1}^m \lambda_i^k h_i(\mathbf{x}) + \frac{\sigma_k}{2} \sum_{i=1}^m h_i^2(\mathbf{x}) \right\},$$

得到最优解 $\mathbf{x}^k$;

(3) 若 $[\sum_{i=1}^m h_i^2(\mathbf{x}^k)]^{\frac{1}{2}} \leq \varepsilon$, 则停止迭代, 得近似解 $\mathbf{x}^k$; 否则, 转步骤 (4);

(4) 令 $\lambda_i^{k+1} = \lambda_i^k + \sigma_k h_i(\mathbf{x}^k)$, $\sigma_{k+1} = \rho \sigma_k$, $k := k + 1$, 转步骤 (2).

例 用增广拉格朗日乘子法求解下列优化问题

$$\begin{aligned} \min \{f(x) = 2x_1^2 + x_2^2 - 2x_1x_2\} \\ \text{s.t. } h(x) = x_1 + x_2 - 1 = 0 \end{aligned}$$

解: 增广拉格朗日乘子罚函数为

$$\phi(x, \lambda, \sigma) = 2x_1^2 + x_2^2 - 2x_1x_2 + \lambda(x_1 + x_2 - 1) + \frac{\sigma}{2}(x_1 + x_2 - 1)^2,$$


取 $\sigma_1 = 2$, $\lambda^1 = -1$, $\rho = 2$, 利用解析法求解 $\min_x \phi(x, -1, 2)$, 得到极小点 $x^1 = \begin{pmatrix} \frac{1}{2} \\ \frac{3}{4} \end{pmatrix}$

修正 λ , 有 $\lambda^2 = \lambda^1 + \sigma_1 h(x^1) = -1 + 2 \times \frac{1}{4} = -\frac{1}{2}$, $\sigma_2 = 2\sigma_1 = 4$

再求解 $\min_x \phi(x, -\frac{1}{2}, 4)$, 得到 x^2 . 如此继续。

对一般约束的拉格朗日乘子法, 将不等式约束加入松弛变量变成等式约束。具体过程在PPT第46页, 注意可以使用后面推导出来的更新乘子的公式

13



(1) 共轭向量ppt p8

(2) $Ax=b$

(3)

- 当 $n=1$ 时, Q 是一个 1×1 的对称正定矩阵, 只有一个元素 q_{11} 。我们可以选择向量 $d_1 = [1]$, 其中 1 表示单位向量。根据定义, d_1 是共轭的, 因为 $d_1^T Q d_1 = [1] q_{11} [1] = q_{11} > 0$ 。所以, 在 $n=1$ 的情况下, 我们可以找到一个共轭向量。
- 假设对于某个正整数 k , 我们已经证明了对称正定矩阵 Q 在维度为 k 的情况下存在一个包含 k 个向量的共轭向量组。即, 在 $n=k$ 的情况下, 我们有共轭向量组 $\{d_1, d_2, \dots, d_k\}$ 。
- 现在考虑维度为 $k+1$ 的情况。我们将 Q 表示为如下形式的块矩阵:
$$Q = \begin{bmatrix} A & b \\ b^T & c \end{bmatrix}$$
其中, A 是一个 $k \times k$ 的对称正定矩阵, b 是一个 $k \times 1$ 的列向量, c 是一个标量。
根据归纳假设, 在维度为 k 的情况下, 对称正定矩阵 A 存在一个包含 k 个向量的共轭向量组 $\{d_1, d_2, \dots, d_k\}$, 满足 $d_i^T A d_j = 0$ ($i \neq j$)。
- 现在我们来构造维度为 $k+1$ 的共轭向量组 $\{d_1, d_2, \dots, d_k, d_{k+1}\}$ 。
我们选择 $d_{k+1} = [0; 0; \dots; 0; 1]$, 即最后一个分量为 1, 其余分量为 0。显然, d_{k+1} 是一个单位向量。
对于任意 $i \neq j$, 我们有:
$$(d_i, d_{k+1})^T Q (d_j, d_{k+1}) = (d_i^T A d_j + d_i^T b + 0) + (0 + 0 + c) = d_i^T A d_j$$
根据归纳假设, d_i 和 d_j 是共轭的, 即 $d_i^T A d_j = 0$ 。因此, $(d_i, d_{k+1})^T Q (d_j, d_{k+1}) = 0$, 即 d_{k+1} 与其他向量共轭。
综上所述, 我们找到了一个包含 $k+1$ 个向量的共轭向量组 $\{d_1, d_2, \dots, d_k, d_{k+1}\}$ 。

$$(d_i, d_{k+1})^T Q (d_j, d_{k+1}) = (d_i^T A d_j + d_i^T b + 0) + (0 + 0 + c) = d_i^T A d_j + d_i^T b + c\delta_{ij}$$

其中, δ_{ij} 是克罗内克 δ (Kronecker delta) 符号, 当 $i=j$ 时为 1, 当 $i \neq j$ 时为 0。

因此, 根据归纳假设, d_i 和 d_j 是共轭的, 即 $d_i^T A d_j = 0$ 。由于 c 是正常数, 可以调整 b 的取值, 使得 $d_i^T b + c\delta_{ij} = 0$, 从而保持共轭性。

(4)

对于任意初始点 $x^{(0)}$, 基本的共轭方向算法都能在 n 次迭代之内收敛到唯一的全局极小点 x^* , 即 $x^{(n)} = x^*$, 具有二次终止性。

理解: $\{d^{(0)}, \dots, d^{(k-1)}\}$ 线性无关, 线性共轭方向法如果在一个方向上使得函数的表现最优化了, 就可以不用再考虑这个维度, 只需要考虑剩下的维度。

11.1 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 一阶连续可微, 即 $f \in C^1$, 求其极小点的迭代公式为

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$$

其中, $\mathbf{d}^{(1)}, \mathbf{d}^{(2)}, \dots$ 为定义在 $\mathbb{R}^n$ 中的方向, 步长 $\alpha_k \geq 0$, 按照最小化函数 $f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})$ 的方式求取, 即

$$\alpha_k = \arg \min_{\alpha \geq 0} f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})$$

实际上, 这一迭代公式几乎适用于本书第二部分讨论过的所有方法, 包括最速下降法、牛顿法、共轭梯度法和拟牛顿法等。

令 $\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)})$, 假定 $\mathbf{d}^{(k)T} \mathbf{g}^{(k)} < 0$ 。

a. 证明 $\mathbf{d}^{(k)}$ 是 f 的下降方向, 即存在一个 $\bar{\alpha} > 0$, 使得对于所有 $\alpha \in (0, \bar{\alpha}]$, 都有

$$f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)}) < f(\mathbf{x}^{(k)})$$

b. 证明 $\alpha_k > 0$ 。

c. 证明 $\mathbf{d}^{(k)T} \mathbf{g}^{(k+1)} = 0$ 。

(1)

定理 设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在点 $\bar{\mathbf{x}}$ 处可微, 且 $\nabla f(\bar{\mathbf{x}}) \neq \mathbf{0}$ 。

(1) 若存在向量 $\mathbf{d} = \mathbf{x} - \bar{\mathbf{x}} \in \mathbb{R}^n$ 使得 $\nabla f(\bar{\mathbf{x}})^T \mathbf{d} < 0$, 则 $\mathbf{d}$ 就是 $f(\mathbf{x})$ 在点 $\bar{\mathbf{x}}$ 处的下降方向。

特别地, 向量 $\mathbf{d} = -\nabla f(\bar{\mathbf{x}})$ 是 f 在 $\bar{\mathbf{x}}$ 处的一个下降方向。

(2) 若矩阵 $H \in \mathbb{R}^{n \times n}$ 对称正定, 则向量 $\mathbf{d} = -H\nabla f(\bar{\mathbf{x}})$ 是 f 在 $\bar{\mathbf{x}}$ 处的一个下降方向。

证明 显然, 结论(2)是结论(1)的一种特殊情形, 故只需证明结论(1)。设 $\nabla f(\bar{\mathbf{x}})^T \mathbf{d} < 0$ 。利用Taylor展开, 得到: 当 $\alpha > 0$ 充分小时

$$f(\bar{\mathbf{x}} + \alpha \mathbf{d}) = f(\bar{\mathbf{x}}) + \alpha \nabla f(\bar{\mathbf{x}})^T \mathbf{d} + o(\alpha) < f(\bar{\mathbf{x}})$$

即 $\mathbf{d}$ 是 f 在 $\bar{\mathbf{x}}$ 处的一个下降方向。

(2)

寻找 α_k 使得 $\alpha_k = \arg \min_{\alpha > 0} \phi(\alpha)$, 即 α_k 为最佳步长。

最佳步长的正交性条件: 由极值的必要条件知, α_k 是方程

$$\phi'(\alpha) = \nabla f(\mathbf{x}^k + \alpha \mathbf{d}^k)^T \mathbf{d}^k = 0 \text{ 的非负根。}$$

通常求 $\phi(\alpha)$ 的全局极小点是困难的, 往往取方程的最小正根作为 $\phi(\alpha)$ 的极小点

$$\alpha_k, \text{ 这就是 Curry 准则, 即 } \alpha_k = \min \{ \alpha | \nabla f(\mathbf{x}^k + \alpha \mathbf{d}^k)^T \mathbf{d}^k = 0, \alpha > 0 \}$$

证明 假设 $\nabla f(\mathbf{x}^*) \neq \mathbf{0}$ 。定义 $\mathbf{d} = -\nabla f(\mathbf{x}^*)$, 则对充分小的 $\alpha > 0$, 利用一阶Taylor展式

$$\begin{aligned} f(\mathbf{x}^* + \alpha \mathbf{d}) &= f(\mathbf{x}^*) + \alpha \nabla f(\mathbf{x}^*)^T \mathbf{d} + o(\alpha) \\ &= f(\mathbf{x}^*) - \alpha \|\nabla f(\mathbf{x}^*)\|^2 + o(\alpha) < f(\mathbf{x}^*) \end{aligned}$$

这与 $\mathbf{x}^*$ 是局部最优解矛盾。

(3)

$$\alpha_k = \operatorname{argmin} f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)}), \text{ 有 } \left. \frac{df(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})}{d\alpha} \right|_{\alpha=\alpha_k} = (\mathbf{d}^{(k)})^T \nabla f(\mathbf{x}^{(k+1)}) = 0.$$

表明 $\mathbf{d}^{(k)}$ 与 $\mathbf{d}^{(k+1)}$ 是正交的, 即 $\mathbf{g}_{k+1}^T \mathbf{g}_k = 0$ 。

后一次下降方向 $\mathbf{g}_{k+1}$ 与前一次下降方向 $\mathbf{g}_k$ 总是互相垂直的, 称之为锯齿状下降。

s5.各种算法的迭代次数, 是否能收敛, 是否具备二次终止性等特点总结:

(1) **最速下降法**具有全局收敛性, 最速梯度下降在二次型上的收敛速度是线性的, 收敛系数随着条件数的增加而增大, 条件数远远大于1的矩阵是病态的。以该矩阵为黑塞矩阵的函数是病态的。步长固定的梯度下降只有步长满足一定条件时才会收敛。

(2) 目标函数为正定二次函数时, 对于任意初始点, **牛顿法**的收敛阶数为 ∞ , 具有二次终止性。一般情况下, 牛顿法的初始点必须与最优点足够近, 具有局部收敛性, 在迭代过程中计算的黑塞矩阵需正定时具备二阶收敛速度, 当黑塞矩阵奇异时无法计算。

(3) 对于任意初始点 $\mathbf{x}_0$, **基本的共轭方向算法**都能在 n 次迭代之内收敛到唯一的全局极小点 $\mathbf{x}^*$, 即 $\mathbf{x}(n) = \mathbf{x}^*$, 具有二次终止性。**共轭梯度法**也具备二次终止性。

(4) 对于 n 维正定二次型问题, **Broyden族 (DFP, BFGS)** 方法最多经过 n 步迭代即可解出最优解, 具有二次终止性。对于非二次型问题, 拟牛顿法通常不会在 n 步之内收敛到极小点。

(5) **原始Powell 算法**用于二次函数极小化问题的求解时产生的加速方向关于二次函数的Hessian矩阵相互共轭, 从而算法具有二次终止性

(6) **外罚函数法**达到的聚点必为全局最优解, 其具有病态性。**内罚函数法**得到的聚点也为全局最优解, 但是它不能解决等式约束问题,