

最优化问题基础

2023年4月11日 19:03

魏尔斯特拉斯定理(Weierstrass定理), 连续函数在紧集上一定存在最优解):

假设 $f: \Omega \rightarrow \mathbb{R}$ 是一个连续函数, 其中 $\Omega \subset \mathbb{R}^n$ 是紧集(有界闭集)。那么, 必定存在点 $x_0 \in \Omega$, 使得对于所有的 $x \in \Omega$ 都有 $f(x_0) \leq f(x)$ 。也就是说, f 能够在 Ω 上取得极小值。

因此一般取可行域 D 为紧集, 约束条件取 $c_i(x) \leq 0$, 而不是 $c_i(x) < 0$ 。

$$f(x) = \frac{1}{2} x^T A x + b^T x + c, \text{ 其中 } x \in \mathbb{R}^n, A \text{ 是 } n \times n \text{ 对称矩阵, } b \in \mathbb{R}^n, c \in \mathbb{R}.$$
$$\nabla f(x) = A x + b, \quad \nabla^2 f(x) = A$$

一元函数 $\phi(a) = f(x + ad)$, $a \in \mathbb{R}, x, d \in \mathbb{R}^n$ 的一阶导数、一阶导数。

$$\nabla f(x + ad)^T d$$

$$d^T \nabla^2 f(x + ad) d$$

定理 若函数 $f(x)$ 具有连续的一阶偏导数, 则它在 $\bar{x}$ 处沿方向 d 的一阶方向导数为

$$\frac{\partial}{\partial d} f(\bar{x}) = \left\langle \nabla f(\bar{x}), \frac{d}{\|d\|} \right\rangle = \frac{1}{\|d\|} d^T \nabla f(\bar{x}).$$

证明 记 $\bar{x} = (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n)^T$, $d = (d_1, \dots, d_n)^T$, 考虑单变量函数 $\phi(a) = f(\bar{x} + ad)$,

$$\phi'(a) = d^T \nabla f(\bar{x} + ad),$$

当 $a = 0$ 时, 有 $\phi'(0) = d^T \nabla f(\bar{x})$.

$$\frac{\partial}{\partial d} f(\bar{x}) = \lim_{a \rightarrow 0^+} \frac{f(\bar{x} + ad) - f(\bar{x})}{a \|d\|} = \frac{1}{\|d\|} \lim_{a \rightarrow 0^+} \frac{\phi(a) - \phi(0)}{a} = \frac{1}{\|d\|} \phi'(0) = \frac{1}{\|d\|} d^T \nabla f(\bar{x}) \quad \square$$

$d = \nabla f(\bar{x})$ 是在 $\bar{x}$ 处使得方向导数达到最大的方向, 称为 $\bar{x}$ 处的最速上升方向 (steepest ascent direction).

同理, 可得 $\frac{\partial}{\partial d} f(\bar{x}) \geq -\|\nabla f(\bar{x})\|$, 当 $d = -\nabla f(\bar{x})$ 时, 有 $\frac{\partial}{\partial d} f(\bar{x}) = -\|\nabla f(\bar{x})\|$,

$d = -\nabla f(\bar{x})$ 称为 $\bar{x}$ 处的最速下降方向 (steepest descent direction).

定理 若函数 $f(\mathbf{x})$ 具有连续的二阶偏导数, 则它在 $\bar{\mathbf{x}}$ 处的二阶方向导数为

$$\frac{\partial^2}{\partial \mathbf{d}^2} f(\bar{\mathbf{x}}) = \frac{1}{\|\mathbf{d}\|^2} \mathbf{d}^T \nabla^2 f(\bar{\mathbf{x}}) \mathbf{d}.$$

证明 考虑单变量函数 $\phi(a) = f(\bar{\mathbf{x}} + a\mathbf{d})$, $\phi''(a) = \mathbf{d}^T \nabla^2 f(\bar{\mathbf{x}} + a\mathbf{d}) \mathbf{d}$

当 $a = 0$ 时, 有 $\phi''(0) = \mathbf{d}^T \nabla^2 f(\bar{\mathbf{x}}) \mathbf{d}$.

$$\frac{\partial}{\partial \mathbf{d}} f(\bar{\mathbf{x}}) = \frac{1}{\|\mathbf{d}\|} \phi'(0), \quad \frac{\partial}{\partial \mathbf{d}} f(\bar{\mathbf{x}} + a\mathbf{d}) = \frac{1}{\|\mathbf{d}\|} \phi'(a)$$

$$\begin{aligned} \frac{\partial^2}{\partial \mathbf{d}^2} f(\bar{\mathbf{x}}) &= \lim_{a \rightarrow 0^+} \frac{\frac{\partial}{\partial \mathbf{d}} f(\bar{\mathbf{x}} + a\mathbf{d}) - \frac{\partial}{\partial \mathbf{d}} f(\bar{\mathbf{x}})}{a \|\mathbf{d}\|} = \frac{1}{\|\mathbf{d}\|^2} \lim_{a \rightarrow 0^+} \frac{\phi'(a) - \phi'(0)}{a} \\ &= \frac{1}{\|\mathbf{d}\|^2} \phi''(0) = \frac{1}{\|\mathbf{d}\|^2} \mathbf{d}^T \nabla^2 f(\bar{\mathbf{x}}) \mathbf{d} \end{aligned}$$

设 X 是 $\mathbb{R}^n$ 的子集, 若对于任意 $x, y \in X$ 和任意 $\lambda \in (0, 1)$, 有 $(1 - \lambda)x + \lambda y \in X$, 即连接集合 X 中任意两点的线段都在集合 X 中, 则称 X 是凸集.

常见的直线、超平面、单位球、正方体等均为凸集. 规定单点集和空集也是凸集.

设 $X \subset \mathbb{R}^n$ 是凸集, $f: X \rightarrow \mathbb{R}$, 若对任意的 $x, y \in X$ 和任意的 $\lambda \in (0, 1)$, 不等式 $f((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y)$

成立, 则称 $f(x)$ 是 X 上的凸函数(Convex function).

定理 若 $f \in C^2(\mathbb{R}^n)$, 则下面三个结论是等价的:

(1) f 是凸函数;

(2) $f(y) \geq f(x) + \nabla f(x)^T(y - x), \forall x, y \in \mathbb{R}^n$ (一阶条件)

(3) $\nabla^2 f(x)$ 是半正定的, 记作 $\nabla^2 f(x) \geq 0$. (二阶条件)

凸规划问题的最优解具有下述特殊性质:

- ① 如果最优解存在, 那么最优解集为凸集;
- ② 任何局部最优解也就是全局最优解;
- ③ 如果目标函数为严格凸函数且最优解存在, 那么最优解唯一。

线性规划和二次规划都是凸优化过程

一阶必要条件

设 $f(\mathbf{x})$ 在 $\mathbf{x}^* \in \mathbb{R}^n$ 处可微, 若 $\mathbf{x}^*$ 为无约束优化问题 $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$ 的局部最优解, 则 $\nabla f(\mathbf{x}^*) = \mathbf{0}$.

二阶必要条件

设 $f(x)$ 二阶连续可微. 若 x^* 是无约束问题 $\min_{x \in \mathbb{R}^n} f(x)$ 的一个局部解, 则

(1) $\nabla f(x^*) = 0$

(2) $\nabla^2 f(x^*)$ 为半正定. (在局部解 x^* 处的二阶方向导数非负)

二阶充分条件

设 $f(x)$ 二阶连续可微, 且满足 (1) $\nabla f(x^*) = 0$ (2) $\nabla^2 f(x^*)$ 为正定, 则 x^* 是无约束问题的一个严格局部解.

定理(二阶充分条件) 设 $f(x)$ 在点 $x^* \in \mathbb{R}^n$ 的一个邻域 $N(x^*, \delta)$ 内二次可微. 若在点 x^* 处满足 $\nabla f(x^*) = 0$, 且 $\forall x \in N(x^*, \delta)$ 都有 $\nabla^2 f(x)$ 半正定, 则 x^* 是函数 $f(x)$ 的局部极小点.

若 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸函数, 且 $f(x)$ 一阶连续可微, 则 x^* 是全局最小解的充分必要条件是 $\nabla f(x^*) = 0$.

对于 $\nabla f(x^*) = 0$ 的临界点 x^* , 如果 $\nabla^2 f(x^*)$

- 正定, 则 x^* 是 f 的极小值点;
- 负定, 则 x^* 是 f 的极大值点;
- 不定, 则 x^* 是 f 的鞍点;

性质1: 设 A 是一个 2×2 的对称矩阵, 则 A 半正定(正定), 当且仅当

$$\text{Tr}(A), \det(A) \geq 0 (\text{Tr}(A), \det(A) > 0)$$

- 对于一个算法, 如果它对任意正定二次函数, 从任意初始点出发, 可以经有限步迭代求得极小点, 就说该算法具有二次终止性。

步长 a_k 的确定方法即为一维搜索问题.

通常求 $\phi(\alpha)$ 的全局极小点是困难的, 往往取方程的最小正根作为 $\phi(\alpha)$ 的极小点

α_k , 这就是 **Curry 准则**, 即 $\alpha_k = \min \{ \alpha | \nabla f(x^k + \alpha d^k)^T d^k = 0, \alpha > 0 \}$

对于二次函数极小化问题 $\min f(x) = \frac{1}{2} x^T G x + g^T x + b$,

其中 $G \in \mathbb{R}^{n \times n}$ 是对称正定矩阵, 设 $d^{(k)}$ 是 $f(x)$ 在 $x^{(k)}$ 处的下降方向, 最优步长

$$\alpha_k = -\frac{\nabla f(x^{(k)})^T d^{(k)}}{(d^{(k)})^T G d^{(k)}}$$

定理 设 $\nabla f(x)$ 在水平集 $L(x^0) = \{x \mid f(x) \leq f(x^0)\}$ 上存在且一致连续, 下降算法的搜索方向 d^k 与 $-\nabla f(x^k)$ 之间的夹角 θ_k 满足 $0 \leq \theta_k \leq \frac{\pi}{2} - \bar{u}$ ($\bar{u} > 0$), 步长 α_k 由以下3种方法之一确定, (1) 精确线性搜索; (2) Glodstein方法; (3) Wolfe-Powell方法, 取搜索方向 $d^{(k)} = -\nabla f(x^{(k)})$ 的方法称为**梯度下降法**

目标函数为正定二次函数 $f(x) = \frac{1}{2}x^T Ax + b^T x + c$ 时, 最速下降法的迭代公式为:

$$g_k = Ax^{(k)} + b$$

$$x^{(k+1)} = x^{(k)} - \frac{g_k^T g_k}{g_k^T A g_k} g_k, \quad k = 0, 1, \dots$$

基本Newton法

- (1) 取初始点 $x^{(0)}$, 置精度要求 ε , 置 $k = 0$.
- (2) 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 则停止计算 ($x^{(k)}$ 作为无约束问题的解);
 否则, 求解线性方程组 $\nabla^2 f(x^{(k)})d = -\nabla f(x^{(k)})$, 得到 $d^{(k)}$.
- (3) 置 $x^{(k+1)} = x^{(k)} + d^{(k)}, k := k + 1$, 转步骤 (2).

经典牛顿法的收敛是有条件的:

- (1) 初始点 $x^{(0)}$ 必须距离问题的解充分近, 即牛顿法只有**局部收敛性**, 当 $x^{(0)}$ 距问题的解较远时, 牛顿算法在多数情况下会失效;
- (2) 海瑟矩阵 $\nabla^2 f(x^*)$ 需要为**正定矩阵**, 具有二阶收敛速度. 若 $\nabla^2 f(x^*)$ 是奇异的半正定矩阵, 牛顿算法的收敛速度可能仅达到 Q-线性.

Algorithm 1 带线搜索的修正牛顿法

- 1: 给定初始点 x^0 .
 - 2: **for** $k = 0, 1, 2, \dots$ **do**
 - 3: 确定矩阵 E^k 使得矩阵 $B^k \stackrel{\text{def}}{=} \nabla^2 f(x^k) + E^k$ 正定且条件数较小.
 - 4: 求解修正的牛顿方程 $B^k d^k = -\nabla f(x^k)$ 得方向 d^k .
 - 5: 使用任意一种线搜索准则确定步长 α_k .
 - 6: 更新 $x^{k+1} = x^k + \alpha_k d^k$.
 - 7: **end for**
-

- **最速下降法**: 负梯度方向搜索, 迭代次数不确定, 不需要计算 $\mathbf{S}^{-1}$
- **牛顿法**: 牛顿方向搜索, 一次迭代, 需要计算Hesse矩阵的逆 $\mathbf{S}^{-1}$
- **共轭梯度法**: 共轭方向搜索

- 对于n维二次型问题, 能够在n步之内得到结果;
- 不需要Hesse矩阵 (Hessian-Free优化);
- 不需要计算Hesse矩阵的逆

影响迭代搜索算法效率的关键因素为每次迭代的搜索方向

定义 设 $\mathbf{S}$ 是 $n \times n$ 对称正定矩阵.

若 $\mathbb{R}^n$ 中两个非零向量 $\mathbf{d}_i, \mathbf{d}_j (i \neq j)$ 满足 $\mathbf{d}_i^T \mathbf{S} \mathbf{d}_j = 0$, 则称 $\mathbf{d}_i$ 与 $\mathbf{d}_j$ 是 $(\mathbf{S})$ **共轭方向**.

若 $\mathbb{R}^n$ 中 n 个非零向量 $\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}$ 满足 $\mathbf{d}_i^T \mathbf{S} \mathbf{d}_j = 0, i, j = 0, \dots, n-1, i \neq j$, 则称它们为 $\mathbf{S}$ 的**两两共轭方向**, 或称这个向量组是 $(\mathbf{S})$ **共轭向量组**.

方法3: 格拉姆-施密特 (Gram-Schmidt) 过程可以将 $\mathbb{R}^n$ 中的一组基向量转换为一组标准正交基向量, 借鉴这一过程, 可以设计一种系统化的构造关于 $\mathbf{S}$ 共轭向量的算法流程。

给定一组 $\mathbb{R}^n$ 中的线性无关向量 $\{\mathbf{p}^{(0)}, \dots, \mathbf{p}^{(n-1)}\}$, 利用格拉姆-施密特方法可以产生一组向量 $\{\mathbf{d}^{(0)}, \dots, \mathbf{d}^{(n-1)}\}$:

$$\begin{aligned} \mathbf{d}^{(0)} &= \mathbf{p}^{(0)} \\ \mathbf{d}^{(k+1)} &= \mathbf{p}^{(k+1)} - \sum_{i=0}^k \frac{\mathbf{p}^{(k+1)T} \mathbf{S} \mathbf{d}^{(i)}}{\mathbf{d}^{(i)T} \mathbf{S} \mathbf{d}^{(i)}} \mathbf{d}^{(i)} \end{aligned}$$

可以证明, 向量 $\mathbf{d}^{(0)}, \dots, \mathbf{d}^{(n-1)}$ 是关于 $\mathbf{S}$ 共轭的。

如果这一组 $\mathbf{p}$ 是生成 $\mathbf{S}$ 的, 则后面的求和操作中间就不用乘 $\mathbf{S}$ 了

基本的共轭方向算法

给定初始点 $\mathbf{x}^{(0)}$ 和一组关于 $\mathbf{S}$ 共轭的方向 $\mathbf{d}^{(0)}, \mathbf{d}^{(1)}, \dots, \mathbf{d}^{(n-1)}$,

迭代公式为 ($k \geq 0$ 表示迭代次数):

$$\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)}) = \mathbf{S} \mathbf{x}^{(k)} + \mathbf{b}$$

$$\alpha_k = -\frac{\mathbf{g}^{(k)T} \mathbf{d}^{(k)}}{\mathbf{d}^{(k)T} \mathbf{S} \mathbf{d}^{(k)}}$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$$

共轭梯度法：求正定二次函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{S} \mathbf{x} + \mathbf{b}^T \mathbf{x}$ 的极小点

(1) 令 $k := 0$; 选择初始值 $\mathbf{x}^{(0)}$ 。

(2) 计算 $\mathbf{g}^{(0)} = \nabla f(\mathbf{x}^{(0)}) = \mathbf{S} \mathbf{x}^{(0)} + \mathbf{b}$, 如果 $\mathbf{g}^{(0)} = \mathbf{0}$, 停止迭代; 否则, 令 $\mathbf{d}^{(0)} = -\mathbf{g}^{(0)}$ 。

(3) 计算 $\alpha_k = -\frac{\mathbf{g}^{(k)T} \mathbf{d}^{(k)}}{\mathbf{d}^{(k)T} \mathbf{S} \mathbf{d}^{(k)}}$

(4) 计算 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$ 。

(5) 计算 $\mathbf{g}^{(k+1)} = \nabla f(\mathbf{x}^{(k+1)})$, 如果 $\mathbf{g}^{(k+1)} = \mathbf{0}$, 停止迭代。

(6) 计算 $\beta_k = \frac{\mathbf{g}^{(k+1)T} \mathbf{S} \mathbf{d}^{(k)}}{\mathbf{d}^{(k)T} \mathbf{S} \mathbf{d}^{(k)}}$ 。

(7) 计算 $\mathbf{d}^{(k+1)} = -\mathbf{g}^{(k+1)} + \beta_k \mathbf{d}^{(k)}$ 。

(8) 令 $k := k + 1$, 回到第 3 步。

拟牛顿方法的基本性质:

定理(拟牛顿法是一种共轭方向法) 将拟牛顿法应用到二次型问题中, $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x}$, $\mathbf{A}$ 为 $n \times n$ 对称正定矩阵, 黑塞矩阵为 $\mathbf{A}$,

$\mathbf{g}^{(i)} = \nabla f(\mathbf{x}^{(i)}) = \mathbf{A} \mathbf{x}^{(i)} + \mathbf{b}$,

$\Delta \mathbf{x}^{(i)} = \mathbf{x}^{(i+1)} - \mathbf{x}^{(i)} = \alpha_i \mathbf{d}^{(i)}$, $\Delta \mathbf{g}^{(i)} = \mathbf{g}^{(i+1)} - \mathbf{g}^{(i)} = \mathbf{A} \Delta \mathbf{x}^{(i)}$

$$\begin{aligned} \mathbf{d}^{(k)} &= -\mathbf{H}_k \mathbf{g}^{(k)} \\ \alpha_k &= \arg \min_{\alpha \geq 0} f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)}) \\ \mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)} \end{aligned}$$

其中, 矩阵 $\mathbf{H}_0, \mathbf{H}_1, \mathbf{H}_2, \dots$ 是对称正定矩阵

且对于 $0 \leq k < n-1$, 有 $\mathbf{H}_{k+1} \Delta \mathbf{g}^{(i)} = \Delta \mathbf{x}^{(i)}$, $0 \leq i \leq k$

如果 $\alpha_i \neq 0, 0 \leq i \leq k$, 那么 $\mathbf{d}^{(0)}, \mathbf{d}^{(1)}, \dots, \mathbf{d}^{(k+1)}$ 是 $\mathbf{A}$ 共轭的。

由可行方向和序列可行方向的定义: 对任给的 $\mathbf{x} \in \Omega$, $FD(\mathbf{x}) \subseteq SFD(\mathbf{x})$.

几何上, 可行方向是指向可行域内部的方向, 序列可行方向包含了可行方向全体及其极限。

设 $\mathbf{x}^* \in \Omega$, 对 $\mathbf{0} \neq \mathbf{d} \in \mathbb{R}^n$, 如果 $\mathbf{d}^T \nabla c_i(\mathbf{x}^*) = 0, i \in E$, $\mathbf{d}^T \nabla c_i(\mathbf{x}^*) \leq 0, i \in I(\mathbf{x}^*)$

则称 $\mathbf{d}$ 为 $\mathbf{x}^*$ 处的线性化可行方向。(没有考虑非有效约束)

定理(约束规划问题局部解的几何一阶必要条件) 若 $\mathbf{x}^*$ 是约束优化问题的局部极小点, 则

$$SFD(\mathbf{x}^*) \cap DD(\mathbf{x}^*) = \emptyset$$

即在局部极小点处不存在可行下降方向。

假设 x^* 满足KKT条件, 则满足

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{i=1}^l \mu_i \nabla h_i(x^*) = 0 \quad (1)$$

$$\lambda_i \geq 0 \quad i = 1, \dots, m \quad (2)$$

$$g_i(x) \leq 0 \quad i = 1, \dots, m \quad (3)$$

$$h_i(x) = 0 \quad i = 1, \dots, l \quad (4)$$

$$\lambda_i g_i(x^*) = 0 \quad i = 1, \dots, m \quad (5)$$

记一个新函数

$$L(x) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{i=1}^l \mu_i h_i(x)$$

定理 (约束问题局部解的一阶必要条件) 设约束问题 (1) 中 $f(x)$, $c_i(x)$ ($i = 1, 2, \dots, l+m$) 具有连续的一阶偏导数, 若 x^* 是约束问题 (1) 的**局部解**, 并且在 x^* 处**约束限制条件成立** (即 $SFD^* = LFD^*$), 则存在 $\lambda^* = (\lambda_1^*, \lambda_2^*, \dots, \lambda_{l+m}^*)^T$, 使得

$$\nabla_x L(x^*, \lambda^*) = \nabla f(x^*) + \sum_{i=1}^{l+m} \lambda_i^* \nabla c_i(x^*) = 0,$$

$$c_i(x^*) = 0, i \in E = \{1, 2, \dots, l\},$$

$$c_i(x^*) \leq 0, i \in I = \{l+1, l+2, \dots, l+m\},$$

$$\lambda_i^* \geq 0, i \in I = \{l+1, l+2, \dots, l+m\},$$

$$\lambda_i^* c_i(x^*) = 0, i \in I = \{l+1, l+2, \dots, l+m\},$$

其中 **Lagrange函数** $L(x, \lambda) = f(x) + \sum_{i=1}^{l+m} \lambda_i c_i(x)$.

- 对 $\forall d \in SFD^*$, 若 $\nabla f(x^*)^T d > 0$ 成立, 即在 x^* 处所有可行都是上升方向, 则 x^* 是一个**严格局部最优解**;
- 若 $\exists d \in SFD^*$, 满足 $\nabla f(x^*)^T d < 0$, 即在 x^* 处有可行下降方向, 则 x^* **不是局部最优解**.
- 对于满足 $\nabla f(x^*)^T d = 0$ 的可行方向, **无法判断 x^* 是否是最优解**.

定理(约束问题局部解的二阶充分条件) 考虑约束问题 (1), 设 $f(x), c_i(x) (i \in E \cup I)$ 具有连续的二阶偏导数. 若存在 x^* 满足下列条件:

(1) KKT 条件成立, 即存在 $\lambda^* = (\lambda_1^*, \lambda_2^*, \dots, \lambda_{l+m}^*)^T$, 使得

$$\begin{aligned}\nabla_x L(x^*, \lambda^*) &= \nabla f(x^*) + \sum_{i=1}^{l+m} \lambda_i^* \nabla c_i(x^*) = 0, \\ c_i(x^*) &= 0, i \in E = \{1, 2, \dots, l\}, \\ c_i(x^*) &\leq 0, i \in I = \{l+1, l+2, \dots, l+m\}, \\ \lambda_i^* &\geq 0, i \in I = \{l+1, l+2, \dots, l+m\}, \\ \lambda_i^* c_i(x^*) &= 0, i \in I = \{l+1, l+2, \dots, l+m\},\end{aligned}$$

(2) 对于任意的 $d \in LFD_1^*$, 有 $d^T \nabla_x^2 L(x^*, \lambda^*) d > 0$,

其中 $M = LFD_1^* = \{d \in \mathbb{R}^n \mid d \neq 0, \nabla c_i(x^*)^T d = 0, i \in E; \nabla c_i(x^*)^T d = 0, i \in I(x^*), \lambda_i^* > 0; \nabla c_i(x^*)^T d \leq 0, i \in I(x^*), \lambda_i^* = 0\}$ 是 x^* 处线性化可行方向的子集;
 $I(x^*)$ 是 x^* 处的有效约束指标集;

则 x^* 是约束问题 (1) 的严格局部解.

- 可以证明: 对偶问题D的最优值 $\leq$ 问题P的最优值, 即对偶问题D的最优值等于或者是问题P的最优值的下限。

要得到最大化下界 $d(\lambda, \mu)$, 可以求解 **Lagrange 对偶问题 (dual problem, 简称对偶问题)**:

$$\begin{aligned}\max \quad & d(\lambda, \mu) \\ \text{s. t.} \quad & \mu_i \geq 0, i \in I.\end{aligned}\tag{3}$$

$$d^* = \max_{\lambda, \mu \geq 0} d(\lambda, \mu) = \max_{\lambda, \mu \geq 0} \min_{x \in X} L(x, \lambda, \mu)$$

弱对偶性(Weak Duality)

$$d^* \leq p^*$$

强对偶性(Strong Duality)


如果 $d^* = p^*$, 则称强对偶性成立。

如果原问题是凸优化问题, 则通常 (但不总是) 强对偶性成立。

凸优化 + Slater条件 $\Rightarrow$ 强对偶成立

Slater条件(Slater's condition)

如果原问题是凸优化问题, 集合 X 为非空凸集, $f(x)$ 及 $g_j(x), j \in I$ 是凸函数, $h_i(x), i \in E$ 均为线性函数, 并且至少存在绝对一个绝对可行点 (绝对可行点就是一个可以让所有不等式约束都不取等号的可行点), 那么强对偶性成立。



内罚函数的定义可以如下:

$B(x)$ 可以是约束的倒数和的形式,称为**倒数障碍函数(Inverse Barrier)**.

$$B(x) = - \sum_{i=1}^p \frac{1}{g_i(x)},$$

$B(x)$ 可以取成对数形式, 称为**对数障碍函数(Log Barrier)**

$$B(x) = - \sum_{i=1}^p \min\{0, \ln(-g_i(x))\}$$