

最优化 · 重点知识点 + 题型模板 + 例题（期末突击学习版）

怎么用这份文档：按「题型」组织，每个题型 = 知识点（够用就行）+ 公式化解题步骤（SOP，照着套）+ 例题（用模拟题/往年真题完整演算）。

目标是第一次学也能上手算，而不是泛泛复习。配套深讲见 [详细笔记](#)。

两类卷子要分清：

- 往年题（mid-2017~2022）= 期中「凸优化」：偏理论——凸集/凸锥/对偶锥证明、共轭函数、SOCP/SDP 化归、复杂对偶。→ 见 题型 A/B/C/F。
- 模拟题 = 期末「优化理论与方法」+ 个人总结例题：偏计算——凸性判定、驻点分类、梯度/牛顿/共轭/拟牛顿算法、KKT、罚函数/ALM。→ 见 题型 D~L。
- 期末通常两头都考，但计算题（D~L）是拿分主力，优先吃透。

〇、30 秒速查公式表

梯度/Hessian（二次型 $f = \frac{1}{2}x^T Ax + b^T x + c$, A 对称）： $\nabla f = Ax + b$, $\nabla^2 f = A$ 。

凸性： $\nabla^2 f \succeq 0$ （凸）/ $\succ 0$ （严格凸）/ $\succeq mI$ （ m -强凸）/ $\preceq LI$ （ L -光滑）。一阶判据 $f(y) \geq f(x) + \nabla f(x)^T(y - x)$ 。

最优性条件

问题	必要条件	充分条件
无约束	$\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*) \succeq 0$	$\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*) \succ 0$ （严格极小）
约束	KKT（需约束品性 CQ）	凸问题下 KKT 即充分（全局）

KKT ($\min f$ s.t. $c_i = 0$ ($i \in E$), $c_j \leq 0$ ($j \in I$)):

① 平稳 $\nabla f + \sum_{i \in E} \lambda_i \nabla c_i + \sum_{j \in I} \mu_j \nabla c_j = 0$; ② 原始可行; ③ $\mu_j \geq 0$; ④ 互补 $\mu_j c_j = 0$ 。

算法迭代核心

方法	方向 / 步长 / 迭代
梯度下降	$x^{k+1} = x^k - \alpha_k g_k, g_k = \nabla f(x^k)$
最速下降(二次型)	$\alpha_k = \frac{g_k^T g_k}{g_k^T A g_k}$
一般下降方向精确步长(二次型)	$\alpha_k = -\frac{g_k^T d_k}{d_k^T A d_k}$
牛顿法	解 $\nabla^2 f(x^k) d^k = -\nabla f(x^k), x^{k+1} = x^k + d^k$
高斯-牛顿	$J^T J d = -J^T r$

方法	方向 / 步长 / 迭代
LM	$(J^T J + \nu I)d = -J^T r$
共轭梯度(FR)	$d^{k+1} = -g_{k+1} + \beta_k d^k, \beta_k^{FR} = \frac{g_{k+1}^T g_{k+1}}{g_k^T g_k}$
拟牛顿通式	$d^k = -H_k g_k$ (H_k 对称正定, 近似 $[\nabla^2 f]^{-1}$)
割线方程	$B^{k+1} s^k = y^k$ 或 $H^{k+1} y^k = s^k, s = x^{k+1} - x^k, y = g_{k+1} - g_k$
BFGS (H 形式)	$H^{k+1} = (I - \rho s y^T) H^k (I - \rho y s^T) + \rho s s^T, \rho = \frac{1}{y^T s}$
DFP (H 形式)	$H^{k+1} = H^k - \frac{H y y^T H}{y^T H y} + \frac{s s^T}{y^T s}$
BB 步长	$\alpha_{BB1} = \frac{s^T y}{y^T y}, \alpha_{BB2} = \frac{s^T s}{s^T y}$

ALM (等式约束): $L_\sigma = f + \sum \lambda_i c_i + \frac{\sigma}{2} \sum c_i^2$, 乘子更新 $\lambda^{k+1} = \lambda^k + \sigma_k c(x^{k+1})$ 。

题型 A · 判定函数的凸性 / 凹性

知识点

$f \in C^2$ 时三条等价: ① f 凸; ② $f(y) \geq f(x) + \nabla f(x)^T (y - x)$; ③ $\nabla^2 f(x) \succeq 0$ (在整个定义域上)。

- **严格凸**: $\nabla^2 f \succ 0$ (充分非必要, 如 x^4)。
- **凹**: $-f$ 凸, 即 $\nabla^2 f \preceq 0$ 。
- **既非凸也非凹**: Hessian **变号** (有的点正定、有的点负定)。
- 2×2 矩阵定号速判: $A \succ 0 \iff \text{tr } A > 0$ 且 $\det A > 0$; $A \succeq 0 \iff \text{tr } A \geq 0, \det A \geq 0$ 且对角元 ≥ 0 。 $n \times n$ 用**顺序主子式**全 > 0 判正定。

解题步骤 (SOP)

1. 写出定义域, 确认是凸集 (否则无从谈起)。
2. 求 ∇f 、 $\nabla^2 f$ 。
3. 判 $\nabla^2 f$ 定号: 主子式 / 特征值 / 配成 $\sum (\dots)^2$ / 写成 vv^T 型 (秩 1 半正定)。
4. 在**整个定义域**上恒 $\succeq 0 \rightarrow$ 凸; 恒 $\preceq 0 \rightarrow$ 凹; 变号 $\rightarrow$ 都不是。
5. **一元函数**直接看 $f''(x)$ 的符号。

例 A1 (模拟题一.1) $f(x) = \frac{1}{1 + e^{-x}}$ (sigmoid), 凸还是凹?

记 $\sigma = f$ 。 $f' = \sigma(1 - \sigma) > 0$; $f'' = \sigma(1 - \sigma)(1 - 2\sigma)$ 。

- $x < 0 \Rightarrow \sigma < \frac{1}{2} \Rightarrow f'' > 0$ (局部凸);
- $x > 0 \Rightarrow \sigma > \frac{1}{2} \Rightarrow f'' < 0$ (局部凹)。

f'' 在 $x = 0$ 变号 $\Rightarrow$ 在 $\mathbb{R}$ 上既不是凸函数, 也不是凹函数。

例 A2 (模拟题一.2) $f(x_1, x_2) = \frac{x_1^2}{x_2}$, $\text{dom} = \mathbb{R} \times \mathbb{R}_{++}$

偏导: $f_{x_1} = \frac{2x_1}{x_2}$, $f_{x_2} = -\frac{x_1^2}{x_2^2}$ 。

$$\nabla^2 f = \begin{bmatrix} \frac{2}{x_2} & -\frac{2x_1}{x_2^2} \\ -\frac{2x_1}{x_2^2} & \frac{2x_1^2}{x_2^3} \end{bmatrix} = \frac{2}{x_2^3} \begin{bmatrix} x_2 & -x_1 \\ -x_1 & x_1^2 \end{bmatrix} [x_2 \quad -x_1].$$

这是 $\frac{2}{x_2^3} vv^T$ 形式 ($x_2 > 0$ 故系数 > 0 , $vv^T \succeq 0$ 恒成立) $\Rightarrow \nabla^2 f \succeq 0 \Rightarrow$ **凸函数** (这是"二次比线性" $\frac{x_1^2}{x_2}$ 的标准结论)。

例 A3 (往年 2022 第 1 题) 证 $f(X) = -\log \det X$ 在 S_{++}^n 上凸

限制到直线法 (证矩阵函数凸的通用套路): 取 $X \succ 0$, $V = V^T$, 令 $g(t) = f(X + tV)$ 。

$g(t) = -\log \det(X + tV) = -\log \det X - \log \det(I + tX^{-1/2}VX^{-1/2}) = -\log \det X - \sum_i \log(1 + t\lambda_i)$, 其中 λ_i 为 $X^{-1/2}VX^{-1/2}$ 的特征值。则 $g''(t) = \sum_i \frac{\lambda_i^2}{(1+t\lambda_i)^2} \geq 0$, 故 g 凸 $\Rightarrow f$ 沿任意直线凸 $\Rightarrow f$ 凸。■

通法: f 凸 $\iff$ 对任意 x, v , $g(t) = f(x + tv)$ 一元凸 (往年 2020 第 2 题就是要你证这个等价性)。矩阵/复杂函数凸性都靠它降到一元。

常用保凸法则 (不必每次求 Hessian)

- 非负加权和、逐点上确界 $\sup_i f_i$ 、与仿射复合 $f(Ax + b)$ 保凸。
- $h(g(x))$: h 凸不减 + g 凸 $\Rightarrow$ 凸。
- 透视函数 $tf(x/t)$ 保凸 ($\frac{x_1^2}{x_2}$ 即 $x_2 \cdot (x_1/x_2)^2$ 的透视)。
- 范数 $\|x\|$ 、 $\max$ 、 $\log \sum e^{x_i}$ 凸; $\log \det X$ 、 $x^{1/n}$ 几何均值在正定域凹。

题型 B · 凸集 / 凸锥 / 对偶锥 (期中常考)

知识点

- **凸集:** $x, y \in C \Rightarrow \theta x + (1 - \theta)y \in C$, $\theta \in [0, 1]$ 。
- **凸锥:** 对 $\theta_1, \theta_2 \geq 0$, $\theta_1 x_1 + \theta_2 x_2 \in K$ (对非负组合封闭)。
- **对偶锥** $K^* = \{y \mid y^T x \geq 0, \forall x \in K\}$, 恒为凸锥。
- 常用: $(\mathbb{R}_+^n)^* = \mathbb{R}_+^n$ (自对偶); $(S_+^n)^* = S_+^n$ (自对偶, 内积为 $\langle X, Y \rangle = \text{tr}(XY)$); 二阶锥自对偶。

解题步骤 (证 K 是凸锥 + 求 K^*)

1. **凸锥:** 任取 $x_1, x_2 \in K$, $\theta_1, \theta_2 \geq 0$, 验证 $\theta_1 x_1 + \theta_2 x_2 \in K$ (逐条代入定义)。
2. **猜 K^* :** 写出 $\{y \mid y^T x \geq 0 \forall x \in K\}$, 凭几何/已知结论猜出闭式 $\hat{K}$ 。
3. **证 $\hat{K} \subseteq K^*$:** 任取 $y \in \hat{K}$, $x \in K$, 直接算 $y^T x \geq 0$ 。
4. **证 $K^* \subseteq \hat{K}$:** 反证——若 $y \notin \hat{K}$, 构造 $x \in K$ 使 $y^T x < 0$ 。

例 B1（往年 2019/2017） S_+^n 的对偶锥是自身

取 $Y \in S_+^n$ ，对任意 $X \in S_+^n$: $\langle X, Y \rangle = \text{tr}(XY) = \text{tr}(Y^{1/2}XY^{1/2}) \geq 0$ (半正定阵的迹非负)，故 $S_+^n \subseteq (S_+^n)^*$ 。反之若 $Y \notin S_+^n$ ，存在 v 使 $v^TYv < 0$ ，取 $X = vv^T \succeq 0$ 得 $\langle X, Y \rangle = v^TYv < 0$ ，故 $Y \notin (S_+^n)^*$ 。两向包含 $\Rightarrow (S_+^n)^* = S_+^n$ 。■

题型 C · 化成 LP/QP/SOCP/SDP（锥规划建模，期中常考）

套路表（"把难写的目标/约束塞进锥里"）

想表达	标准锥形式
$\min \max_i (a_i^T x + b_i)$	引入 t : $\min t$ s.t. $a_i^T x + b_i \leq t$ (LP)
$\ Ax - b\ _2 \leq t$	二阶锥 $(Ax - b, t) \in \mathcal{Q}^{m+1}$ (SOCP)
$\frac{x_1^2}{x_2} \leq t, x_2 > 0$	旋转二阶锥 $\Leftrightarrow \ (2x_1, x_2 - t)\ _2 \leq x_2 + t$
$X \succeq 0 / \lambda_{\max}(A(x)) \leq t$	$X \succeq 0 / tI - A(x) \succeq 0$ (SDP)
Schur 补: $\begin{bmatrix} A & B \\ B^T & C \end{bmatrix} \succeq 0$	$\Leftrightarrow C \succ 0, A - BC^{-1}B^T \succeq 0$ (把二次项线性化进 SDP, 2018 第 1 题)

核心招式：① 上图集 (epigraph) 法——把 $\min f$ 换成 $\min t, f \leq t$; ② 把 $f \leq t$ 的非线性部分认成某个锥的成员关系。

例 C（往年 2019 第 3 题骨架） $\min \frac{\mu}{2} x^T Q x + \|A(x)\|_2$

引 t : $\min \frac{\mu}{2} x^T Q x + t$ s.t. $\|A(x)\|_2 \leq t$ 。

- $\|A(x)\|_2 \leq t$ 即 $(A(x), t)$ 落在二阶锥 ($A(x)$ 是矩阵时用矩阵二范数 $\Rightarrow \begin{bmatrix} tI & A(x) \\ A(x)^T & tI \end{bmatrix} \succeq 0$, 半定锥)。
- 二次项 $\frac{\mu}{2} x^T Q x$ 用 Schur 补再引 s 化成 $\begin{bmatrix} s & (\frac{\mu}{2} Q)^{1/2} x \\ \star & I \end{bmatrix} \succeq 0$ 。
得到一个含二阶锥 + 半定锥的凸问题。

题型 D · 无约束最优性：求驻点并分类

知识点（驻点的"身份证"）

驻点 x^* ($\nabla f = 0$) 处看 $\nabla^2 f(x^*)$:

- 正定 $\Rightarrow$ 严格局部极小; 负定 $\Rightarrow$ 严格局部极大; 不定 (有正有负特征值) $\Rightarrow$ 鞍点。
- 半正定 (含 0 特征值): 二阶判别失效, 需看更高阶或邻域分析。
- 全局/严格: 若 f 凸, 则局部极小=全局极小; 能把 f 配方成平方和 + 常数时, 直接读出全局最小值与是否唯一。

解题步骤 (SOP)

1. $\nabla f = 0$ 解出**所有**驻点 (注意多解: 高次项会给多个根)。
2. 求 $\nabla^2 f$, 逐个驻点代入。
3. 按定号判类型 (正定/负定/不定/半定)。
4. 问全局时: 尝试配方 $f = \sum(\dots)^2 + \text{const}$, 或用凸性, 或 $f \rightarrow +\infty$ 的趋势 + 紧性。

例 D1 (模拟题二) $f = x_1^4 - 2x_1^2 + x_2^2 + 2x_2x_3 + 2x_3^2$

① 驻点: $\nabla f = (4x_1^3 - 4x_1, 2x_2 + 2x_3, 2x_2 + 4x_3) = 0$ 。

- $4x_1(x_1^2 - 1) = 0 \Rightarrow x_1 \in \{0, 1, -1\}$;
- $\begin{cases} x_2 + x_3 = 0 \\ x_2 + 2x_3 = 0 \end{cases} \Rightarrow x_2 = x_3 = 0$ 。

驻点: $(0, 0, 0), (1, 0, 0), (-1, 0, 0)$ 。

② Hessian: $\nabla^2 f = \begin{bmatrix} 12x_1^2 - 4 & 0 & 0 \\ 0 & 2 & 2 \\ 0 & 2 & 4 \end{bmatrix}$ 。右下块 $\begin{bmatrix} 2 & 2 \\ 2 & 4 \end{bmatrix}$: $\det = 4 > 0, \text{tr} > 0 \Rightarrow$ **正定** (恒定)。只需看

$(1, 1)$ 元 $12x_1^2 - 4$:

- $(\pm 1, 0, 0)$: $12 - 4 = 8 > 0 \Rightarrow$ 整体正定 $\Rightarrow$ **严格局部极小**;
- $(0, 0, 0)$: $-4 < 0 \Rightarrow$ 一负两正特征值 $\Rightarrow$ **鞍点**。

③ 全局: 配方

$$f = (x_1^2 - 1)^2 + (x_2 + x_3)^2 + x_3^2 - 1 \geq -1,$$

等号 $\iff x_1^2 = 1, x_3 = 0, x_2 = 0$ 。故 $(\pm 1, 0, 0)$ 都是**全局极小点** (值 -1 , **非唯一**); $(0, 0, 0)$ 是**鞍点** (非极值)。

例 D2 (个人总结) $f = 8x_1^2 + 3x_1x_2 + 7x_2^2 - 19x_1 - 17x_2 - 29$

$$\nabla f = (16x_1 + 3x_2 - 19, 3x_1 + 14x_2 - 17) = 0 \Rightarrow x^* = (1, 1)^T。$$

$\nabla^2 f = \begin{bmatrix} 16 & 3 \\ 3 & 14 \end{bmatrix}$, $\det = 224 - 9 > 0, \text{tr} > 0 \Rightarrow$ 正定 $\Rightarrow$ 严格局部极小。又 f 是正定二次型 $\Rightarrow$ 凸 $\Rightarrow$ **唯一全局极小点** $(1, 1)$ 。

半定失效的处理 (总结例题里那道 $f = (x_1 - 2)^4 + (x_1 - 2x_2)^2$): 驻点 $(2, 1)$ 处 Hessian 半正定, 沿

$x = x^* + \Delta x$ 重算 $H(x) = \begin{bmatrix} 12\Delta x_1^2 + 2 & -4 \\ -4 & 8 \end{bmatrix}$, 邻域内恒半正定 $\Rightarrow$ 仍是局部极小。

题型 E · 约束最优性: Lagrange / KKT

知识点

Lagrange 函数 $L(x, \lambda, \mu) = f(x) + \sum_{i \in E} \lambda_i c_i(x) + \sum_{j \in I} \mu_j c_j(x)$ ($c_j \leq 0$ 形式)。

KKT 五条: 平稳 $\nabla_x L = 0$; 原始可行; 对偶可行 $\mu_j \geq 0$; 互补松弛 $\mu_j c_j = 0$ 。

约束品性 CQ (KKT 成为必要条件的前提, 满足其一即可):

- **LICQ**: 起作用约束的梯度 $\{\nabla c_i\}$ (等式 + 有效不等式) **线性无关**;

- **LFCQ**: 起作用约束都是线性函数。

CQ 不成立时, 局部极小未必是 KKT 点。凸问题 + KKT $\Rightarrow$ 全局最优 (充分)。

解题步骤 (SOP)

1. 列 Lagrange 函数; 写出 KKT 五条。
2. 分有效集讨论不等式约束 (哪些 $c_j = 0$ 起作用、哪些 $\mu_j = 0$ 失效)。
3. 解平稳方程组 + 约束方程, 求出候选 KKT 点。
4. 验对偶可行 ($\mu \geq 0$) + 互补松弛; 非凸时再用二阶充分条件 (在临界锥上 $d^T \nabla_x^2 L d > 0$) 确认是极小。

例 E1 (模拟题四) $\min f = x_1 x_2$ s.t. $c = x_1^2 + x_2^2 - 1 = 0$

$L = x_1 x_2 + \lambda(x_1^2 + x_2^2 - 1)$ 。平稳:

$$\begin{cases} x_2 + 2\lambda x_1 = 0 \\ x_1 + 2\lambda x_2 = 0 \end{cases} \Rightarrow x_1(1 - 4\lambda^2) = 0.$$

$$x_1 \neq 0 \Rightarrow \lambda = \pm \frac{1}{2}.$$

- $\lambda = \frac{1}{2}$: $x_2 = -x_1$, 代入约束 $2x_1^2 = 1 \Rightarrow x_1 = \pm \frac{1}{\sqrt{2}}$, 得 $(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}), (-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$, $f = -\frac{1}{2}$ 。
- $\lambda = -\frac{1}{2}$: $x_2 = x_1$, 得 $(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}), (-\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}})$, $f = +\frac{1}{2}$ 。

可行域是单位圆 (紧), f 连续 $\Rightarrow$ 最小值 $\boxed{f^* = -\frac{1}{2}}$, 在 $(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}})$ 或 $(-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$ 取得 (另两点是最大值 $+\frac{1}{2}$)。

例 E2 (往年 2022 第 4 题) 含不等式的 KKT / CQ / 二阶条件

$\min f = -2x_1 + x_2$ s.t. $g_1 = (1 - x_1)^3 - x_2 \geq 0$, $g_2 = x_2 + 0.25x_1^2 - 1 \geq 0$, 给定 $x^* = (0, 1)^T$ 。

在 x^* : $g_1 = 1 - 1 = 0$ (有效), $g_2 = 1 - 1 = 0$ (有效), 两约束都起作用。

梯度 $\nabla g_1 = (-3(1 - x_1)^2, -1)|_{x^*} = (-3, -1)$, $\nabla g_2 = (0.5x_1, 1)|_{x^*} = (0, 1)$ 。

(a) LICQ: $\det \begin{bmatrix} -3 & 0 \\ -1 & 1 \end{bmatrix} = -3 \neq 0 \Rightarrow$ 两梯度线性无关 $\Rightarrow$ LICQ 成立。

(b) KKT: 对 ≥ 0 约束, 平稳条件 $\nabla f = \mu_1 \nabla g_1 + \mu_2 \nabla g_2$, $\mu \geq 0$ 。 $\nabla f = (-2, 1)$:

$$\begin{cases} -2 = -3\mu_1 \\ 1 = -\mu_1 + \mu_2 \end{cases} \Rightarrow \mu_1 = \frac{2}{3}, \mu_2 = \frac{5}{3} (\geq 0).$$

互补松弛自动满足 (两约束有效) $\Rightarrow$ KKT 成立。

(c)(d) 二阶条件: 临界方向 d 满足 $\nabla g_1^T d = \nabla g_2^T d = 0$ (两 $\mu > 0$) $\Rightarrow$ 仅 $d = 0$ (梯度满秩) $\Rightarrow$ 临界锥平凡 $\Rightarrow$ 二阶必要与充分条件都平凡成立, x^* 是严格局部极小。

要点: $\mu_j > 0$ 的有效约束在二阶判别里贡献"等式方向" $\nabla g_j^T d = 0$; 只在 $\mu_j = 0$ 的退化有效约束上才放宽成 ≤ 0 。

题型 F · 写出对偶问题（含"对偶的对偶"）

知识点

对偶函数 $d(\lambda, \mu) = \inf_x L(x, \lambda, \mu)$ ，恒为凹（与原问题凸性无关）。对偶问题 $\max_{\mu \geq 0} d(\lambda, \mu)$ 。

弱对偶 $d^* \leq p^*$ 恒成立；强对偶 $d^* = p^*$ 需凸 + Slater（存在严格内部可行点）。

解题步骤（SOP）

1. 写 $L(x, \lambda, \mu)$ ；对 $\mu \geq 0$ 。
2. 对 x 求 $\inf$ ：令 $\nabla_x L = 0$ 解出 $x(\lambda, \mu)$ ，回代得显式 $d(\lambda, \mu)$ （凸二次型可得闭式；若 L 关于某 x 无下界，则该处 $d = -\infty$ ，转为对偶约束）。
3. 写对偶问题 $\max d$ s.t. $\mu \geq 0$ （及 $\inf$ 有限的条件）。
4. 对偶的对偶：对得到的对偶问题再走一遍 1~3，凸问题下应回到原问题（强对偶）。

例 F（个人总结） $\min x_1^2 + x_2^2$ s.t.

$$c_1 = -x_1 + x_2 + 2 \leq 0, c_2 = \frac{1}{2}x_1 + x_2 + 1 \leq 0$$

$$L = x_1^2 + x_2^2 + \mu_1(-x_1 + x_2 + 2) + \mu_2(\frac{1}{2}x_1 + x_2 + 1)。$$

$$\nabla_x L = 0: 2x_1 - \mu_1 + \frac{1}{2}\mu_2 = 0, 2x_2 + \mu_1 + \mu_2 = 0 \Rightarrow x_1 = \frac{\mu_1}{2} - \frac{\mu_2}{4}, x_2 = -\frac{\mu_1 + \mu_2}{2}。$$

回代：

$$d(\mu) = -\frac{1}{2}\mu_1^2 - \frac{1}{4}\mu_1\mu_2 - \frac{5}{16}\mu_2^2 + 2\mu_1 + \mu_2。$$

对偶问题： $\max d(\mu)$ s.t. $\mu_1 \geq 0, \mu_2 \geq 0$ 。（凹二次，无约束极大在 $\nabla d = 0$ ，再投影到 $\mu \geq 0$ 。）

题型 G · 线搜索：步长收敛性 / 精确步长 / 黄金分割

知识点

- 下降方向 d ： $\nabla f(x)^T d < 0$ 。特别地 $d = -\nabla f$ 、 $d = -H\nabla f$ ($H \succ 0$) 都是下降方向。
- 精确步长（二次型 $f = \frac{1}{2}x^T Ax + b^T x$ ）： $\alpha_k = -\frac{g_k^T d_k}{d_k^T A d_k}$ （最速下降时 $d = -g$ ，化简为 $\frac{g^T g}{g^T A g}$ ）。
- 非精确准则：Armijo $f(x + \alpha d) \leq f(x) + c_1 \alpha \nabla f^T d$ ；Wolfe 再加曲率 $\nabla f(x + \alpha d)^T d \geq c_2 \nabla f^T d$ ($0 < c_1 < c_2 < 1$)。

例 G1（模拟题三.1） $f = \frac{1}{2}x^2$ ，固定步长梯度下降，收敛范围 & 最快步长

$$g = x, x_{k+1} = x_k - \alpha x_k = (1 - \alpha)x_k \Rightarrow x_k = (1 - \alpha)^k x_0。$$

- 收敛 $\iff |1 - \alpha| < 1 \iff 0 < \alpha < 2$ 。
- 收敛因子 $|1 - \alpha|$ ， $\alpha = 1$ 时为 0，一步到 $x = 0$ ，最快 ($\alpha > 2$ 发散， $\alpha = 2$ 等幅震荡)。

推广： $f = \frac{1}{2}x^T Ax$ ，固定步长收敛 $\iff 0 < \alpha < \frac{2}{\lambda_{\max}(A)}$ ，最优 $\alpha^* = \frac{2}{\lambda_{\min} + \lambda_{\max}}$ ，线性收敛比 $\frac{\kappa - 1}{\kappa + 1}$ (κ 为条件数)。

例 G2 (个人总结) 黄金分割法求 $f(x) = x^4 - 14x^3 + 60x^2 - 70x$ 在 $[0, 2]$ 的极小点 (精度 0.3)

压缩率 $\rho = \frac{3-\sqrt{5}}{2} \approx 0.382$, 每次区间乘 0.618。需 $0.618^N \cdot 2 \leq 0.3 \Rightarrow N = 4$ 。

步骤 (每次保留较小函数值一侧):

1. $a_1 = a_0 + \rho(b_0 - a_0) = 0.764$, $b_1 = a_0 + (1 - \rho)(b_0 - a_0) = 1.236$;
 $f(a_1) = -24.36 < f(b_1) = -18.96 \Rightarrow$ 区间 $\rightarrow [0, 1.236]$ 。
2. 复用 a_1 为新 b_2 , 只需新算一个内点 $a_2 = 0.472$, 比较...
- 3~4. 同法每步固定刚变动端、只算一个新点, 4 步后区间长 ≤ 0.3 , 极小点 ≈ 0.78 。

要点: 黄金分割每次只新增一个函数求值 (复用上一步的内点), 这是它比二分更省的关键。

题型 H · 梯度类 / 最速下降法

知识点 & SOP (求二次型最小值)

$f = \frac{1}{2}x^T Ax + b^T x$ (先检查 A 对称, 不对称则用 $\frac{1}{2}(A + A^T)$ 代替)。

1. $g_k = Ax^k + b$; 若 $\|g_k\| \leq \varepsilon$ 停。
2. 方向 $d_k = -g_k$; 步长 $\alpha_k = \frac{g_k^T g_k}{g_k^T A g_k}$ 。
3. $x^{k+1} = x^k + \alpha_k d_k$, 回到 1。

收敛性: 全局收敛; 二次型上线性收敛, 条件数大 (病态) 则极慢, 相邻方向正交 $\Rightarrow$ 锯齿现象。

例 H (锯齿) $\min f = \frac{x_1^2}{2} + x_2^2, x^{(0)} = (2, 1)^T$

$\nabla f = (x_1, 2x_2)$, $g_0 = (2, 2)$, $d_0 = (-2, -2)$ 。一维搜索 $\phi(\alpha) = 2(1 - \alpha)^2 + (1 - 2\alpha)^2$,
 $\phi' = 0 \Rightarrow \alpha_0 = \frac{2}{3}$ 。

$x^{(1)} = (\frac{2}{3}, -\frac{1}{3})$, 一般 $x^{(k)} = (\frac{2}{3^k}, \frac{(-1)^k}{3^k}) \rightarrow 0$, 路径在谷底来回锯齿, 效率低。

题型 I · 牛顿类 (牛顿 / 修正牛顿 / 高斯-牛顿 / LM)

知识点

- 经典牛顿: 解 $\nabla^2 f(x^k)d = -\nabla f(x^k)$, 步长固定 1。正定二次型一步收敛, 一般 Q-二次收敛。
- 风险: ① 只有局部收敛 (初值要近); ② $\nabla^2 f$ 不正定时 d 未必下降, 可能收敛到极大/鞍点; ③ $\nabla^2 f$ 奇异则失败。
- 修正牛顿: 取 $B^k = \nabla^2 f + E^k \succ 0$ (如加 τI), 解 $B^k d = -g$, 再用线搜索定步长 (阻尼)。
- 最小二乘 $f = \frac{1}{2}\|r(x)\|^2$: 高斯-牛顿 $J^T J d = -J^T r$ (省去二阶项); $J^T J$ 奇异时用 LM ($(J^T J + \nu I)d = -J^T r$ 保正定)。

例 I (牛顿二次型一步收敛) $\min f = x_1^2 + x_2^2 + x_1x_2 + 2x_1 - 3x_2$, $x^{(0)} = 0$

$\nabla f(0) = (2, -3)$, $\nabla^2 f = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ 。解 $\nabla^2 f d = -\nabla f$ 得 $d = (-\frac{7}{3}, \frac{8}{3})$, $x^{(1)} = (-\frac{7}{3}, \frac{8}{3})$, $\nabla f(x^{(1)}) = 0 \Rightarrow$ 一步到最优。

题型 J · 共轭梯度法

知识点

共轭 = A 度量下正交: $d_i^T A d_j = 0$ ($i \neq j$)。沿一组 A -共轭方向, n 维正定二次型至多 n 步收敛 (二次终止性), 且不需 Hessian、不求逆。

两种用法:

- **基本共轭方向法**: 已知一组共轭方向, 逐步 $\alpha_k = -\frac{g_k^T d_k}{d_k^T A d_k}$, $x^{k+1} = x^k + \alpha_k d_k$ 。
- **共轭梯度 (FR)**: 不预先给方向, 边走边生成 $d_{k+1} = -g_{k+1} + \beta_k d_k$, $\beta_k = \frac{g_{k+1}^T g_{k+1}}{g_k^T g_k}$ (二次型也可用 $\beta_k = \frac{g_{k+1}^T A d_k}{d_k^T A d_k}$)。
- **构造共轭方向**: 对线性无关组 $\{p_i\}$ 用 **Gram-Schmidt** (A 内积):
 $d_0 = p_0$, $d_{k+1} = p_{k+1} - \sum_{i=0}^k \frac{p_{k+1}^T A d_i}{d_i^T A d_i} d_i$ 。
- **非二次型**: 把公式里出现 A (Hessian) 的地方换成实际梯度差/线搜索; 每 n 步重启为 $-g$ 。

解题步骤 (CG 求 $f = \frac{1}{2} x^T A x + b^T x$)

1. $g_0 = Ax^0 + b$, $d_0 = -g_0$ 。
2. $\alpha_k = -\frac{g_k^T d_k}{d_k^T A d_k}$, $x^{k+1} = x^k + \alpha_k d_k$ 。
3. $g_{k+1} = Ax^{k+1} + b$; 若 $= 0$ 停。
4. $\beta_k = \frac{g_{k+1}^T g_{k+1}}{g_k^T g_k}$, $d_{k+1} = -g_{k+1} + \beta_k d_k$, 回 2。

例 J (个人总结) 基本共轭方向法 $f = \frac{1}{2} x^T \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix} x + x^T \begin{bmatrix} 1 \\ -1 \end{bmatrix}$,
 $x^0 = 0$, 给定 $d_0 = (1, 0)^T$, $d_1 = (-\frac{3}{8}, \frac{3}{4})^T$

$g_0 = Sx^0 + b = (1, -1)$ 。 $\alpha_0 = -\frac{g_0^T d_0}{d_0^T S d_0} = -\frac{1}{4} = -\frac{1}{4}$, $x^1 = (-\frac{1}{4}, 0)$ 。

$g_1 = Sx^1 + b = (0, -\frac{3}{2})$ 。 $\alpha_1 = -\frac{g_1^T d_1}{d_1^T S d_1} = 2$, $x^2 = (-1, \frac{3}{2})$, $g_2 = 0 \Rightarrow$ **2 步收敛** (二维正定二次型)。

题型 K · 拟牛顿法 (BFGS / DFP)

知识点

用对称正定 H_k 近似 $[\nabla^2 f]^{-1}$ ，方向 $d_k = -H_k g_k$ 。核心是割线方程 $H_{k+1} y_k = s_k$ ($s_k = x^{k+1} - x^k, y_k = g_{k+1} - g_k$)。满足割线方程的修正阵不唯一 $\Rightarrow$ DFP/BFGS 是不同取法。

- **BFGS** (H 形式, 工业默认): $H_{k+1} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T, \rho_k = \frac{1}{y_k^T s_k}$ 。
- **DFP**: $H_{k+1} = H_k - \frac{H_k y_k y_k^T H_k}{y_k^T H_k y_k} + \frac{s_k s_k^T}{s_k^T y_k}$ 。
- **保正定关键**: 曲率条件 $s_k^T y_k > 0$ (Wolfe 线搜索可保证)。
- **二次终止**: n 维正定二次型 + $H_0 = I$, BFGS 至多 n 步收敛且 $H_n = A^{-1}$ 。
- **步长**: 二次型用精确公式 $\alpha_k = -\frac{g_k^T d_k}{d_k^T A d_k}$; 非二次型用线搜索。

解题步骤 (SOP)

1. $g_k = \nabla f(x^k)$; 若 $\|g_k\| \leq \varepsilon$ 停。
2. $d_k = -H_k g_k$ 。
3. 步长 α_k (二次型用公式, 否则线搜索), $x^{k+1} = x^k + \alpha_k d_k$ 。
4. $s_k = x^{k+1} - x^k, y_k = g_{k+1} - g_k, \rho_k = \frac{1}{y_k^T s_k}$ 。
5. 按 BFGS/DFP 更新 H_{k+1} , 回 1。

例 K (模拟题三.2) BFGS 求 $f = \frac{1}{2} x^T Q x - x^T b + 10$,
 $Q = \begin{bmatrix} 5 & -3 \\ -3 & 2 \end{bmatrix}, b = (0, 1)^T, H_0 = I, x^0 = 0$

$\nabla f = Qx - b$ 。

第 1 步: $g_0 = -b = (0, -1), d_0 = -g_0 = (0, 1)$ 。
 $\alpha_0 = -\frac{g_0^T d_0}{d_0^T Q d_0} = -\frac{-1}{2} = \frac{1}{2}, x^1 = (0, \frac{1}{2})$ 。
 $g_1 = Qx^1 - b = (-\frac{3}{2}, 1) - (0, 1) = (-\frac{3}{2}, 0)$ 。
 $s_0 = (0, \frac{1}{2}), y_0 = (-\frac{3}{2}, 1), y_0^T s_0 = \frac{1}{2}, \rho_0 = 2$ 。
 $H_1 = (I - \rho_0 s_0 y_0^T)(I - \rho_0 y_0 s_0^T) + \rho_0 s_0 s_0^T = \begin{bmatrix} 1 & \frac{3}{2} \\ \frac{3}{2} & \frac{11}{4} \end{bmatrix}$ 。

第 2 步: $d_1 = -H_1 g_1 = (\frac{3}{2}, \frac{9}{4})$ 。
 $\alpha_1 = -\frac{g_1^T d_1}{d_1^T Q d_1} = -\frac{-9/4}{9/8} = 2, x^2 = (0, \frac{1}{2}) + 2(\frac{3}{2}, \frac{9}{4}) = (3, 5)$ 。
 $g_2 = Qx^2 - b = (0, 0) \Rightarrow$ 停, $x^* = (3, 5)$ 。

验证: $H_2 = \begin{bmatrix} 2 & 3 \\ 3 & 5 \end{bmatrix} = Q^{-1}$ ($\det Q = 1$)。2 步收敛且 $H_n = Q^{-1}$, 符合二次终止性。

DFP 对照: 同题用 DFP 更新公式也 2 步收敛到 $(3, 5)$, 但 DFP 对病态二次型实测步数远多于 BFGS (Powell 1986), 故工业默认 BFGS / L-BFGS。

题型 L · 罚函数法 与 增广拉格朗日法 (ALM)

知识点

方法	形式	适用	罚因子	路径
二次外罚	$f + \sigma [\sum_E c_i^2 + \sum_I \max(0, c_j)^2]$	等式+不等式	$\sigma \rightarrow \infty$ (病态)	从可行域外逼近, 初值任意
对数内罚 (障碍)	$f - \sigma \sum_I \ln(-c_j)$	仅不等式	$\sigma \rightarrow 0^+$	从内部逼近, 初值须严格可行
ℓ_1 精确罚	$f + \sigma \sum c_i $	通用	$\sigma > \ \lambda^*\ _\infty$ 有限	非光滑 (精确罚必非光滑)
ALM	$f + \sum \lambda_i c_i + \frac{\sigma}{2} \sum c_i^2$	通用	有限 σ 即可	靠乘子逼近降违反度

ALM 的优势: 二次罚要 $\sigma \rightarrow \infty$ 才精确 (病态); ALM 靠乘子更新 $\lambda^{k+1} = \lambda^k + \sigma_k c(x^{k+1})$ 逼近 λ^* , 有限 σ 就能让违反度 $c \rightarrow 0$ 。

解题步骤 (等式约束 ALM)

- 1. 写 $L_\sigma(x, \lambda) = f + \sum \lambda_i c_i + \frac{\sigma}{2} \sum c_i^2$ 。
- 2. 固定 λ^k, σ_k , $\min_x L_\sigma$ (令 $\nabla_x L_\sigma = 0$ 解出 $x^{k+1}(\lambda^k)$)。
- 3. 更新乘子 $\lambda^{k+1} = \lambda^k + \sigma_k c(x^{k+1})$ (必要时 σ 放大)。
- 4. $\|c(x^{k+1})\| \leq \varepsilon$ 停。
不等式约束: 引松弛/投影, 乘子更新 $\mu^{k+1} = \max\{\mu^k + \sigma_k c(x^{k+1}), 0\}$ (max 自动保 $\mu \geq 0$)。

例 L1 (模拟题五) $f = x^2 + y^2$ s.t. $c = x + y - 2 = 0$

- (1) $L_\sigma = x^2 + y^2 + \lambda(x + y - 2) + \frac{\sigma}{2}(x + y - 2)^2$ 。
- (2) $\sigma = 1$: $\nabla_x L = 0$ 由对称性 $x = y$, $2x + \lambda + (2x - 2) = 0 \Rightarrow x = y = \frac{2-\lambda}{4}$ 。
- (3) $c = x + y - 2 = \frac{2-\lambda}{2} - 2 = \frac{-2-\lambda}{2}$, 递推 $\lambda^{k+1} = \lambda^k + c = \lambda^k + \frac{-2-\lambda^k}{2} = \frac{\lambda^k}{2} - 1$ 。
- (4) $\lambda^0 = 0$: $0 \rightarrow -1 \rightarrow -\frac{3}{2} \rightarrow \dots$, 不动点 $\lambda^* = \frac{\lambda^*}{2} - 1 \Rightarrow \lambda^* = -2$ 。
- (5) $x = y = \frac{2-\lambda^*}{4} = \frac{2-(-2)}{4} = 1 \Rightarrow$ 解 $(1, 1)$, $f = 2$ (正是 $x^2 + y^2$ 在 $x + y = 2$ 上的真最小, $c = 0$ 严格满足)。

例 L2 (个人总结) 不等式约束 ALM 的松弛消元

$\min f(x)$ s.t. $c_i(x) \leq 0$: 松弛化 $c_i(x) + s_i = 0, s_i \geq 0$ 。固定 x 解关于 $s_i \geq 0$ 的二次子问题得闭式 $s_i = \max\left\{-\frac{\mu_i}{\sigma_k} - c_i(x), 0\right\}$,
回代得只含 x 的可微函数 (用梯度法解), 乘子更新 $\mu_i^{k+1} = \max\{\mu_i^k + \sigma_k c_i(x^{k+1}), 0\}$ 。

例 L3（个人总结）内罚（障碍）法 $\min x_1^2 + 2x_2^2 \text{ s.t. } x_1 + x_2 - 1 \geq 0$

$P(x, r) = x_1^2 + 2x_2^2 - r \ln(x_1 + x_2 - 1)$ 。 $\nabla P = 0$: $2x_1 - \frac{r}{x_1+x_2-1} = 0$, $4x_2 - \frac{r}{x_1+x_2-1} = 0$, 解出 $x(r)$, $r \rightarrow 0^+$ 时 $x \rightarrow (\frac{2}{3}, \frac{1}{3})$ (从可行域内部逼近边界真解)。

算法特性总结表（必背，常出简答/判断）

算法	方向	是否需 Hessian	二次终止性	收敛速度	关键风险/条件
最速下降	$-g$	否	无	二次型线性（病态极慢，锯齿）	步长须 $0 < \alpha < \frac{2}{\lambda_{\max}}$ 才收敛
牛顿法	$-(\nabla^2 f)^{-1}g$	是（含求逆）	正定二次型一步	Q-二次（局部）	初值要近；Hessian 须正定、非奇异
修正牛顿	$-(B)^{-1}g, B \succ 0$	是	—	局部超线性~二次	加 E^k 保正定 + 线搜索
共轭梯度	共轭方向	否	$\leq n$ 步	线性二次型有限步；非线性超线性	每 n 步重启
拟牛顿 BFGS	$-H_k g$	否（近似逆）	$\leq n$ 步（二次型, $H_n = A^{-1}$ ）	Q-超线性	曲率 $s^T y > 0$ (Wolfe)
外罚函数	—	—	—	聚点为全局最优	病态 ($\sigma \rightarrow \infty$)，可处理等式+不等式
内罚函数	—	—	—	聚点为全局最优	仅不等式，初值须可行, $\sigma \rightarrow 0$
ALM	—	—	—	$\limsup \sigma < \infty \Rightarrow$ Q-线性； $\sigma \rightarrow \infty \Rightarrow$ 超线性	有限罚因子即可（优于二次罚）

易错点清单（考前扫一遍）

- 1. 对偶函数恒凹，与原问题凸性无关；弱对偶 $d^* \leq p^*$ 恒成立；强对偶需凸+Slater。
- 2. 凸性判定看整个定义域：Hessian 变号 $\Rightarrow$ 既非凸也非凹（如 sigmoid）。
- 3. 驻点分类：半定时二阶判别失效，要做邻域/高阶分析；能配方就配方读全局。
- 4. 二次型先对称化： $f = \frac{1}{2}x^T A x$ 中 A 不对称要换成 $\frac{1}{2}(A + A^T)$ ，步长公式才对。
- 5. KKT 需约束品性 (LICQ/LFCQ)；CQ 不成立时局部极小未必是 KKT 点。凸问题 KKT 即全局充分。
- 6. 二阶充分条件在临界锥上判别： $\mu_j > 0$ 的有效约束给等式方向 $\nabla g_j^T d = 0$ 。
- 7. 固定步长梯度法： $0 < \alpha < \frac{2}{\lambda_{\max}}$ 才收敛； $\alpha = \frac{2}{\lambda_{\min} + \lambda_{\max}}$ 最优。
- 8. 牛顿法非全局：可能收敛到极大/鞍点、Hessian 奇异即失败，须阻尼+修正。
- 9. BFGS 保正定靠 $s^T y > 0$ (Wolfe)；DFP 与 BFGS 对偶但实测更差。
- 10. 共轭 = A -正交，消锯齿； n 步终止与拟牛顿同源。

11. **精确罚必非光滑**（光滑会推出 $\nabla f(x^*) = 0$ ，与约束最优矛盾）。
 12. **二次罚 $\sigma \rightarrow \infty$ （病态）；精确罚/ALM 用有限罚因子——ALM 核心优势。**
 13. **内点(对数罚) vs 外点(二次罚)：**内点从内部、初值须可行、 $\sigma \rightarrow 0$ 、仅不等式；外点从外部、初值任意、 $\sigma \rightarrow \infty$ 、通用。
-

完整逐题演算与图示见 [课件例题全集.md](#)、[详细笔记/](#)；本文件聚焦**期末高频题型 + 可套用步骤**。