

最优化理论与方法·课件例题全集

本文件系统收录全部课件（1-1 ~ 1-7、2-1 ~ 2-4、共轭梯度法、极值应用案例、15、16）中的**例题**，按章节组织。

每道例题给出：**题目** → **完整解答** → **涉及方法/知识点**（并链接到 [详细笔记/](#) 对应章节深入理解）。

配套材料：

- 逐章精讲：[详细笔记/](#)
- 模拟题解答：[模拟题 解答与知识点.md](#)
- 考试速查：[考试速查 6页A4.md](#)

编排说明：🔴=题目，✅=解答，🔗=知识点链接。带★的为考试高频题型。

目录

- [第1章 凸集](#)
- [第2章 凸函数](#)
- [第3章 凸优化问题](#)
- [第4章 无约束可微优化的最优性条件](#)
- [第5章 对偶理论](#)
- [第6章 KKT 条件与约束优化](#)
- [第7章 线搜索方法](#)
- [第8章 梯度类算法](#)
- [第9章 牛顿类算法](#)
- [第10章 拟牛顿类算法](#)
- [第11章 共轭梯度法](#)
- [第12章 罚函数法与增广拉格朗日法](#)
- [附：综合应用案例](#)

第1章 凸集

配套精讲：[详细笔记/01 凸集.md](#)

例 1.1 判断集合是否为凸集（图示直观）★

🔴 **题目** 判断下列平面集合是否为凸集：

(a) 实心圆盘；(b) 圆环；(c) 两个分离的圆盘的并；(d) 多边形（实心）。

✅ **解答**

- 凸集判据：集合 C 中任取两点 x, y ，连线段 $[x, y] = \{\lambda x + (1 - \lambda)y : \lambda \in [0, 1]\}$ 完全落在 C 内。
- (a) 实心圆盘 ✅ 凸：任意两点连线都在盘内。

- (b) 圆环 ✗ 非凸：取内孔两侧两点，连线穿过空心区。
- (c) 两分离圆盘之并 ✗ 非凸：取两盘各一点，连线中段在两盘之外。
- (d) 实心多边形 ✓ 凸（凸多边形时）：边界为有限个半平面之交。

🔗 **知识点** 凸集定义、线段判据。是否为凸集"看连线是否出界"。

例 1.2 闭范数球是凸集（用定义证明）★

🔴 **题目** 证明闭范数球 $B = \{x \in \mathbb{R}^n : \|x - x_c\| \leq r\}$ 是凸集（ $\|\cdot\|$ 为任意范数）。

✅ **解答** 任取 $x_1, x_2 \in B$, $\lambda \in [0, 1]$, 记 $z = \lambda x_1 + (1 - \lambda)x_2$ 。则

$$\|z - x_c\| = \|\lambda(x_1 - x_c) + (1 - \lambda)(x_2 - x_c)\|$$

由范数的三角不等式与齐次性：

$$\leq \lambda\|x_1 - x_c\| + (1 - \lambda)\|x_2 - x_c\| \leq \lambda r + (1 - \lambda)r = r.$$

故 $z \in B$, B 是凸集。■

🔗 **知识点** 用定义证凸集的标准三步（取两点→作凸组合→用三角不等式放缩）。范数的凸性是后续大量证明的基石。

例 1.3 凸包 (convex hull)

🔴 **题目** (a) 求有限点集 $S_1 = \{(\frac{3}{2}, 2), (3, 1)\}$ 的凸包；(b) 直观描述平面上一组离散点的凸包。

✅ **解答**

- (a) 两点的凸包就是连接它们的**线段** $\{\lambda(\frac{3}{2}, 2) + (1 - \lambda)(3, 1) : \lambda \in [0, 1]\}$ 。
- (b) 有限点集的凸包是"用橡皮筋套住所有点"形成的**凸多边形**（含内部）。
- 一般定义： $\text{conv}(S) = \{\sum_i \lambda_i x_i : x_i \in S, \lambda_i \geq 0, \sum_i \lambda_i = 1\}$, 即 S 中点的所有**凸组合**。

🔗 **知识点** 凸组合、凸包；Carathéodory 定理（ $\mathbb{R}^n$ 中凸包内任一点可表为至多 $n + 1$ 个点的凸组合）。

例 1.4 凸锥的判定★

🔴 **题目** 判断下列集合是否为凸锥：

- (1) $C_2 = \{(x, y) : y \geq 0\}$ （上半平面）；
- (2) 齐次线性方程组解集 $\{x : Ax = 0\}$ ；
- (3) $\mathbb{R}^2$ 中由两条射线张成的扇形区域。

✅ **解答** 凸锥判据：对任意 $x_1, x_2 \in C$ 与 $\theta_1, \theta_2 \geq 0$, 有 $\theta_1 x_1 + \theta_2 x_2 \in C$ （即对非负组合封闭）。

- (1) ✓： $y_1, y_2 \geq 0, \theta_1, \theta_2 \geq 0 \Rightarrow \theta_1 y_1 + \theta_2 y_2 \geq 0$ 。
- (2) ✓： $Ax_1 = 0, Ax_2 = 0 \Rightarrow A(\theta_1 x_1 + \theta_2 x_2) = 0$ 。子空间一定是凸锥。
- (3) ✓：两射线非负组合落在扇形内（前提是夹角 $\leq 180^\circ$ ）。

🔗 **知识点** 锥、凸锥、非负组合封闭性；子空间/半空间都是凸锥。

例 1.5 仿射集/凸集/凸锥的"包"对比

🔴 **题目** 对点集 $S_1 = \{(\frac{3}{2}, 2), (3, 1)\}$, 分别描述其**凸包** conv、**凸锥包** cone、**仿射包** aff。

✅ **解答**

- **凸包** (系数 ≥ 0 且和为 1) : 连接两点的**线段**。
- **凸锥包** (系数 ≥ 0 , 无和约束) : 由原点出发、过这两点的两条射线所夹的**扇形 (含边界)**。
- **仿射包** (系数和为 1, 可负) : 过两点的**整条直线**。

🔗 **知识点** 三种"包"的层级关系: $\text{conv} \subseteq \text{cone}$ 、 $\text{conv} \subseteq \text{aff}$ 。系数约束的差别 (和为1+非负 / 仅非负 / 仅和为1)。

例 1.6 超平面分离两凸集★

🔴 **题目** 设 C_1, C_2 是两个不相交的非空凸集, 说明存在超平面将其分离; 并举一例说明"不相交"不足以保证**严格**分离。

✅ **解答**

- **分离定理**: 若 $C_1 \cap C_2 = \emptyset$ 且都凸, 则存在 $a \neq 0, b$ 使

$$a^T x \leq b \quad (\forall x \in C_1), \quad a^T x \geq b \quad (\forall x \in C_2).$$

- **不能严格分离的反例**: $C_1 = \{(x, y) : y \leq 0\}$, $C_2 = \{(x, y) : y > 0, xy \geq 1\}$ (或取 $C_1 = \{(x, 0)\}$ 轴、 $C_2 = \{(x, y) : y \geq e^x\}$ 之类两集合"无限靠近但不相交")。它们被直线 $y = 0$ 分离, 但任何平行平移都会切入某一集合, 故不能**严格**分离 (间隙趋于 0)。

🔗 **知识点** 分离超平面定理、支撑超平面定理; 严格分离需要额外条件 (如其中一个为闭集、另一个为紧集)。这是对偶理论的几何根基。

例 1.7 支撑超平面

🔴 **题目** 对凸集 C 边界上一点 x_0 , 说明支撑超平面的含义。

✅ **解答** 存在 $a \neq 0$ 使 $a^T x \leq a^T x_0$ 对所有 $x \in C$ 成立, 即超平面 $\{x : a^T x = a^T x_0\}$ 过 x_0 且整个 C 落在它一侧。直观: 在边界点"贴"一块平板, 把凸集顶住。

🔗 **知识点** 支撑超平面定理 (任意凸集边界点都存在支撑超平面); 与凸集的"局部即全局"性质呼应。

第 2 章 凸函数

配套精讲: [详细笔记/02 凸函数.md](#)

例 2.1 示性函数 (广义实值函数)

🔴 题目 写出集合 $S \subseteq \mathbb{R}^n$ 的示性函数 δ_S 及其有效定义域。

✅ 解答

$$\delta_S(x) = \begin{cases} 0, & x \in S \\ +\infty, & x \notin S \end{cases}, \quad \text{dom } \delta_S = \{x : \delta_S(x) < +\infty\} = S.$$

当 S 为凸集时 δ_S 是凸函数。它把“约束 $x \in S$ ”编码进目标函数，是凸分析中连接集合与函数的桥梁。

🔗 知识点 广义实值函数、适当函数、有效定义域 $\text{dom } f = \{x : f(x) < +\infty\}$ 、上方图 $\text{epi } f$ 。

例 2.2 一元/多元凸 (凹) 函数清单

🔴 题目 列举常见一元、多元凸函数与凹函数。

✅ 解答

- **一元凸**: 仿射 $ax + b$; 指数 e^{ax} ; 幂 x^α ($\alpha \geq 1$ 或 $\alpha \leq 0, x > 0$); $|x|^p$ ($p \geq 1$); 负熵 $x \log x$ ($x > 0$)。
- **一元凹**: 仿射 $ax + b$; 幂 x^α ($0 \leq \alpha \leq 1, x > 0$); 对数 $\log x$ ($x > 0$)。
- **多元凸**: 仿射 $a^T x + b$; 任意范数 $\|x\|_p$; 二次型 $x^T A x$ ($A \succeq 0$); 最小二乘 $\|Ax - b\|_2^2$; quadratic-over-linear x^2/y ($y > 0$); $\log\text{-sum-exp } \log \sum_k e^{x_k}$; $-\log \det X$ ($X \succ 0$)。

🔗 知识点 常见函数凸性“背诵表”——考试判定题先查表，再用一/二阶条件验证。

例 2.3 仿射函数既凸又凹 (用定义证)

🔴 题目 证明 $f(x) = a^T x + b$ 既是凸函数又是凹函数。

✅ 解答 对任意 $x, y, \lambda \in [0, 1]$:

$$f(\lambda x + (1 - \lambda)y) = a^T(\lambda x + (1 - \lambda)y) + b = \lambda(a^T x + b) + (1 - \lambda)(a^T y + b) = \lambda f(x) + (1 - \lambda)f(y).$$

等号恒成立，故凸、凹定义同时满足。■ (仿射函数是唯一既凸又凹的函数类。)

🔗 知识点 凸函数定义；仿射函数的特殊地位。

例 2.4 向量范数是凸函数 (用定义证) ★

🔴 题目 证明任意向量范数 $f(x) = \|x\|$ 是凸函数。

✅ 解答 对任意 $x, y, \lambda \in [0, 1]$ ，由三角不等式与齐次性：

$$\|\lambda x + (1 - \lambda)y\| \leq \|\lambda x\| + \|(1 - \lambda)y\| = \lambda\|x\| + (1 - \lambda)\|y\|.$$

即 $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$ 。■

🔗 知识点 范数凸性；与 [例 1.2](#) 同源 (范数凸 $\Leftrightarrow$ 范数球凸)。

例 2.5 限制在直线上判定凸性： $-\log \det X$

🔴 题目 证明 $f(X) = -\log \det X$ 在 $X \succ 0$ 上是凸函数。

✅ 解答 方法：把多元函数限制在任意直线上，化为一元问题。取 $X \succ 0$ 、方向 V ，令 $g(t) = f(X + tV)$ (t 使 $X + tV \succ 0$)：

$$g(t) = -\log \det(X + tV) = -\log \det X - \sum_{i=1}^n \log(1 + t\lambda_i),$$

其中 λ_i 是 $X^{-1/2}VX^{-1/2}$ 的特征值。每个 $-\log(1 + t\lambda_i)$ 关于 t 是凸的，故 g 凸；对任意直线都凸 $\Rightarrow f$ 凸。■

🔗 知识点 判定定理： f 凸 $\Leftrightarrow$ 对每个 x, v ， $g(t) = f(x + tv)$ 关于 t 凸。高维降到一维的通用技巧。

例 2.6 凸函数不一定可导

🔴 题目 举例说明凸函数未必可导。

✅ 解答 $f(x) = |x|$ 是凸函数（例 2.4 的特例），但在 $x = 0$ 处不可导（左右导数 $-1 \neq 1$ ）。这引出次梯度概念：在 $x = 0$ 处次梯度集合为 $[-1, 1]$ 。

🔗 知识点 凸函数的连续性好，但光滑性不保证；不可导点用次梯度刻画。

例 2.7 严格凸 $\neq$ 二阶导处处为正

🔴 题目 说明“严格凸”不能推出“Hessian 处处正定”。

✅ 解答 $f(x) = x^4$ 严格凸，但 $f''(x) = 12x^2$ 在 $x = 0$ 处 $f''(0) = 0$ （只是半正定）。结论：二阶可微严格凸 $\Rightarrow \nabla^2 f \succeq 0$ （半正定），但不能加强为处处正定。

🔗 知识点 二阶条件的方向性： $\nabla^2 f \succ 0 \Rightarrow$ 严格凸（充分非必要）；严格凸 $\Rightarrow \nabla^2 f \succeq 0$ 。

例 2.8 二次函数严格凸 $\Leftrightarrow Q$ 正定★

🔴 题目 设 Q 对称， $f(x) = \frac{1}{2}x^T Qx + c^T x$ 。证明 f 在 $\mathbb{R}^n$ 上严格凸当且仅当 $Q \succ 0$ 。

✅ 解答

- 充分性： $Q \succ 0 \Rightarrow \nabla^2 f = Q \succ 0 \Rightarrow f$ 严格凸（二阶条件）。
- 必要性（反证）：若 f 严格凸但 Q 仅半正定不正定，则 Q 有零特征值，存在 $x \neq 0$ 使 $Qx = 0$ 。取 $y = -x$ ， $z = \frac{1}{2}x + \frac{1}{2}y = 0$ ，则 $\frac{1}{2}f(x) + \frac{1}{2}f(y)$ 经计算等于 $f(0) = f(z)$ ，与严格凸性 $f(z) < \frac{1}{2}f(x) + \frac{1}{2}f(y)$ 矛盾。■

🔗 知识点 二次函数凸性 $\Leftrightarrow Q \succeq 0$ ；严格凸 $\Leftrightarrow Q \succ 0$ 。与例 2.9 配合是考试核心。

例 2.9 判断凸/凹/都不是 (Hessian + 顺序主子式) ★★

🔴 题目 判断下列函数是凸、凹、还是都不是：

(1) $f: \mathbb{R} \rightarrow \mathbb{R}, f(x) = -8x^2$;

(2) $f: \mathbb{R}^3 \rightarrow \mathbb{R}, f(x) = 4x_1^2 + 3x_2^2 + 5x_3^2 + 6x_1x_2 + x_1x_3 - 3x_1 - 2x_2 + 15$;

(3) $f: \mathbb{R}^2 \rightarrow \mathbb{R}, f(x) = 2x_1x_2 - x_1^2 - x_2^2$.

✅ 解答 方法：算 Hessian，再用顺序主子式判定定号性。

• (1) $f''(x) = -16 < 0$ 恒成立 $\Rightarrow$ Hessian 负定 $\Rightarrow$ 凹函数。

• (2) Hessian

$$F = \begin{pmatrix} 8 & 6 & 1 \\ 6 & 6 & 0 \\ 1 & 0 & 10 \end{pmatrix}, \quad \Delta_1 = 8 > 0, \quad \Delta_2 = \det \begin{pmatrix} 8 & 6 \\ 6 & 6 \end{pmatrix} = 12 > 0, \quad \Delta_3 = \det F = 114 > 0.$$

各阶顺序主子式全正 $\Rightarrow F \succ 0$ (正定) $\Rightarrow$ 凸函数。

• (3) Hessian

$$F = \begin{pmatrix} -2 & 2 \\ 2 & -2 \end{pmatrix},$$

特征值 0, -4, 半负定 $\Rightarrow$ 凹函数 (非严格)。

🔍 知识点 这是判定题的标准模板：① 写出 Hessian (二次型系数： $\partial^2/\partial x_i^2$ 取对角、交叉项系数除以 2 取非对角) ② 顺序主子式判定正 (全正 $\rightarrow$ 正定 $\rightarrow$ 凸) ③ 判负定看 $(-1)^k \Delta_k > 0$ (交错 $\rightarrow$ 负定 $\rightarrow$ 凹)。详见 [详细笔记/02 凸函数.md](#)。

易错：交叉项 $6x_1x_2$ 对应 Hessian 中 $F_{12} = F_{21} = 6$ (不是 12)，因为 $\partial^2(6x_1x_2)/\partial x_1\partial x_2 = 6$ 。 $4x_1^2$ 对应 $F_{11} = 8$ (二阶导)。

例 2.10 最小二乘与 quadratic-over-linear 的凸性

🔴 题目 证明 (1) $f(x) = \|Ax - b\|_2^2$ 对任意 A 都凸; (2) $f(x, y) = x^2/y$ 在 $\{y > 0\}$ 上凸。

✅ 解答

• (1) $\nabla f = 2A^T(Ax - b), \nabla^2 f = 2A^T A \succeq 0$ ($A^T A$ 恒半正定) $\Rightarrow$ 凸。

• (2) $\nabla^2 f(x, y) = \frac{2}{y^3} \begin{pmatrix} y \\ -x \end{pmatrix} \begin{pmatrix} y \\ -x \end{pmatrix}^T \succeq 0$ (外积矩阵半正定, $y > 0$) $\Rightarrow$ 在 $y > 0$ 上凸。

🔍 知识点 $A^T A \succeq 0$ 是最小二乘问题凸性的来源 (关联 [第4章](#) 正规方程)。

例 2.11 log-sum-exp 是凸函数 (柯西不等式)

🔴 题目 证明 $f(x) = \log \sum_{k=1}^n e^{x_k}$ 是凸函数。

✅ 解答 记 $z_k = e^{x_k}$ 。Hessian

$$\nabla^2 f = \frac{1}{\mathbf{1}^T z} \text{diag}(z) - \frac{1}{(\mathbf{1}^T z)^2} z z^T.$$

对任意 v :

$$v^T \nabla^2 f v = \frac{(\sum_k z_k v_k^2)(\sum_k z_k) - (\sum_k v_k z_k)^2}{(\sum_k z_k)^2} \geq 0,$$

分子非负由柯西不等式 (取 $x_i = \sqrt{z_i} v_i$, $y_i = \sqrt{z_i}$, 则 $(\sum v_k z_k)^2 = (x^T y)^2 \leq \|x\|^2 \|y\|^2 = (\sum z_k v_k^2)(\sum z_k)$)。故 $\nabla^2 f \succeq 0$, f 凸。■

🔑 知识点 $\log$ -sum-exp 是 $\max$ 的光滑近似; softmax、交叉熵的凸性根基。

例 2.12 保凸运算综合★

🔴 题目 利用保凸运算说明下列函数是凸函数:

- (1) 对数障碍 $f(x) = -\sum_{i=1}^m \log(b_i - a_i^T x)$;
- (2) 分段线性 $f(x) = \max_i(a_i^T x + b_i)$;
- (3) x 的前 r 个最大分量之和 $f(x) = x_{[1]} + \dots + x_{[r]}$;
- (4) 点到凸集 S 的距离 $\text{dist}(x, S) = \inf_{y \in S} \|x - y\|$;
- (5) 对称矩阵最大特征值 $\lambda_{\max}(X)$;
- (6) $f(x) = (\max\{0, \|x\|^2 - 1\})^2$ 。

✅ 解答

- (1) 每个 $-\log(b_i - a_i^T x)$ 是凸函数 (凹的对数取负) 与仿射复合, 非负加权和仍凸。
- (2) 有限个仿射 (凸) 函数的逐点最大仍凸。
- (3) 可写成 $f(x) = \max\{x_{i_1} + \dots + x_{i_r} : 1 \leq i_1 < \dots < i_r \leq n\}$, 即多个线性函数取 $\max$, 凸。
- (4) $\|x - y\|$ 关于 (x, y) 联合凸, 对 $y \in S$ (凸集) 取 $\inf$ 后关于 x 凸。
- (5) $\lambda_{\max}(X) = \sup_{\|y\|_2=1} y^T X y$, 每个 $y^T X y$ 关于 X 线性 (凸), 逐点取 $\sup$ 仍凸。
- (6) $h(t) = t^2$ 在 $t \geq 0$ 不减且凸, $g(x) = \max\{0, \|x\|^2 - 1\}$ 非负且凸, 复合 $h \circ g$ 凸。
(对比反例: $f(x) = (\|x\|^2 - 1)^2$ 不凸, 因为 $h(t) = t^2$ 对 $t < 0$ 递减, 复合条件被破坏。)

🔑 知识点 保凸运算清单: ① 非负加权和 ② 与仿射复合 $f(Ax + b)$ ③ 逐点 $\max/\sup$ ④ 对凸集变量取 $\inf$ ⑤ 与单调函数复合 (需注意单调方向) ⑥ 透视函数。判定凸性时优先"拆成已知凸函数 + 保凸运算", 比直接算 Hessian 快。

例 2.13 凸/严格凸/强凸的层级分类★

🔴 题目 判断下列一元函数属于: 凸 / 严格凸 / 强凸 的哪些类。

✅ 解答

函数	凸	严格凸	强凸	说明
x^3	✗	✗	✗	$f'' = 6x$ 变号, 非凸
x	✓	✗	✗	仿射, $f'' = 0$
$ x $	✓	✗	✗	含直线段
x^4	✓	✓	✗	$f''(0) = 0$, 无 $m > 0$ 下界

函数	凸	严格凸	强凸	说明
e^x	✓	✓	✗	$f'' = e^x \rightarrow 0 \ (x \rightarrow -\infty)$
x^2	✓	✓	✓	$f'' = 2 \geq m = 2 > 0$

层级关系：强凸 $\subset$ 严格凸 $\subset$ 凸。

🔑 **知识点** 强凸定义： $f(x) - \frac{m}{2}\|x\|^2$ 仍凸 ($m > 0$)；等价二阶条件 $\nabla^2 f \succeq mI$ 。强凸 $\Rightarrow$ 二次下界 $f(y) \geq f(x) + \nabla f(x)^T(y-x) + \frac{m}{2}\|y-x\|^2$ (保证算法线性收敛的关键，见 [详细笔记/08 梯度类算法.md](#))。

例 2.14 下水平集是凸集

🔴 **题目** 证明：若 f 是凸函数，则其 α -下水平集 $D_\alpha = \{x : f(x) \leq \alpha\}$ 是凸集。反之是否成立？

✅ **解答** 设 $x_1, x_2 \in D_\alpha$ (即 $f(x_1) \leq \alpha, f(x_2) \leq \alpha$)， $\lambda \in (0, 1)$ ：

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2) \leq \lambda\alpha + (1-\lambda)\alpha = \alpha,$$

故 $\lambda x_1 + (1-\lambda)x_2 \in D_\alpha$ 。■

反之不成立：所有下水平集都凸的函数称“拟凸函数”，如 $f(x) = x^3$ 下水平集都是区间（凸），但 f 非凸。

🔑 **知识点** 凸函数 $\Rightarrow$ 下水平集凸（单向）；拟凸函数。约束 $f_i(x) \leq 0$ (f_i 凸) 定义的可行域为凸集——这是凸优化问题的结构来源（[第3章](#)）。

例 2.15 由不等式/等式约束定义的凸集

🔴 **题目** 给出集合 $S = \{x \in \mathbb{R}^n : g_i(x) \leq 0, h_j(x) = 0\}$ 是凸集的充分条件。

✅ **解答**

- S 凸的**充分（非必要）条件**：每个 g_i 是凸函数，每个 h_j 是仿射函数。
- 理由： $\{g_i \leq 0\}$ 是凸函数的下水平集（凸）， $\{h_j = 0\}$ 是仿射集（凸），有限个凸集之交仍凸。
- 推论： $S = \{x : g_i(x) \geq 0\}$ 凸的充分条件是 g_i 为凹函数。

🔑 **知识点** 凸优化标准形 $\min f_0$ s.t. $f_i(x) \leq 0$ (凸)、 $Ax = b$ (仿射)。等式约束必须仿射，否则可行域一般非凸。直接衔接 [第3章](#) 与 [第6章 KKT](#)。

第3章 凸优化问题

配套精讲：[详细笔记/03 凸优化问题与稀疏优化.md](#)

例 3.1 判断是否为凸优化问题（形式 vs 本质）★

🔴 **题目** 判断

$$\min x_1^2 + x_2^2 \quad \text{s.t.} \quad f_1(x) = \frac{x_1}{1+x_2^2} \leq 0, \quad h_1(x) = (x_1 + x_2)^2 = 0$$

是否为凸优化问题？

✅ 解答

- 按标准定义不是: $f_1 = x_1/(1+x_2^2)$ 非凸, $h_1 = (x_1+x_2)^2$ 非仿射 (等式约束必须仿射)。
- 但本质等价于凸问题: 可行域 $\{x_1/(1+x_2^2) \leq 0\} = \{x_1 \leq 0\}$, $\{(x_1+x_2)^2 = 0\} = \{x_1+x_2 = 0\}$, 故等价于

$$\min x_1^2 + x_2^2 \quad \text{s.t.} \quad x_1 \leq 0, x_1 + x_2 = 0,$$

这是凸问题。结论: 判断凸性要看可行域与目标的实质, 而非约束的书写形式。

🔗 知识点 凸优化标准形 (f_0, f_i 凸、 $Ax = b$ 仿射); "凸问题"是判定题高频考点——先核对每个约束函数类型。

例 3.2 等价变换①: 松弛变量

🔴 题目 将不等式约束 $f_i(x) \leq 0$ 化为等式 + 非负约束。

✅ 解答 引入松弛变量 $s_i \geq 0$: $f_i(x) \leq 0 \iff f_i(x) + s_i = 0, s_i \geq 0$ 。于是标准形

$$\min f_0(x) \quad \text{s.t.} \quad f_i(x) + s_i = 0, s_i \geq 0, h_i(x) = 0.$$

🔗 知识点 松弛变量是单纯形法/内点法把问题化标准形的基本手段。

例 3.3 等价变换②: 目标的单调变换★

🔴 题目 (1) 说明 $\min \|Ax - b\|_2$ 与 $\min \|Ax - b\|_2^2$ 等价; (2) 说明逻辑回归的极大似然 (非凸) 可化为交叉熵损失极小化 (凸)。

✅ 解答

- (1) $\phi(u) = u^2$ 在 $u \geq 0$ (范数取值域) 上单调增, 故 $\arg \min \|Ax - b\|_2 = \arg \min \|Ax - b\|_2^2$ 。两者解相同但问题不同: $\|Ax - b\|_2$ 在 $Ax = b$ 处不可微, 平方后处处可微 (更利于算法)。
⚠️ 单调性必须在取值域上成立: $\arg \min_{x \in \mathbb{R}} x = \emptyset$ 而 $\arg \min x^2 = \{0\}$, 因为 u^2 在整个 $\mathbb{R}$ 上不单调。
- (2) 极大似然 $\max \prod \sigma(\cdot)^{y_i} (1 - \sigma)^{1-y_i} \rightarrow$ 取 $\log$ (单调增, $\max$ 不变) $\rightarrow$ 取负号 (变 $\min$) 得交叉熵

$$\min_w \sum_i [-y_i \log \sigma(x_i^T w) - (1 - y_i) \log(1 - \sigma(x_i^T w))],$$

其中 $-\log \sigma(t) = \log(1 + e^{-t})$ 、 $-\log(1 - \sigma(t)) = \log(1 + e^t)$ 均凸 ($f'' > 0$)。非凸问题经单调变换变成凸问题。

🔗 知识点 ϕ 单调增不改变 argmin/argmax; 单调减则互换 min/max。逻辑回归损失凸性来自负对数 logistic 函数。

例 3.4 等价变换③：上方图形式 (Elastic-Net)

🔴 题目 把 $\min_x \|Ax - y\|_2^2 + \alpha\|x\|_2^2 + \beta\|x\|_1$ 改写为只含可微目标/约束的形式。

✅ 解答 $\min_x f(x) \iff \min_{x,t} t \text{ s.t. } f(x) \leq t$ (上方图思想)。对 $\|x\|_1$ 用此法并拆 $|x_i| = \max\{x_i, -x_i\}$:

$$\min_{x,s} \|Ax - y\|_2^2 + \alpha\|x\|_2^2 + \beta \sum_i s_i \quad \text{s.t.} \quad s_i \geq x_i, \quad s_i \geq -x_i.$$

不可微的 ℓ_1 项被光滑化为线性约束。

🔗 知识点 上方图等价; $|x_i| \leq s_i \iff -s_i \leq x_i \leq s_i$ 是 ℓ_1 线性化的核心技巧 (基追踪、LAD 同理)。

例 3.5 凸优化"局部解必是全局解"★

🔴 题目 证明凸优化问题的任意局部最优解都是全局最优解。

✅ 解答 (反证) 设 x^* 为局部解, 存在邻域半径 δ 。若 x^* 非全局解, 则有 $\bar{x} \in D$ 使 $f(\bar{x}) < f(x^*)$ 。取 $\tilde{x} = \alpha\bar{x} + (1-\alpha)x^*$, $0 < \alpha < \min\{1, \delta/\|\bar{x} - x^*\|\}$ 。由 D 凸知 $\tilde{x} \in D$, 且 $\|\tilde{x} - x^*\| = \alpha\|\bar{x} - x^*\| < \delta$ 落在邻域内。由 f 凸:

$$f(\tilde{x}) \leq \alpha f(\bar{x}) + (1-\alpha)f(x^*) < \alpha f(x^*) + (1-\alpha)f(x^*) = f(x^*),$$

与 x^* 是局部解矛盾。■

🔗 知识点 凸性的"最大红利"——无局部陷阱。这是凸优化算法理论简单的根源。

例 3.6 严格凸 $\Rightarrow$ 全局最优解唯一

🔴 题目 证明严格凸目标的凸优化问题最多有一个全局最优解; 举例说明"存在性"需另行保证。

✅ 解答 设 $x^*, \bar{x}$ 都是全局最优解 ($f(x^*) = f(\bar{x})$) 且 $x^* \neq \bar{x}$ 。取中点:

$$f\left(\frac{1}{2}x^* + \frac{1}{2}\bar{x}\right) < \frac{1}{2}f(x^*) + \frac{1}{2}f(\bar{x}) = f(x^*),$$

矛盾, 故唯一。

- 反例 (无解): $f(x) = e^x$ 严格凸但 $\inf = 0$ 取不到, 无极小解。
- 正例: $f(x) = x^4$ 严格凸, 唯一极小解 $x = 0$ 。

🔗 知识点 最优解集是凸集; 严格凸 $\Rightarrow$ 唯一 (若存在); 强凸 $\Rightarrow$ 存在且唯一。

例 3.7 典型凸优化问题谱系★

🔴 题目 列出五类典型凸优化问题及包含关系。

✅ 解答 $LP \subset QP \subset QCQP \subset SOCP \subset SDP$ (均为凸问题)。

类型	目标	约束
LP 线性规划	$c^T x$	$Ax = b, Gx \leq h$
QP 二次规划	$\frac{1}{2} x^T P x + q^T x \ (P \succeq 0)$	$Gx \leq h, Ax = b$
QCQP 二次约束二次规划	二次凸	二次凸 $\frac{1}{2} x^T P_i x + q_i^T x + r_i \leq 0$
SOCP 二阶锥规划	$f^T x$	$\ A_i x + b_i\ _2 \leq c_i^T x + d_i$
SDP 半定规划	$c^T x$	$\sum x_i A_i + B \preceq 0 \text{ (LMI)}$

🔑 **知识点** 识别问题类型 → 选对求解器。 $n_i = 0$ 时 SOCP 退化为 LP; $c_i = 0$ 时退化为 QCQP。

例 3.8 线性最小二乘 / 线性回归 (QP 实例) ★

🔴 **题目** 写出线性最小二乘的矩阵形式并说明其凸性; 给出线性回归的建模。

✅ **解答**

- 最小二乘 $\min_x \sum_i (a_i^T x - b_i)^2 = \min_x \frac{1}{2} \|Ax - b\|_2^2$ 。 $\nabla^2 f = A^T A \succeq 0 \Rightarrow$ 凸 (无约束 QP)。
- 线性回归: 样本 (x_i, y_i) , 求 w, b 使 $\min_{w,b} \sum_i (w^T x_i + b - y_i)^2$ 。令 $\hat{w} = (w; b)$ 、增广矩阵 $X = [x_i^T \ 1]$, 化为 $\min_{\hat{w}} \|X\hat{w} - y\|_2^2$ 。

🔑 **知识点** 最小二乘是凸优化最古老的实例; 正规方程 $A^T A x = A^T b$ (见 [第4章](#))。

例 3.9 一般 LP 化标准形

🔴 **题目** 把 $\min c^T x \text{ s.t. } Ax = b, Gx \leq h$ 化为标准形 $\min c^T x \text{ s.t. } Ax = b, x \geq 0$ 。

✅ **解答**

- ① 不等式引入松弛 $s \geq 0$: $Gx + s = h$ 。
- ② 自由变量拆正负部 $x = x^+ - x^-$, $x^\pm \geq 0$ 。
得 $\min c^T x^+ - c^T x^- \text{ s.t. } Gx^+ - Gx^- + s = h, Ax^+ - Ax^- = b, x^+, x^-, s \geq 0$ 。

🔑 **知识点** 松弛变量 + 正负部拆分是 LP 标准化的两板斧。

例 3.10 运输问题 (LP 建模)

🔴 **题目** I 个产地 (供 s_i)、 J 个市场 (需 r_j , $\sum s_i = \sum r_j$) , 单位运费 b_{ij} , 求最小总运费方案。

✅ **解答** 令 $x_{ij} \geq 0$ 为 $P_i \rightarrow M_j$ 运量:

$$\min_x \sum_{i,j} b_{ij} x_{ij} \quad \text{s.t.} \quad \sum_j x_{ij} = s_i, \sum_i x_{ij} = r_j, x_{ij} \geq 0.$$

🔑 **知识点** 经典 LP; 产销平衡是有解的前提。

例 3.11 基追踪 / 数据拟合 (绝对值 $\rightarrow$ LP) ★

🔴 题目 把 (1) 基追踪 $\min \|x\|_1$ s.t. $Ax = b$; (2) 最小 ℓ_1 拟合 $\min \|Ax - b\|_1$; (3) 最小 ℓ_∞ 拟合 $\min \|Ax - b\|_\infty$ 各化为 LP。

✅ 解答

- (1) 引入 $z_i \geq |x_i|$: $\min \sum_i z_i$ s.t. $Ax = b, -z_i \leq x_i \leq z_i$ 。(或拆正负部 $x = x^+ - x^-$, $\min \sum (x_i^+ + x_i^-)$ s.t. $Ax^+ - Ax^- = b, x^\pm \geq 0$ 。)
- (2) 令 $y = Ax - b$, $\min \|y\|_1$ s.t. $y = Ax - b$, 再按 (1) 线性化。
- (3) 令 $t = \|Ax - b\|_\infty$: $\min t$ s.t. $-t\mathbf{1} \leq Ax - b \leq t\mathbf{1}$ 。

🔗 知识点 ℓ_1/ℓ_∞ 范数极小化都是 LP。 ℓ_1 诱导稀疏 (压缩感知)。统一技巧: 绝对值/最大值 $\rightarrow$ 引辅助变量夹逼。

例 3.12 支持向量机 (QP 建模) ★

🔴 题目 从“最大化间隔”推导 SVM 的标准二次规划模型。

✅ 解答

- 点到超平面距离 $r = \frac{|w^T x + b|}{\|w\|}$ 。最大化最小间隔: $\max_{w,b,\gamma} \gamma$ s.t. $\frac{y_i(w^T x_i + b)}{\|w\|} \geq \gamma$ 。
- 利用 (w, b) 可同比例缩放, 强制 $\|w\| = 1/\gamma$, 消去 γ , 最大化 $\|w\|^{-1} \Leftrightarrow$ 最小化 $\|w\|^2$:

$$\min_{w,b} \frac{1}{2} \|w\|_2^2 \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, m.$$

这是凸二次规划 (QP), 间隔 $\gamma = 2/\|w\|$ 。

🔗 知识点 SVM = 带线性约束的 QP; 几何间隔最大化 $\Leftrightarrow \|w\|$ 最小化。其对偶问题引出支持向量与核方法 (见 [第 5 章对偶](#))。

例 3.13 QCQP / SOCP / SDP 的凸性

🔴 题目 说明 (1) SOCP 约束 $\|A_i x + b_i\|_2 \leq c_i^T x + d_i$ 定义凸集; (2) LMI 解集 $\{x: B + \sum x_i A_i \preceq 0\}$ 是凸集。

✅ 解答

- (1) $\|Ax + b\| - (c^T x + d)$ 是凸函数 (凸范数 - 仿射), 其 0 下水平集为凸集; 或视为标准二阶锥 $\{(u, t) : \|u\|_2 \leq t\}$ 的仿射原像。
- (2) 设 $F(x) = B + \sum x_i A_i$, $F(x) \preceq 0, F(y) \preceq 0$, 则 $F(\alpha x + (1 - \alpha)y) = \alpha F(x) + (1 - \alpha)F(y) \preceq 0$, 故解集凸。

🔗 知识点 半正定锥 S_+^n 是凸锥; LMI 是线性映射的原像, 保凸。SDP 是 LP 在矩阵空间的推广。

例 3.14 CVXPY 建模 (DCP 规则)

🔴 题目 用 CVXPY 求解

$$\min \sqrt{x_1^2 + x_2^2 + 1} + 2 \max\{x_1, x_2, 0\} \text{ s.t. } |x_1| + |x_2| + \frac{x_1^2}{x_2} \leq 5, \frac{1}{x_2} + x_1^4 \leq 10, x_2 \geq 1, x_1 \geq 0.$$

✅ 解答 (要点) 目标 $\sqrt{x_1^2 + x_2^2 + 1}$ 需写成 `norm([x, 1])` (CVXPY 不能从 $\sqrt{\cdots}$ 直接识别凸性); x_1^2/x_2 用 `quad_over_lin`、 $1/x_2$ 用 `inv_pos`。约束逐条须满足 DCP (凸函数 $\leq$ 凹/常数)。

🔗 知识点 建模语言要求表达式符合 DCP 规则——把函数拼成“已知凸原子 + 保凸运算”。这正是 例 2.12 保凸运算的工程化应用。

第 4 章 无约束可微优化的最优性条件

配套精讲: [详细笔记/04 无约束最优性条件.md](#)

本章是**考试最核心章节**, "求驻点 $\rightarrow$ Hessian 判定 $\rightarrow$ 判断极小/极大/鞍点/全局性"是必考题型。

例 4.1 强制 (coercive) 函数的判定

🔴 题目 判断下列函数是否强制 (coercive, 即 $\|x\| \rightarrow \infty \Rightarrow f \rightarrow +\infty$):

(1) $f(x) = x_1^2 + x_2^2$; (2) $f(x) = x_1^2 + x_2^2 - 2x_1x_2$; (3) $f(x) = 1 - e^{-|x|}$ 。

✅ 解答

- (1) ✓ 强制: $f = \|x\|^2 \rightarrow \infty$ 。
- (2) ✗ 非强制: $f = (x_1 - x_2)^2$, 沿 $x_1 = x_2$ 方向恒为 0, 不趋于 ∞ 。
- (3) ✗ 非强制: $|x| \rightarrow \infty$ 时 $f \rightarrow 1$ (有界)。

🔗 知识点 Weierstrass 定理 (紧集上连续函数取到最值); **强制 + 连续 $\Rightarrow$ 全局极小存在** (即使定义域非紧)。强凸 $\Rightarrow$ 强制 $\Rightarrow$ 极小存在。

例 4.2 下降方向与方向导数

🔴 题目 (1) 给出下降方向的一阶充分条件; (2) 对 $f(x) = x_1^2 - x_2^2$ 在 $(0, 0)$ 处找一个下降方向, 尽管该点梯度为零。

✅ 解答

- (1) 若 $\nabla f(x)^T d < 0$, 则 d 是下降方向 (因方向导数 $\lim_{t \rightarrow 0^+} \frac{f(x+td) - f(x)}{t} = \nabla f(x)^T d < 0$)。最速下降方向取 $d = -\nabla f(x)$ 。
- (2) $\nabla f = (2x_1, -2x_2)$, $\nabla f(0, 0) = 0$, 任意方向都有 $\nabla f^T d = 0$ 。取 $d = (0, 1)$: $f(0, t) = -t^2 < 0 = f(0, 0)$, 确是下降方向。**原因: 一阶项为零, 二阶项主导** (负曲率方向 $d^T \nabla^2 f d < 0$)。

🔗 知识点 $\nabla f^T d < 0$ 是下降的一阶**充分**条件; 非凸时 $\nabla f^T d = 0$ 仍可能下降 (二阶充分条件: $\nabla f^T d = 0$ 且 $d^T \nabla^2 f d < 0$)。

例 4.3 一阶必要条件与驻点概念★

🔴 题目 (1) 叙述局部极小的一阶必要条件; (2) 举例说明"梯度为零"不充分; (3) 说明驻点与极值点的区别。

✅ 解答

- (1) 若 x^* 是 $\min_x f$ 的局部解且 f 在 x^* 可微, 则 $\nabla f(x^*) = 0$ (否则 $d = -\nabla f(x^*)$ 是下降方向, 矛盾)。满足 $\nabla f = 0$ 的点叫**驻点/稳定点/临界点**。
- (2) $f(x) = x_1^3 + x_2^2$, $\nabla f = (3x_1^2, 2x_2)$, $\nabla f(0,0) = 0$, 但 $f(-\varepsilon, 0) = -\varepsilon^3 < 0 = f(0,0)$, 故 $(0,0)$ 非局部解 (是鞍点)。
- (3) 驻点可能是极小/极大/鞍点; 驻点要求一阶导存在, 而极值点不要求——如 $f(x) = |x|$ 在 $x = 0$ 是极小点但**非驻点** (导数不存在)。

🔗 知识点 $\nabla f(x^*) = 0$ 是**必要非充分**条件; 鞍点 (既非极大也非极小的驻点); 逆命题不成立。

例 4.4 二阶必要条件 + 求多个驻点★★

🔴 题目 $\min f(x) = \frac{1}{2}x_1^2 + x_1x_2 + 2x_2^2 - 4x_1 - 4x_2 - x_2^3$, 求驻点并判断。

✅ 解答

- 梯度 $\nabla f = (x_1 + x_2 - 4, x_1 + 4x_2 - 4 - 3x_2^2)^T = 0$, 解得两驻点 $\bar{x} = (4, 0)$ 、 $\tilde{x} = (3, 1)$ 。
- Hessian $\nabla^2 f = \begin{pmatrix} 1 & 1 \\ 1 & 4 - 6x_2 \end{pmatrix}$ 。
- $\nabla^2 f(\bar{x}) = \begin{pmatrix} 1 & 1 \\ 1 & 4 \end{pmatrix}$, $\Delta_1 = 1 > 0, \Delta_2 = 3 > 0$ 正定 $\Rightarrow \bar{x} = (4, 0)$ 是**严格局部极小点**。
- $\nabla^2 f(\tilde{x}) = \begin{pmatrix} 1 & 1 \\ 1 & -2 \end{pmatrix}$, $\Delta_2 = -3 < 0$ 不定 $\Rightarrow \tilde{x} = (3, 1)$ **不是极值点 (鞍点)**。

🔗 知识点 二阶必要条件: 局部极小 $\Rightarrow \nabla f = 0$ 且 $\nabla^2 f \succeq 0$ 。解题模板: ① $\nabla f = 0$ 求所有驻点 ② 逐点代入 Hessian ③ 顺序主子式判定定号性。

例 4.5 满足一二阶必要条件却非极小 / 鞍点

🔴 题目 (1) 说明 $f(x) = x^3$ 在 $x = 0$; (2) $f(x) = x_1^2 - x_2^2$ 在 $(0,0)$ 。

✅ 解答

- (1) $f'(0) = 0, f''(0) = 0$ 同时满足一阶、二阶必要条件, 但 $x = 0$ 非极小 ($f(-\varepsilon) < 0$)。
- (2) $\nabla f(0,0) = 0$, $\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$ 不定 ($d_1 = (1,0)$ 处 > 0 , $d_2 = (0,1)$ 处 < 0), 不满足二阶必要条件, 是**鞍点**。

🔗 知识点 Hessian 既有正特征值又有负特征值 $\Rightarrow$ 鞍点; 沿正特征向量上升、负特征向量下降。 x^3 说明二阶必要条件也不充分。

例 4.6 二阶充分条件★

🔴 题目 (1) 叙述二阶充分条件; (2) 求 $f(x) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$ 的极小点。

✅ 解答

- (1) 若 $\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*) \succ 0$ (正定), 则 x^* 是**严格局部极小点** (由二阶 Taylor + Rayleigh 不等式 $d^T \nabla^2 f d \geq \lambda_{\min} > 0$)。
- (2) $\nabla f = 0$: $\begin{cases} 4(x_1 - 2)^3 + 2(x_1 - 2x_2) = 0 \\ -4(x_1 - 2x_2) = 0 \end{cases}$ 解得 $x^* = (2, 1)$ 。
 $\nabla^2 f = \begin{pmatrix} 12(x_1 - 2)^2 + 2 & -4 \\ -4 & 8 \end{pmatrix}$, 在 x^* 处 $= \begin{pmatrix} 2 & -4 \\ -4 & 8 \end{pmatrix}$ **半正定** ($\Delta_2 = 0$), 二阶充分条件不直接适用。但邻域内 $\nabla^2 f(x) = \begin{pmatrix} 12\Delta x_1^2 + 2 & -4 \\ -4 & 8 \end{pmatrix}$ 始终半正定, 由"邻域内 Hessian 半正定"版本的充分条件知 x^* 是局部极小点。

🔗 知识点 $\nabla^2 f(x^*) \succ 0 \Rightarrow$ 严格局部极小 (充分非必要); 半正定的边界情形需查邻域。Rayleigh 不等式 $\lambda_{\min} \leq \frac{x^T S x}{\|x\|^2} \leq \lambda_{\max}$ 。

例 4.7 驻点分类 + 全局性判断★★

🔴 题目 $\min f(x_1, x_2) = \frac{1}{3}x_1^3 + \frac{1}{2}x_1^2 + 2x_1x_2 + \frac{1}{2}x_2^2 - x_2 + 9$ 。

(1) 求所有驻点并判断局部极小/极大; (2) 是否存在全局极小/极大?

✅ 解答

- (1) $\nabla f = \begin{pmatrix} x_1^2 + x_1 + 2x_2 \\ 2x_1 + x_2 - 1 \end{pmatrix} = 0$, 解得 $x^1 = (2, -3)$ 、 $x^2 = (1, -1)$ 。
 $\nabla^2 f = \begin{pmatrix} 2x_1 + 1 & 2 \\ 2 & 1 \end{pmatrix}$ 。
 - $\nabla^2 f(x^1) = \begin{pmatrix} 5 & 2 \\ 2 & 1 \end{pmatrix}$, $\Delta_1 = 5 > 0, \Delta_2 = 1 > 0$ 正定 $\Rightarrow x^1 = (2, -3)$ **严格局部极小**。
 - $\nabla^2 f(x^2) = \begin{pmatrix} 3 & 2 \\ 2 & 1 \end{pmatrix}$, $\Delta_2 = -1 < 0$ 不定 $\Rightarrow x^2 = (1, -1)$ **非极值点**。
- (2) $f(x_1, 0) = \frac{1}{3}x_1^3 + \frac{1}{2}x_1^2 + 9$, $x_1 \rightarrow \pm\infty$ 时 $f \rightarrow \pm\infty$, **无全局极小/极大**。

🔗 知识点 含三次项的函数一般非凸、可有多驻点; 全局性需另外分析 (看 f 趋于 $\pm\infty$ 的行为)。这是典型大题。

例 4.8 凸函数驻点 = 全局最优 (充要条件) ★

🔴 题目 $\min f(x_1, x_2) = 8x_1^2 + 3x_1x_2 + 7x_2^2 - 19x_1 - 17x_2 - 29$, 求驻点并判断全局性。

✅ 解答

- $\nabla f = \begin{pmatrix} 16x_1 + 3x_2 - 19 \\ 3x_1 + 14x_2 - 17 \end{pmatrix} = 0$ 解得 $x^0 = (1, 1)$ 。
- $\nabla^2 f = \begin{pmatrix} 16 & 3 \\ 3 & 14 \end{pmatrix}$, $\Delta_1 = 16 > 0, \Delta_2 = 215 > 0$ 正定且**恒定** $\Rightarrow f$ 是 (严格) 凸函数。
- 由"凸函数充要条件 $\nabla f(x^*) = 0 \iff x^*$ 全局最优", $x^0 = (1, 1)$ 是**全局极小点** (且唯一)。

🔗 **知识点** 可微凸函数: $\nabla f(x^*) = 0$ 是全局最优的充要条件——这是凸优化求解的根本判据。二次型 Hessian 是常数矩阵, 正定即全局严格凸。

例 4.9 二次函数极小化的存在唯一性★

🔴 **题目** 设 $q(x) = \frac{1}{2}x^T Qx + c^T x$ (Q 对称)。证明: (1) q 有全局极小 $\Leftrightarrow Q \succeq 0$ 且 $Qx^* + c = 0$ 有解; (2) q 有唯一全局极小 $\Leftrightarrow Q \succ 0$ 。

✅ **解答**

- (1) ($\Leftarrow$) $Q \succeq 0 \Rightarrow q$ 凸, $\nabla q(x^*) = Qx^* + c = 0 \Rightarrow x^*$ 最优。($\Rightarrow$) 有极小点 $\Rightarrow \nabla q = 0$ (方程有解) 且 $\nabla^2 q = Q \succeq 0$ 。
- (2) ($\Leftarrow$) $Q \succ 0 \Rightarrow$ 严格凸且 Q 可逆, $x^* = -Q^{-1}c$ 唯一。($\Rightarrow$) 唯一极小 $\Rightarrow$ 由 (1) $Q \succeq 0$ 且 $Qx = -c$ 解唯一 $\Rightarrow Q$ 非奇异 $\Rightarrow Q \succ 0$ 。

🔗 **知识点** 二次函数的最优性完全由 Q 的定号性与相容性 $c \in \text{range}(Q)$ 决定。衔接 [例 2.8](#)。

例 4.10 线性最小二乘与正规方程★★

🔴 **题目** $\min_x \frac{1}{2} \|Ax - b\|_2^2$ ($A \in \mathbb{R}^{m \times n}$)。导出最优解满足的方程, 并讨论解的存在唯一性与几何意义。

✅ **解答**

- $\nabla f(x) = A^T(Ax - b) = 0 \Rightarrow$ **正规方程组** $A^T Ax^* = A^T b$ 。因 $A^T A \succeq 0$, f 凸, 故满足正规方程即全局极小。
- **几何意义**: 残差 $r = b - Ax^*$ 垂直于 $\text{span}(A)$ (列空间), 即 Ax^* 是 b 在列空间上的正交投影 $\Rightarrow A^T r = 0$ 。
- **解的情况**:
 - A 列满秩 $\Rightarrow A^T A \succ 0$ 可逆, 唯一解 $x^* = (A^T A)^{-1} A^T b$ 。
 - A 非列满秩 $\Rightarrow A^T A \succeq 0$ 奇异, f 凸但解不唯一, 解集为 $x_0 + N(A^T A)$ 。
 - 正规方程**恒有解** (因 $A^T b \in \text{span}(A^T A)$)。

🔗 **知识点** 正规方程 $A^T Ax = A^T b$ 是最小二乘核心公式; 几何上是正交投影; 列满秩 $\Rightarrow$ 唯一。衔接 [例 2.10](#)、[例 3.8](#)。

例 4.11 Tikhonov 正则化 / 岭回归★

🔴 **题目** 当 $A^T A$ 病态或奇异时, 如何改善最小二乘解? 给出岭回归的解。

✅ **解答**

- 加 ℓ_2 正则项: $\min_x \|Ax - b\|_2^2 + \lambda \|x\|_2^2$ ($\lambda > 0$)。
- 梯度置零: $2(A^T A + \lambda I)x - 2A^T b = 0 \Rightarrow x^* = (A^T A + \lambda I)^{-1} A^T b$ 。
- $A^T A + \lambda I \succ 0$ **恒正定** (特征值都 $+\lambda$) $\Rightarrow$ 严格凸, 唯一解。条件数 $\kappa = \frac{\lambda_{\max} + \lambda}{\lambda_{\min} + \lambda}$ 显著减小 (如 $500 \rightarrow 2.65$)。

🔗 **知识点** 正则化把半正定变正定 $\Rightarrow$ 严格凸 $\Rightarrow$ 唯一稳定解; 平衡拟合与解的光滑性。去噪问题用差分矩阵 L 作正则项: $x_{RLS} = (I + \lambda L^T L)^{-1} b$ 。

例 4.12 综合判定题 (自测) ★

🔴 题目 $f(x) = (x_1 - x_2)^4 + x_1^2 - x_2^2 - 2x_1 + 2x_2 + 1$, 求满足一阶必要条件的点, 并判断是否局部极小。

✅ 解答

- $\nabla f = \begin{pmatrix} 4(x_1 - x_2)^3 + 2x_1 - 2 \\ -4(x_1 - x_2)^3 - 2x_2 + 2 \end{pmatrix} = 0$ 。两式相加: $2x_1 - 2x_2 = 0 \Rightarrow x_1 = x_2$, 代回得 $2x_1 - 2 = 0 \Rightarrow x_1 = x_2 = 1$, 驻点 $(1, 1)$ 。
- $\nabla^2 f = \begin{pmatrix} 12(x_1 - x_2)^2 + 2 & -12(x_1 - x_2)^2 \\ -12(x_1 - x_2)^2 & 12(x_1 - x_2)^2 - 2 \end{pmatrix}$, 在 $(1, 1)$ 处 $(x_1 - x_2 = 0) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$ 不定。
- 结论: $(x_1, x_2) = (1, 1)$, 不是局部极小点 (N) ——是鞍点。

💡 知识点 即使含四次项, 关键仍是 Hessian 在驻点处的定号性; 本题 Hessian 退化为对角不定矩阵。

第 5 章 对偶理论

配套精讲: [详细笔记/05 对偶理论.md](#)

核心套路: 写拉格朗日函数 $\rightarrow$ 对 x 求 inf 得对偶函数 $g \rightarrow$ 解对偶问题 $\max g \rightarrow$ 比较对偶间隙。

例 5.1 对偶思想: 构造下界★

🔴 题目 $\min x_1^2 + x_2^2 + 2x_1$ s.t. $x_1 + x_2 = 0$ (最优 $(x_1, x_2)^* = (-\frac{1}{2}, \frac{1}{2})$, $p^* = -\frac{1}{2}$)。用"罚到目标里再去约束"的思路构造下界。

✅ 解答

- 直接丢掉约束: $\min x_1^2 + x_2^2 + 2x_1$ 最优 $-1 < p^*$, 是个 (松的) 下界。
- 加乘子项 $\mu(x_1 + x_2)$ (在可行域上该项为 0, 故等价), 再去约束得 $P_\mu: \min x_1^2 + x_2^2 + 2x_1 + \mu(x_1 + x_2)$ 。最优值

$$q(\mu) = -\frac{\mu^2}{2} - \mu - 1 \leq p^* \quad (\forall \mu).$$

- 在所有下界中取最大: $\max_\mu q(\mu)$, 解得 $\mu^* = -1$, $d^* = -\frac{1}{2} = p^*$ (此例对偶间隙为 0)。

💡 知识点 对偶函数=去约束后的最优值, 恒为原问题下界; 对偶问题=最好 (最大) 的下界。

例 5.2 对偶下界可能很松 ($-\infty$)

🔴 题目 $\min -x^2$ s.t. $x = 1$ ($p^* = -1$)。求对偶下界。

✅ 解答 $P_\mu: \min_x -x^2 + \mu(1 - x)$, 因 $-x^2 \rightarrow -\infty$, 故 $g(\mu) = -\infty$ 对所有 μ 。对偶给出平凡下界 $-\infty$ 。

原因: 原问题非凸 ($-x^2$ 凹), 强对偶不成立。

💡 知识点 弱对偶 $d^* \leq p^*$ 永远成立, 但非凸时间隙可能巨大; 下界有用性依赖凸性 + 约束品性。

例 5.3 拉格朗日对偶函数是凹函数★

🔴 题目 证明对任意约束优化问题, 对偶函数 $g(\lambda, \nu) = \inf_x L(x, \lambda, \nu)$ 是凹函数。

✅ 解答 对固定 x , $L(x, \lambda, \nu) = f(x) + \sum \lambda_i c_i + \sum \nu_i c_i$ 是 (λ, ν) 的仿射函数 (既凸又凹)。 g 是一族仿射函数的逐点下确界, 故 g 凹 (无论原问题是否凸!)。

🔗 知识点 g 凹 + 定义域 $\{\lambda \geq 0\}$ 凸 $\Rightarrow$ 对偶问题恒为凸优化 (凹函数在凸集上求 max), 局部即全局。这是对偶最大的价值之一。

例 5.4 弱对偶定理

🔴 题目 证明 $g(\lambda, \nu) \leq p^*$ ($\lambda \geq 0$)。

✅ 解答 设 $\tilde{x}$ 可行 ($c_i \leq 0, i \in I; c_i = 0, i \in E$)。因 $\lambda \geq 0$: $\sum_{i \in I} \lambda_i c_i(\tilde{x}) + \sum_{i \in E} \nu_i c_i(\tilde{x}) \leq 0$, 故

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu) \leq L(\tilde{x}, \lambda, \nu) \leq f(\tilde{x}).$$

对所有可行 $\tilde{x}$ 取下确界得 $g(\lambda, \nu) \leq p^*$ 。■

🔗 知识点 弱对偶 $d^* \leq p^*$ 对凸/非凸都成立; $p^* - d^*$ 为对偶间隙。

例 5.5 Slater 条件 $\Rightarrow$ 强对偶★

🔴 题目 叙述 Slater 约束品性及其作用。

✅ 解答

- Slater 条件: 凸问题中存在相对内点 $x \in \text{relint } D$ 使不等式约束严格成立 $c_i(x) < 0$ 且 $Ax = b$ 。
- 定理: 凸问题 + Slater $\Rightarrow$ 强对偶 $d^* = p^*$, 且对偶最优解可取到。
- 放宽: 仿射不等式约束无需严格 (只需 ≤ 0)。
- 例: $\Omega = \{-5 \leq x \leq 5, \frac{1}{4}x^2 \leq y \leq \frac{25}{4}\}$, 内部点满足 Slater, 抛物线边界上的点不满足。

🔗 知识点 Slater 是强对偶的充分条件; 凸优化"通常"满足。证明用 $\mathbb{A}, \mathbb{B}$ 两凸集的分离超平面。

例 5.6 带不等式约束的对偶 ($5x^2$) ★

🔴 题目 $\min_x 5x^2$ s.t. $3x \leq 5$ 。求对偶问题并算对偶间隙。

✅ 解答

- 显然 $p^* = 0$ ($x^* = 0$ 可行)。凸且满足 Slater。
- $L(x, \lambda) = 5x^2 + \lambda(3x - 5)$, 对 x 求极小: $10x + 3\lambda = 0 \Rightarrow x^* = -\frac{3}{10}\lambda$ 。
- $g(\lambda) = -\frac{9}{20}\lambda^2 - 5\lambda$ 。
- 对偶 $\max_{\lambda \geq 0} \{-\frac{9}{20}\lambda^2 - 5\lambda\}$: 该二次在 $\lambda \geq 0$ 上递减, 最大在 $\lambda^* = 0, d^* = 0$ 。对偶间隙 = 0。

🔗 知识点 不等式约束乘子 $\lambda \geq 0$; 最优 $\lambda^* = 0$ 对应约束不起作用 (互补松弛, 见 第 6 章)。

例 5.7 带等式约束的对偶 ($\frac{1}{2}\|x\|^2$) ★

🔴 题目 $\min \frac{1}{2}(x_1^2 + x_2^2)$ s.t. $x_1 = 1$ 。求对偶并算间隙。

✅ 解答

- $p^* = \frac{1}{2}$ ($x^* = (1, 0)$)。
- $L = \frac{1}{2}(x_1^2 + x_2^2) + \nu(x_1 - 1)$, $\partial_x L = 0: x_1 = -\nu, x_2 = 0$, $g(\nu) = -\frac{1}{2}\nu^2 - \nu$ 。
- $\max_{\nu} g: \nu^* = -1, d^* = \frac{1}{2} = p^*$, 恢复 $x_1^* = 1, x_2^* = 0$ 。间隙 = 0。

🔗 知识点 等式约束乘子 ν 无符号限制; 强对偶下由 ν^* 反解原变量。

例 5.8 欠定方程组的最小范数解★

🔴 题目 $\min \|x\|^2$ s.t. $Ax = b$ ($A \in \mathbb{R}^{m \times n}, m \leq n$, 行满秩)。用对偶求闭式解。

✅ 解答

- $L = x^T x + \nu^T (Ax - b)$, $\nabla_x L = 2x + A^T \nu = 0 \Rightarrow x^* = -\frac{1}{2} A^T \nu$ 。
- $g(\nu) = -\frac{1}{4} \nu^T A A^T \nu - b^T \nu$, 对偶 $\max_{\nu} g \Leftrightarrow \min_{\nu} \frac{1}{4} \nu^T A A^T \nu + b^T \nu$ 。
- $\nabla g = 0: \nu^* = -2(AA^T)^{-1}b$, 回代得 $x^* = A^T(AA^T)^{-1}b$ 。
- 凸 + 仿射约束 $\Rightarrow$ Slater 自动成立, 强对偶。

🔗 知识点 最小范数解的伪逆公式 $x^* = A^+ b = A^T(AA^T)^{-1}b$ (行满秩时); 对偶法导出闭式解的范例。

例 5.9 线性规划的对偶 & 对偶的对偶★

🔴 题目 求标准形 LP $\min c^T x$ s.t. $Ax = b, x \geq 0$ 的对偶; 并验证"对偶的对偶 = 原"。

✅ 解答

- $L(x, s, \nu) = c^T x + \nu^T (Ax - b) - s^T x = -b^T \nu + (A^T \nu - s + c)^T x$ ($s \geq 0$ 对应 $x \geq 0$)。
- $g = \inf_x L = \begin{cases} -b^T \nu, & A^T \nu - s + c = 0 \\ -\infty, & \text{else} \end{cases}$ 。
- 对偶 (令 $y = -\nu$): $\max_y b^T y$ s.t. $A^T y \leq c$ 。
- 再对此对偶求对偶, 得回 $\min c^T x$ s.t. $Ax = b, x \geq 0$ ——LP 与其对偶互为对偶。

🔗 知识点 LP 对偶是 LP; 有可行点即满足 Slater, 强对偶成立。primal/dual 的 finite-unbounded-infeasible 组合表。

例 5.10 生产问题与影子价格★

🔴 题目 产品 A 利 4 (耗 C 2、D 5), 产品 B 利 3 (耗 C 3、D 2), 有 C 24、D 26, 求最大利润; 并解释对偶。

✅ 解答

- 原问题 (P): $\max 4x_1 + 3x_2$ s.t. $2x_1 + 3x_2 \leq 24, 5x_1 + 2x_2 \leq 26, x_1, x_2 \geq 0$ 。
- 对偶 (D) (给原料 C、D 定价 y_1, y_2): $\min 24y_1 + 26y_2$ s.t. $2y_1 + 5y_2 \geq 4, 3y_1 + 2y_2 \geq 3, y_1, y_2 \geq 0$ 。

- 对偶最优解 y_1, y_2 即**影子价格**——每多一单位原料能带来的边际利润。

🔗 **知识点** 对偶变量的经济含义=资源的边际价值/影子价格；强对偶 $\Rightarrow$ 最大利润=最小估价。

例 5.11 ℓ_1 正则与全变差去噪的对偶（了解）

🔴 **题目** 写出 (1) $\min \frac{1}{2} \|Ax - b\|^2 + \mu \|x\|_1$ 与 (2) 全变差去噪 $\min \|x - y\|^2 + \lambda \|Lx\|_1$ 的对偶问题。

✅ **解答**

- (1) 令 $r = Ax - b$, $g(\lambda) = b^T \lambda - \frac{1}{2} \|\lambda\|^2$ (当 $\|A^T \lambda\|_\infty \leq \mu$) ; 对偶 $\max b^T \lambda - \frac{1}{2} \|\lambda\|^2$ s.t. $\|A^T \lambda\|_\infty \leq \mu$ 。
- (2) 令 $z = Lx$, 分离极小化后得对偶 $\max -\frac{1}{4} \mu^T L L^T \mu + \mu^T Ly$ s.t. $\|\mu\|_\infty \leq \lambda$ (一个盒约束 QP, 可用梯度投影法求解)。

🔗 **知识点** ℓ_1 /全变差正则的对偶把不可微原问题转成**盒约束光滑问题**, 便于投影梯度法。衔接 [例 4.11](#)。

第6章 KKT条件与约束优化

对应课件 1-7 约束可微优化问题的最优性条件。问题统一写作

$\min f(x)$ s.t. $c_i(x) = 0, i \in E; c_i(x) \leq 0, i \in I$ 。

主线: 几何最优性条件 (切锥) $\rightarrow$ 难算 $\rightarrow$ 用线性化可行锥 F 代替 $\rightarrow$ 二者相等需"约束品性" $\rightarrow$ Farkas 引理 $\rightarrow$

KKT 条件 $\rightarrow$ 二阶条件 $\rightarrow$ 凸问题下 KKT 变充要。这是约束优化的**核心考点**。

例6.1 有效约束与有效指标集 ★★★

🔴 **题目** 可行域由 $h_1 = x_1 + 2x_2 + 3x_3 - 6 = 0, x_1, x_2, x_3 \geq 0$ 给出。判断 $x_a = (0, 0, 2)^T, x_b = (3, 0, 1)^T, x_c = (1, 1, 1)^T$ 处的不等式有效指标集 $I(x)$ 。

✅ **解答**

- 把不等式写成 $g_1 = -x_1 \leq 0, g_2 = -x_2 \leq 0, g_3 = -x_3 \leq 0$ 。"有效"=该不等式取等号 (即对应分量为 0)。
- $x_a = (0, 0, 2)^T$: $x_1 = 0, x_2 = 0$ 取等, $x_3 = 2 > 0$ 。故 $I(x_a) = \{1, 2\}$ 。
- $x_b = (3, 0, 1)^T$: 仅 $x_2 = 0$ 。故 $I(x_b) = \{2\}$ 。
- $x_c = (1, 1, 1)^T$: 三个分量都 > 0 , 无不等式取等。故 $I(x_c) = \emptyset$ 。
- 等式约束 h_1 在任何可行点都有效, 故完整有效指标集 $A(x) = E \cup I(x)$, 三点都含等式 1。

🔗 **知识点** 有效 (积极) 约束 active constraint: $i \in I$ 且 $c_i(x) = 0$; 非有效 $c_i(x) < 0$ 。有效指标集 $I(x) = \{i \in I \mid c_i(x) = 0\}$, $A = E \cup I(x)$ 。在最优点处只有有效约束才"起作用", 非有效约束可暂时忽略。

例6.2 非有效约束可删去不改变解 ★★

🔴 **题目** $\min x_1^2 + 4x_2^2$ s.t. $(x_1 - 1)^2 + x_2^2 \leq 1, x_2^2 - x_1 + 1 \leq 0$, 最优解 $x^* = (1, 0)^T$ 。问 $I(x^*)$ 是什么? 删去哪个约束解不变?

✅ **解答**

- 代入 $x^* = (1, 0)$: 约束 1 值 $= (1 - 1)^2 + 0 - 1 = -1 < 0$ (非有效); 约束 2 值 $= 0 - 1 + 1 = 0$ (有

效)。

- 故 $I(x^*) = \{2\}$ 。
- 约束 1 在 x^* 处非有效, 删去它解仍是 $(1, 0)$ 。直觉: 起约束作用的只有抛物线边界 $x_2^2 - x_1 + 1 \leq 0$, 圆约束在最优点内部冗余。

🔗 知识点 最优点的局部性质只由有效约束决定。判别"哪个约束真正起作用"是建立 KKT 的第一步。

例6.3 不存在可行方向需引入序列可行方向 (切锥) ★★

🔴 题目 可行域为等式约束 $x_1^2 + x_2^2 - 2 = 0$ (一个圆)。在圆上点 $(-\sqrt{2}, 0)$ 处, 普通"可行方向"集是什么? 如何刻画方向?

✅ 解答

- 可行方向定义: $\exists \alpha > 0$ 使 $x^* + \delta d \in \Omega, \forall \delta \in [0, \alpha]$ 。圆是一维曲线, 沿任何直线方向走立即离开圆 $\Rightarrow$ 不存在非零可行方向。
- 需扩展为序列可行方向 (切向量): 存在可行点列 $x_k \rightarrow x^*, d_k = \frac{x_k - x^*}{\|x_k - x^*\|} \rightarrow d$, 则 d 是切向量。
- 在 $(-\sqrt{2}, 0)$ 处沿圆逼近, 得切向量 $d = (0, \pm 1)$, 即竖直方向 (与该点半径正交)。
- 所有切向量构成切锥 $T_X(x^*)$ (含 0)。内点的切锥是整个 $\mathbb{R}^n$ 。

🔗 知识点 切锥 $T_X(x)$ 完全由可行域几何决定, 能反映其本质, 但难以计算; 切锥不一定是凸锥。

例6.4 线性化可行锥 F 的计算 ★★★

🔴 题目 给出线性化可行方向锥的定义并说明几何含义。

✅ 解答 对可行点 x , 积极集 $A(x) = E \cup \{i \in I : c_i(x) = 0\}$, 定义

$$F(x) = \left\{ d \mid d^T \nabla c_i(x) = 0, \forall i \in E; \quad d^T \nabla c_i(x) \leq 0, \forall i \in A(x) \cap I \right\}.$$

- 来源: 一阶 Taylor 线性化。等式约束 $c_i(x^* + \delta d) \approx \delta d^T \nabla c_i = 0 \Rightarrow d^T \nabla c_i = 0$; 有效不等式 $\leq 0 \Rightarrow d^T \nabla c_i \leq 0$ 。
- 几何: d 与每个有效不等式约束梯度 ∇c_i 成钝角或直角 (指向可行域一侧)。
- 优点: 纯代数、易算; 缺点: 受可行域代数表示方式影响, 不一定反映本质。

🔗 知识点 恒有 $T_X(x) \subseteq F(x)$ (切锥 $\subseteq$ 线性化锥, 课件用 Taylor 展开证明); 反向包含不一定成立。

例6.5 $F \supsetneq T$ 的反例 (约束品性失效) ★★★

🔴 题目 (1) $\min x$ s.t. $c(x) = -x + 3 \leq 0$, 把约束改写成 $(-x + 3)^3 \leq 0$, 在 $x^* = 3$ 处比较 T 与 F 。(2) 约束 $(x_1^2 + x_2^2 - 1)^2 = 0$ 在 $A(1, 0)$ 处比较。

✅ 解答

- (1) 可行域恒为 $\{x \geq 3\}$, 故切锥 $T_X(3) = \{d : d \geq 0\}$ 不随写法改变。但 $c(x) = (-x + 3)^3$ 的导数 $c'(3) = -3(x - 3)^2|_3 = 0$, 于是 $F(3) = \{d \mid c'(3)d \leq 0\} = \{d \mid 0 \leq 0\} = \mathbb{R}$ 。此时 $F(3) \supsetneq T_X(3)$ (严格包含)。
- (2) $\nabla c = 2(x_1^2 + x_2^2 - 1)(x_1, x_2)^T$, 在 $A(1, 0)$ 处 $x_1^2 + x_2^2 - 1 = 0 \Rightarrow \nabla c(A) = 0$ 。于是 $F(A) = \{d \mid 0^T d = 0\} = \mathbb{R}^2$, 而切锥 $T_X(A) = \{(0, \pm 1)\}$ 。同样 $F \supsetneq T$ 。
- 病因: 有效约束梯度退化为 0 (或互相线性相关), 线性化"看不出"真实弯曲。

🔑 知识点 F 和 T 不等时 KKT 推导失效, 需要约束品性 (constraint qualification, CQ) 来保证 $T_X(x^*) = F(x^*)$ 。

例6.6 几个常用约束品性的判定 ★★★

🔴 题目 叙述 LICQ、MFCQ、LFCQ 并判断: $c_1 = x_2 - x_1^2 = 0$, $c_2 = x_1^2 + (x_2 - 1)^2 - 1 \leq 0$, 在 $x = (0, 0)$ 处 LICQ 是否成立?

✅ 解答

- LICQ (线性无关约束品性): 有效约束梯度 $\{\nabla c_i(x) : i \in A(x)\}$ 线性无关。 $\Rightarrow T = F$ (最强、最常用)。
- MFCQ (Mangasarian-Fromovitz): $\exists w$ 使 $\nabla c_i^T w < 0$ ($i \in A \cap I$) 且 $\nabla c_i^T w = 0$ ($i \in E$), 且等式梯度线性无关。 LICQ $\Rightarrow$ MFCQ, 反之不然。
- LFCQ (线性约束品性): 所有约束都是线性 (仿射) 的。 $\Rightarrow$ 恒有 $T = F$ 。故 LP、QP 无需再验证品性。
- 判定: $\nabla c_1(0, 0) = (0, 1)^T$ (c_1 有效, 等式), $\nabla c_2(0, 0) = (2x_1, 2(x_2 - 1))|_{(0,0)} = (0, -2)^T$ ($c_2(0, 0) = 0 + 1 - 1 = 0$ 也有效)。两梯度 $(0, 1), (0, -2)$ 平行 $\Rightarrow$ 线性相关 $\Rightarrow$ LICQ 不成立。但此例仍有 $F = T = \{(\alpha, 0)\}$, 说明 LICQ 只是充分非必要条件。

🔑 知识点 LICQ 是 $T = F$ 的充分非必要条件。LFCQ 与 LICQ 间无相互包含关系。

例6.7 Farkas 引理 ★★

🔴 题目 叙述 Farkas 引理, 并说明它如何把"无可行下降方向"翻译成 KKT 的乘子形式。

✅ 解答 Farkas 引理: 给定向量 $\{a_i\}_1^p, \{b_i\}_1^q, c$, 下述系统

$$d^T a_i = 0 \ (\forall i), \quad d^T b_i \geq 0 \ (\forall i), \quad d^T c < 0$$

无解 $\iff$ 存在 $\lambda_i \in \mathbb{R}, \mu_i \geq 0$ 使 $c = \sum_i \lambda_i a_i + \sum_i \mu_i b_i$ 。

- 取 $a_i = \nabla c_i$ ($i \in E$), $b_i = -\nabla c_i$ ($i \in A \cap I$), $c = -\nabla f(x^*)$ 。
- 几何最优性"无可行下降方向"恰是上面系统无解, 于是得 $-\nabla f(x^*) = \sum_{i \in E} \lambda_i \nabla c_i + \sum_{i \in A \cap I} \lambda_i \nabla c_i$, $\lambda_i \geq 0$ ($i \in I$) ——即 KKT 稳定性条件。
- 证明" $\Leftarrow$ "显然; " $\Rightarrow$ "用构造 LP 及其对偶 ($d = 0$ 可行 $\Rightarrow$ 若 (*) 不成立则原 LP 无界, 得矛盾的 d)。

🔑 知识点 Farkas 引理 = 线性不等式系统的"二选一" (择一定理), 是从几何条件过渡到 KKT 乘子表达的桥梁。

例6.8 KKT 条件 (总结形式) ★★★★★

🔴 题目 写出一般约束问题 $\min f$ s.t. $c_i \leq 0$ ($i \in I$), $c_i = 0$ ($i \in E$) 的完整 KKT 条件, 并解释每一条。

✅ 解答 设 x^* 局部最优且 $T_X(x^*) = F(x^*)$ (约束品性成立), 则存在乘子 λ_i^* 使

$$\text{稳定性: } \nabla_x L(x^*, \lambda^*) = \nabla f(x^*) + \sum_{i \in I \cup E} \lambda_i^* \nabla c_i(x^*) = 0,$$

$$\text{原始可行: } c_i(x^*) = 0 \ (i \in E), \quad c_i(x^*) \leq 0 \ (i \in I),$$

$$\text{对偶可行: } \lambda_i^* \geq 0 \ (i \in I),$$

$$\text{互补松弛: } \lambda_i^* c_i(x^*) = 0 \ (i \in I).$$

- 互补松弛 $\lambda_i^* c_i = 0$ 说明: 非有效约束 ($c_i < 0$) 对应 $\lambda_i^* = 0$; 乘子为正 ($\lambda_i^* > 0$) 则约束有效 ($c_i = 0$)。两者恰有一个成立称严格互补。
- 满足 KKT 的 (x^*, λ^*) 称 KKT 对, x^* 称 KKT 点。

🔑 **知识点** KKT 是约束优化的一阶必要条件（需约束品性）。若最优点处 $T \neq F$ ，则最优点不一定是 KKT 点；反之 KKT 点也不一定是局部最优点（仅必要）。等式约束乘子 $\lambda_i \in \mathbb{R}$ 无号限制，不等式乘子 $\lambda_i \geq 0$ 。相关：[[第5章 对偶理论]]。

例6.9 强对偶 $\Rightarrow$ KKT（对偶视角的证明）★★

🔴 **题目** 证明：若目标与约束可微且强对偶成立，则任一对原-对偶最优解满足 KKT。

✅ **解答** 记原最优 x^* 、对偶最优 (λ^*, μ^*) 。强对偶 $\Rightarrow$

$$f(x^*) = d(\lambda^*, \mu^*) = \min_x \left\{ f(x) + \sum_{i \in I} \mu_i^* g_i(x) + \sum_{i \in E} \lambda_i^* h_i(x) \right\} \leq f(x^*) + \underbrace{\sum \mu_i^* g_i(x^*)}_{\leq 0} + \underbrace{\sum \lambda_i^* h_i(x^*)}_{=0} \leq f(x^*).$$

- 两端相等 $\Rightarrow$ 中间所有不等号变等号。
- 第一个 " $\leq$ " 取等 $\Rightarrow x^*$ 是 $L(x, \lambda^*, \mu^*)$ 的极小点 $\Rightarrow \nabla_x L(x^*, \dots) = 0$ （稳定性）。
- 第二个 " $\leq$ " 取等 $\Rightarrow \sum \mu_i^* g_i(x^*) = 0$ ，每项非正 $\Rightarrow \mu_i^* g_i(x^*) = 0$ （互补松弛）。
- 再加上 x^* 原始可行、 $\mu_i^* \geq 0$ 对偶可行，即得全部 KKT。

🔑 **知识点** 这条提供 KKT 的另一来源（不依赖约束品性，但要强对偶）。与几何/Farkas 路线互补。

例6.10 临界锥与二阶最优性条件 ★★★

🔴 **题目** 定义临界锥 $C(x^*, \lambda^*)$ ，写出约束优化的二阶必要/充分条件。

✅ **解答**

- **临界锥**： $C(x^*, \lambda^*) = \{d \in F(x^*) \mid \nabla c_i(x^*)^\top d = 0, \forall i \in A \cap I \text{ 且 } \lambda_i^* > 0\}$ 。即在 F 基础上，把“乘子严格为正”的有效不等式也收紧成等式。这些方向上一阶导无法判定升降。
- 在 C 上有 $d^\top \nabla f(x^*) = \sum \lambda_i^* d^\top \nabla c_i = 0$ 。
- **二阶必要**： x^* 局部最优且 $T = F$ ，则 $d^\top \nabla_{xx}^2 L(x^*, \lambda^*) d \geq 0, \forall d \in C$ 。
- **二阶充分**： (x^*, λ^*) 满足 KKT，且 $d^\top \nabla_{xx}^2 L d > 0, \forall d \in C, d \neq 0$ ，则 x^* 是严格局部极小。**充分条件不需要任何约束品性假设。**

🔑 **知识点** 与无约束 $\nabla^2 f \succeq 0 / \succ 0$ 对照：约束情形只要求 Hessian 在临界锥上（而非全空间）的“投影半正定/正定”。相关：[[第4章 无约束可微优化的最优性条件]]。

例6.11 用二阶条件甄别多个 KKT 点 ★★★★★

🔴 **题目** $\min x_1^2 + x_2^2$ s.t. $\frac{x_1^2}{4} + x_2^2 - 1 = 0$ 。求全部 KKT 对，并用二阶条件判定哪些是局部最优。

✅ **解答**

- $L = x_1^2 + x_2^2 + \lambda(\frac{x_1^2}{4} + x_2^2 - 1)$ ， $\nabla c = (x_1/2, 2x_2)^\top$ （处处非零 $\Rightarrow$ LICQ 成立，且无不等式约束 $\Rightarrow C = F$ ）。
- 稳定性： $2x_1 + \lambda x_1/2 = 0, 2x_2 + 2\lambda x_2 = 0$ ，配合约束解得 **4 个 KKT 对**
 $(x^\top, \lambda) = (2, 0, -4), (-2, 0, -4), (0, 1, -1), (0, -1, -1)$ 。
- $\nabla_{xx}^2 L = \begin{bmatrix} 2 + \lambda/2 & 0 \\ 0 & 2 + 2\lambda \end{bmatrix}$ 。
 - 对 $(2, 0, -4)$ ： $\nabla_{xx}^2 L = \text{diag}(0, -6)$ ， $C = \{(d_1, d_2) \mid d_1 = 0\}$ （因 $\nabla c = (1, 0)$ ）。取 d

- $= (0, 1): d^T \nabla^2 L d = -6 < 0 \Rightarrow$ **不是**局部最优。 $(-2, 0, -4)$ 同理对称 $\Rightarrow$ **不是**。
- 对 $(0, 1, -1): \nabla_{xx}^2 L = \text{diag}(3/2, 0), C = \{(d_1, d_2) \mid d_2 = 0\}$ (因 $\nabla c = (0, 2)$)。任取 $d = (d_1, 0), d_1 \neq 0: d^T \nabla^2 L d = \frac{3}{2} d_1^2 > 0 \Rightarrow$ **严格局部最优**。 $(0, -1, -1)$ 对称 $\Rightarrow$ **也是**局部最优。
 - 结论：填空—— $(-2, 0, -4)$ **不是**局部最优； $(0, -1, -1)$ **是**局部最优。几何上 $(0, \pm 1)$ 是椭圆短轴端点（离原点最近）， $(\pm 2, 0)$ 是长轴端点（最远）。

🔑 **知识点** KKT 给候选点，二阶条件（在临界锥上）做最终甄别。注意 Hessian 在全空间不定，但限制到临界锥后可能定号。

例6.12 Slater 失效 $\Rightarrow$ KKT 点可能不存在 ★★★

🔴 **题目** $\min x^2 + y^2 \text{ s.t. } (x + y - 2)^2 \leq 0$ 。显然 $x^* = y^* = 1, p^* = 2$ 。试用 KKT 求解，会发生什么？

- ✅ **解答** 唯一可行点是 $x + y = 2$ (因平方 ≤ 0 等价于 $= 0$)。KKT:
- $$2x + 2\lambda(x + y - 2) = 0, \quad 2y + 2\lambda(x + y - 2) = 0, \quad (x + y - 2)^2 \leq 0, \quad \lambda(x + y - 2)^2 = 0, \quad \lambda \geq 0.$$
- 在最优点 $x + y - 2 = 0$ ，前两式变为 $2x = 0, 2y = 0 \Rightarrow x = y = 0$ ，与 $x + y = 2$ 矛盾。无论 $\lambda > 0$ 或 $\lambda = 0$ 都**无解**。
 - 原因：约束写成 $(x + y - 2)^2 \leq 0$ ，其梯度在可行点恒为 **0**，**Slater 条件不满足**（可行域无内点）。即使原问题有全局最优，也可能不存在满足 KKT 的 (x^*, λ^*) 。

🔑 **知识点** 凸问题里 Slater 条件（存在严格内点 $c_i(x) < 0$ ）是 KKT 成为最优性条件的保证。退化写法 $\rightarrow$ 无内点 $\rightarrow$ KKT 失效。相关：[[第5章 对偶理论]] 的 Slater。

例6.13 凸优化问题的一阶充要条件（KKT 变充要） ★★★

🔴 **题目** $\min f(x) = 2x_1^2 + 2x_1x_2 + x_2^2 - 10x_1 - 10x_2 \text{ s.t. } c_1 = x_1^2 + x_2^2 - 5 \leq 0, c_2 = 3x_1 + x_2 - 6 \leq 0$ 。求 KKT 点并说明它是否全局解。

✅ **解答**

- f, c_1, c_2 均为一阶连续可微凸函数 (f 的 Hessian $\begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix}$, $\Delta_1 = 4, \Delta_2 = 4 > 0$ 正定; c_1 凸; c_2 线性)，且 Slater 成立 (如 $(0, 0): c_1 = -5 < 0, c_2 = -6 < 0$)。 $\Rightarrow$ 这是凸优化，**KKT 充要**。
- 由 KKT 求得 $x^* = (1, 2)^T$ (验证: $c_1(1, 2) = 1 + 4 - 5 = 0$ 有效, $c_2(1, 2) = 3 + 2 - 6 = -1 < 0$ 非有效 $\Rightarrow \lambda_2^* = 0$; 稳定性 $\nabla f + \lambda_1 \nabla c_1 = 0$ 解出 $\lambda_1^* \geq 0$)。
- 因为凸 + Slater + 满足 KKT $\Rightarrow x^* = (1, 2)^T$ 是**全局极小点**。

🔑 **知识点** 凸优化问题 + Slater: **KKT 是全局最优的充要条件**（局部即全局）。这是 KKT 最实用的场景——直接解 KKT 方程即得全局解。

例6.14 线性规划的 KKT（最优性条件） ★★★

🔴 **题目** 标准型 LP: $\min c^T x \text{ s.t. } Ax = b, x \geq 0$ 。写出其 KKT 条件。

✅ **解答** Lagrange $L = c^T x + \nu^T (Ax - b) - s^T x$ ($s \geq 0$ 对应 $x \geq 0$)。LP 是凸且满足 Slater，故全局最优 x^* 满足

$$c + A^T \nu^* - s^* = 0, \quad Ax^* = b, \quad x^* \geq 0, \quad s^* \geq 0, \quad s^* \odot x^* = 0,$$

其中 $\odot$ 为 Hadamard 积, $s^* \odot x^* = 0$ 即每个分量 $s_i^* x_i^* = 0$ (互补松弛)。

- 上述条件也是**充分**的：满足者既是原 LP 全局最优， (s^*, ν^*) 也是对偶 LP 全局最优。

🔗 **知识点** LP 的 KKT = 原始可行 + 对偶可行 ($A^T \nu + s = c, s \geq 0$) + 互补松弛。这正是单纯形/内点法的理论基础。相关：[[第5章 对偶理论]] LP 自对偶。

例6.15 仿射空间上的投影 (解析解) ★★★

🔴 **题目** $\min \frac{1}{2} \|x - y\|_2^2$ s.t. $Ax = b$ (A 行满秩)。用 KKT 求点 y 到仿射集 $\{Ax = b\}$ 的投影。

✅ **解答** $L = \frac{1}{2} \|x - y\|_2^2 + \lambda^T (Ax - b)$ 。KKT:

$$x^* - y + A^T \lambda^* = 0, \quad Ax^* = b.$$

- 第一式左乘 A : $Ax^* - Ay + AA^T \lambda^* = 0 \Rightarrow \lambda^* = (AA^T)^{-1}(Ay - b)$ 。
- 回代: $x^* = y - A^T(AA^T)^{-1}(Ay - b)$ 。
- 即投影 = y 减去残差 $Ay - b$ 经 $A^T(AA^T)^{-1}$ 拉回的修正量。

🔗 **知识点** "稳定性条件解出 $x(\lambda) \rightarrow$ 代入约束求 $\lambda \rightarrow$ 回代"是解析求 KKT 的标准三步法。当 $b = 0$ 退化为到零空间的投影。相关：[[第5章 对偶理论]] 最小范数解。

例6.16 等式约束二次规划 (EQP) 与 KKT 矩阵 ★★★★★

🔴 **题目** $\min \frac{1}{2} x^T Gx + r^T x$ s.t. $Ax = b$ (A 行满秩, G 对称正定/半正定)。写出 KKT 方程组并给出解。

✅ **解答** $L = \frac{1}{2} x^T Gx + r^T x + \lambda^T (Ax - b)$ 。稳定性 $Gx + r + A^T \lambda = 0$ 与可行 $Ax = b$ 合并为 KKT 方程组

$$\begin{bmatrix} G & A^T \\ A & O \end{bmatrix} \begin{bmatrix} x \\ \lambda \end{bmatrix} = \begin{bmatrix} -r \\ b \end{bmatrix}.$$

- 系数阵称 **KKT 矩阵**。当 G 正定、 A 行满秩时它**非奇异**，有唯一解：
 $\lambda^* = -(AG^{-1}A^T)^{-1}(AG^{-1}r + b), \quad x^* = -G^{-1}(A^T \lambda^* + r)$ 。
- **非奇异性证明**：设 $\begin{bmatrix} G & A^T \\ A & O \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} = 0$ 。则 $Au = 0$ ，且 $u^T Gu + u^T A^T v = u^T Gu = 0$ (用 $Au = 0$)。 G 正定 $\Rightarrow u = 0$ ；再由 $A^T v = 0$ 与 A 行满秩 $\Rightarrow v = 0$ 。故非奇异。

🔗 **知识点** EQP 把约束优化化为**解线性方程组**，是 SQP、内点法每步子问题的原型。引理： A 行满秩 + G 正定 $\Rightarrow AG^{-1}A^T$ 正定，保证上式可逆。相关：[[第3章 凸优化问题]] QP。

例6.17 SVM 的 KKT 与支持向量 ★★★★★

🔴 **题目** 硬间隔 SVM: $\min \frac{1}{2} \|w\|^2$ s.t. $y_i(w^T x_i - b) \geq 1$ 。写出 KKT，并解释"支持向量"。

✅ **解答** $L = \frac{1}{2} \|w\|^2 + \sum_i \lambda_i (1 - y_i(w^T x_i - b))$ 。KKT:

$$w^* = \sum_i \lambda_i^* y_i x_i, \quad \sum_i \lambda_i^* y_i = 0, \quad y_i(w^{*T} x_i - b^*) \geq 1, \quad \lambda_i^* \geq 0, \quad \lambda_i^* (1 - y_i(w^{*T} x_i - b^*)) = 0.$$

- **互补松弛**给出两类样本：
 - $\lambda_i^* = 0$: 该样本不进入 $w^* = \sum \lambda_i^* y_i x_i$ ，对超平面**无影响**。
 - $\lambda_i^* > 0$: 必有 $y_i(w^{*T} x_i - b^*) = 1$ ，样本落在最大间隔边界上，是**支持向量**。
- 故最优超平面只由少数支持向量决定。

✅ **软间隔扩展** $\min \frac{1}{2} \|w\|^2 + C \sum_i \xi_i$ s.t. $y_i(w^T x_i - b) \geq 1 - \xi_i, \xi_i \geq 0$ 。引入乘子 λ_i (间隔约束)、 μ_i ($\xi_i \geq 0$)，KKT 多出 $\nabla_{\xi} L = C1 - \mu^* - \lambda^* = 0$ ，故 $\lambda_i^* \in [0, C]$ 。三种情形：

- $\lambda_i^* = 0 \Rightarrow \mu_i^* = C, \xi_i^* = 0$: 样本在间隔外，无贡献。
- $\lambda_i^* = C \Rightarrow \mu_i^* = 0$: 样本在间隔内或被误分 ($\xi_i^* > 1$ 误分类)。

- $\lambda_i^* \in (0, C) \Rightarrow \xi_i^* = 0, y_i(w^{*\top} x_i - b^*) = 1$: 恰在边界上。

🔗 **知识点** SVM 是 KKT 互补松弛的经典应用——稀疏性 (支持向量) 直接来自 $\lambda_i^* c_i^* = 0$ 。盒约束 $0 \leq \lambda_i \leq C$ 来自软间隔的 $\xi_i \geq 0$ 。相关: [[第3章 凸优化问题]] SVM 建模。

例6.18 可微凸优化的变分不等式刻画 ★★

🔗 **题目** 证明: x 是凸优化 $\min_{x \in X} f_0(x)$ (X 凸) 的最优解 $\iff x$ 可行且 $\nabla f_0(x)^\top (y - x) \geq 0, \forall y \in X$ 。

✅ **解答**

- **充分性**: 由 f_0 凸, $f_0(y) \geq f_0(x) + \nabla f_0(x)^\top (y - x) \geq f_0(x)$ (末步用条件)。故 x 最优。
- **必要性** (反证): 若存在 $y \in X$ 使 $\nabla f_0(x)^\top (y - x) < 0$, 令 $z(t) = ty + (1 - t)x \in X$ (X 凸)。则 $\frac{d}{dt} f_0(z(t))|_{t=0} = \nabla f_0(x)^\top (y - x) < 0$, 故小 $t > 0$ 时 $f_0(z(t)) < f_0(x)$, 与最优矛盾。

🔗 **知识点** 几何含义: 若 $\nabla f_0(x) \neq 0$, 它定义了可行集 X 在 x 处的支撑超平面, $-\nabla f_0$ 指向 X 外。这是 KKT 在凸情形的几何等价表述。相关: [[第3章 凸优化问题]] 局部即全局。

第7章 线搜索方法

对应课件 **2-1线搜索方法**。无约束算法统一框架 $x^{k+1} = x^k + \alpha_k d^k$: 先定**下降方向** d^k ($(d^k)^\top \nabla f(x^k) < 0$), 再定**步长** α_k 。本章聚焦步长: 精确线搜索 (区间收缩/插值) 与非精确准则 (Armijo/Goldstein/Wolfe), 以及 Zoutendijk 收敛性。

例7.1 迭代法 vs 直接解一阶条件 ★★

🔗 **题目** 为什么不直接解 $\nabla f(x) = 0$ 而用迭代法? 写出常见停止准则与收敛速度分类。

✅ **解答**

- $\nabla f = 0$ 对一般 f 是 n 元**非线性方程组**, 常有多解、需算 Hessian、计算量大 (2000 维即 2000 个非线性方程)。迭代法逐点逼近, 避开整体求解。
- **停止准则** (ε 小阈值): $\|\nabla f(x^k)\| \leq \varepsilon$; $|f(x^{k+1}) - f(x^k)| < \varepsilon$; $\|x^{k+1} - x^k\| < \varepsilon$; 及其相对化版本 $\frac{|\Delta f|}{\max\{1, |f|\}} < \varepsilon$; 或超出最大迭代数。
- **Q-收敛速度** ($e_k = \|x^k - x^*\|$): 线性 $\frac{e_{k+1}}{e_k} \leq a \in (0, 1)$ (如 $\{2^{-k}\}$); 超线性 $\frac{e_{k+1}}{e_k} \rightarrow 0$; 次线性 $\rightarrow 1$ (如 $\{1/k\}$, 慢); 二次 $\frac{e_{k+1}}{e_k^2} \leq a$ (如 $\{2^{-2^k}\}$, 最快)。

🔗 **知识点** 复杂度 $N(\varepsilon)$: 次线性 $f^k - f^* \leq c/\sqrt{k} \rightarrow O(1/\varepsilon^2)$; $c/k \rightarrow O(1/\varepsilon)$; 线性 $\rightarrow O(\log \frac{1}{\varepsilon})$; 超线性/二次 $\rightarrow O(\log \log \frac{1}{\varepsilon})$ ($\approx$ 常数, 二次收敛 6 步可达 5×10^{-20})。相关: [[第9章 牛顿类算法]]。

例7.2 精确线搜索的解析步长 (二次函数) ★★★★★

🔗 **题目** 对 $f(x) = \frac{1}{2} x^\top G x + a^\top x + b$ (G 对称正定), 沿下降方向 d^k 的精确最优步长是多少?

✅ **解答** 令 $\phi(\alpha) = f(x^k + \alpha d^k)$, $\nabla f = Gx + a$ 。展开

$$\phi(\alpha) = \frac{1}{2} \alpha^2 (d^k)^\top G d^k + \alpha \nabla f(x^k)^\top d^k + f(x^k).$$

令 $\phi'(\alpha_k) = 0$:

$$\alpha_k = -\frac{\nabla f(x^k)^\top d^k}{(d^k)^\top G d^k}.$$

分母 > 0 (G 正定), 分子 < 0 (下降方向), 故 $\alpha_k > 0$ 。

🔗 **知识点** 这是少数能解析求最优步长的情形。一般 f 难求解析解, 故转用区间收缩/插值/非精确准则。相关: [[第8章 梯度类算法]] 最速下降的精确步长。

例7.3 黄金分割法 (0.618 法) ★★★

🔴 **题目** 黄金分割法为何取 $\rho = \frac{3-\sqrt{5}}{2} \approx 0.382$? 用它求 $f(x) = x^4 - 14x^3 + 60x^2 - 70x$ 在 $[0, 2]$ 上极小, 要求区间压到 0.3 内, 需几步?

✅ **解答**

- 对称压缩 $a_1 - a_0 = b_0 - b_1 = \rho(b_0 - a_0)$, 要每次迭代只算一次新函数值需复用旧点: 由 $\rho(1 - \rho) = 1 - 2\rho$ 得 $\rho^2 - 3\rho + 1 = 0$, 取 $< \frac{1}{2}$ 的根 $\rho = \frac{3-\sqrt{5}}{2} \approx 0.382$, 保留比例 $\tau = 1 - \rho \approx 0.618$ 。
- 每步区间乘 0.618, N 步总压缩比 0.618^N 。要 $0.618^N \leq 0.3/2 = 0.15$, 解得 $N = 4$ 。
- 比较点法则: 若 $f(a_1) < f(b_1)$, 极小在 $[a_0, b_1]$; 否则在 $[a_1, b_0]$ 。

🔗 **知识点** 0.618 法压缩比恒定、每步一次函数求值, 是不依赖导数的区间收缩法。简单 1/3 法每步两次求值、压缩比 0.667^N , 更差。

例7.4 Fibonacci 法及与 0.618 法的关系 ★★★

🔴 **题目** Fibonacci 法允许 ρ_k 变化, 其总压缩比是多少? 为什么说 0.618 法是它的极限? 同例 f 、 $[0, 2]$ 、精度 0.3 需几步?

✅ **解答**

- 取 $\rho_k = 1 - \frac{F_{N-k+1}}{F_{N-k+2}}$ (F 为 Fibonacci 数 $F_{-1} = 0, F_0 = 1, F_{k+1} = F_k + F_{k-1}$: 1, 2, 3, 5, 8, 13, 21, 34, ...)。总压缩比 $\prod_{k=1}^N (1 - \rho_k) = \frac{F_N}{F_{N+1}} \cdot \frac{F_{N-1}}{F_N} \cdots \frac{F_1}{F_2} = \frac{1}{F_{N+1}}$ 。
- 末步 $\rho_N = 1/2$ 两点重合, 取 $\rho_N = \frac{1}{2} - \varepsilon$, 总压缩比 $\frac{1+2\varepsilon}{F_{N+1}}$ 。要 ≤ 0.15 且 $\varepsilon \leq 0.1$, 得 $F_{N+1} \geq \frac{1.2}{0.15} = 8 = F_6$, 故 $N = 4$ 。
- **极限关系:** $\frac{F_n}{F_{n-1}} = 1 + \frac{F_{n-2}}{F_{n-1}}$, 令 $F_* = \lim \frac{F_{n-1}}{F_n}$ 得 $\frac{1}{F_*} = 1 + F_*$, 即 $F_*^2 + F_* - 1 = 0$, $F_* = \frac{\sqrt{5}-1}{2} \approx 0.618$ 。即 0.618 法是用极限比代替每步比值。

🔗 **知识点** Fibonacci 法是“给定步数下总压缩比最小”的最优区间收缩法 (解一个约束优化 $\min \prod (1 - \rho_k)$) ; 0.618 法是其渐进简化。

例7.5 二分法与牛顿法 (一维求极小) ★★★

🔴 **题目** 二分法用什么信息压缩区间? 牛顿法的一维迭代公式如何导出? 牛顿法何时可能失败?

✅ **解答**

- **二分法:** 用一阶导数符号。取中点 $x^{(k)} = \frac{a+b}{2}$, 若 $f'(x^{(k)}) > 0$ 极小在左 $\rightarrow$ 区间取 $[a, x^{(k)}]$; < 0 在右 $\rightarrow [x^{(k)}, b]$; $= 0$ 即极小。每步压缩比 $1/2$, N 步 $(1/2)^N$ 。要 $(0.5)^N \leq 0.15$ 得 $N = 3$ (同例 f , 比 0.618 法/Fibonacci 法的 4 步更快, 但需可导)。
- **牛顿法:** 在 $x^{(k)}$ 处二次近似 $q(x) = f(x^{(k)}) + f'(x^{(k)})(x - x^{(k)}) + \frac{1}{2}f''(x^{(k)})(x - x^{(k)})^2$, 令 $q' = 0$ 得 $x^{(k+1)} = x^{(k)} - \frac{f'(x^{(k)})}{f''(x^{(k)})}$ 。
- **失败情形:** 若某点 $f''(x) < 0$, 牛顿法可能收敛到极大点 (二次近似开口向下)。需 $f'' > 0$ 保证。

- **割线法**: f'' 不可得时用 $f'' \approx \frac{f'(x^k) - f'(x^{k-1})}{x^k - x^{k-1}}$ 代入, 需两个初始点。

🔗 **知识点** 二分法/牛顿法/割线法属"函数逼近/导数类"一维方法; 抛物线法(二次插值)用三点函数值拟合 $p(x) = \alpha x^2 + \beta x + \gamma$, 极小 $x_{k+1} = -\beta/2\alpha$ 。相关: [[第9章 牛顿类算法]]。

例7.6 非精确线搜索的必要性 (仅单调下降不够) ★★★

🔴 **题目** $\min f(x) = x^2$, $x^0 = 1$, $d^k = -\text{sign}(x^k)$, 仅要求 $f(x^k + \alpha_k d^k) < f(x^k)$ 。取两种步长说明仅单调下降为何不收敛。

✅ **解答**

- $\alpha_{k,1} = \frac{1}{3^{k+1}} \rightarrow x_1^k = \frac{1}{2}(1 + \frac{1}{3^k}) \rightarrow \frac{1}{2} \neq 0$ 。函数值单调下降, 但极限 $\frac{1}{2}$ 不是极小点 (步长太小, 下降不充分)。
- $\alpha_{k,2} = 1 + \frac{2}{3^{k+1}} \rightarrow x_2^k = \frac{(-1)^k}{2}(1 + \frac{1}{3^k})$, 在原点左右振荡不收敛 (步长太大)。
- 结论: 仅"函数值单调下降"无法保证收敛, 必须加**充分下降**(控下界)和**充分移动**(防步长过小)约束 $\rightarrow$ Armijo/Goldstein/Wolfe 准则。

🔗 **知识点** 两个失败方向分别对应"下降量相对步长太小"和"步长过大来回跳", 正是三准则要堵的两个漏洞。

例7.7 Armijo 准则与回退法 ★★★★★

🔴 **题目** 写出 Armijo 准则及其几何含义, 说明为何取 $c_1 \in (0, \frac{1}{2}]$, 并给出回退法。

✅ **解答**

- **Armijo (充分下降)**: $f(x^k + \alpha d^k) \leq f(x^k) + c_1 \alpha \nabla f(x^k)^\top d^k$, $c_1 \in (0, 1)$ 。几何: $(\alpha, \phi(\alpha))$ 须落在直线 $l(\alpha) = \phi(0) + c_1 \alpha \phi'(0)$ 下方 ($\phi'(0) = \nabla f^\top d < 0$)。
- **为何 $c_1 \leq \frac{1}{2}$** : 对二次 $\phi(t) = \phi(0) + t\phi'(0) + \frac{t^2}{2}\phi''(0)$ ($\phi'' > 0$), 其精确极小 $t^* = -\phi'(0)/\phi''(0)$ 。代入下降条件得 $t \leq 2(1 - c_1)t^*$ 。要让最优步长 t^* 本身满足 Armijo, 需 $c_1 \leq \frac{1}{2}$; 否则 $c_1 > \frac{1}{2}$ 时 t^* 反被排除。实践建议 $c_1 \in [10^{-5}, 10^{-1}]$ 。
- **回退法**: $\alpha_k = \gamma^{j_0} \hat{\alpha}$, $j_0 = \min\{j: f(x^k + \gamma^j \hat{\alpha} d^k) \leq f(x^k) + c_1 \gamma^j \hat{\alpha} \nabla f^\top d^k\}$, $\gamma \in (0, 1)$ 。从大到小试探, 取首个满足 Armijo 的步长 (保证 α_k 尽量大)。因 d^k 下降, α 充分小时 Armijo 必成立, 算法有限步停。

🔗 **知识点** $\alpha = 0$ 也满足 Armijo 但无意义; 故单 Armijo 需配回退法 (隐式防过小)。实践给 α 加下界防过小。

例7.8 Goldstein 与 Wolfe 准则 ★★★★★

🔴 **题目** 写出 Goldstein 与 Wolfe 准则, 并说明 Wolfe 的优势。

✅ **解答**

- **Goldstein** ($c \in (0, \frac{1}{2})$):
 $f(x^k + \alpha d^k) \leq f(x^k) + c\alpha \nabla f^\top d^k$ (a), $f(x^k + \alpha d^k) \geq f(x^k) + (1 - c)\alpha \nabla f^\top d^k$ (b).
 (a) 充分下降, (b) 防步长太小。缺点: 可能把精确极小点排除在可接受区间外。
- **Wolfe** ($0 < c_1 < c_2 < 1$):
 $f(x^k + \alpha d^k) \leq f(x^k) + c_1 \alpha \nabla f^\top d^k$ (2a), $\nabla f(x^k + \alpha d^k)^\top d^k \geq c_2 \nabla f(x^k)^\top d^k$ (2b).
- **Wolfe 优势**: (2b) 是曲率条件——要求 $\phi'(\alpha) \geq c_2 \phi'(0)$ (切线斜率不太负)。精确极小 α^* 处 $\phi'(\alpha^*) = 0$ 恒满足 (2b), 再取较小 c_1 也满足 (2a), 故 **Wolfe 可接受区间通常包含精确解**, 不像 Goldstein 会误删。

🔗 **知识点** 三准则都含 Armijo (a); 区别在"防步长过小"机制: Goldstein 用函数值下界, Wolfe 用梯度 (曲率) 条件。Wolfe 是拟牛顿法保证 B_k 正定的标准搭配。相关: [[第10章 拟牛顿类算法]]。

例7.9 非单调线搜索准则 ★★

🔗 **题目** 写出 Grippo 和 Zhang-Hager 非单调准则, 并说明与 Armijo 的关系。

✅ **解答**

- **Grippo:** $f(\mathbf{x}^k + \alpha \mathbf{d}^k) \leq \max_{0 \leq j \leq \min\{k, M\}} f(\mathbf{x}^{k-j}) + c_1 \alpha \nabla f^\top \mathbf{d}^k$ 。只要求比前至多 M 步内的最大函数值有下降, 不要求 $f(\mathbf{x}^k)$ 单调。
- **Zhang-Hager:** $f(\mathbf{x}^k + \alpha \mathbf{d}^k) \leq C^k + c_1 \alpha \nabla f^\top \mathbf{d}^k$, 参照值 C^k 递推 $C^0 = f(\mathbf{x}^0)$, $C^{k+1} = \frac{1}{Q^{k+1}}(\eta Q^k C^k + f(\mathbf{x}^{k+1}))$, $Q^0 = 1$, $Q^{k+1} = \eta Q^k + 1$, $\eta \in (0, 1)$ 。 C^k 是历史函数值的加权凸组合。
- **关系:** $\eta = 0$ (或 Grippo 中 $M = 0$) 时退化为标准 Armijo。

🔗 **知识点** 非单调准则放宽单调性, 允许函数值暂时上升, 有助跳出狭窄山谷、提升实际效率 (尤其配合 BB 步长)。相关: [[第8章 梯度类算法]] BB 方法。

例7.10 Zoutendijk 定理与全局收敛 ★★★

🔗 **题目** 叙述 Zoutendijk 定理, 并由它推出线搜索算法 $\nabla f(\mathbf{x}^k) \rightarrow \mathbf{0}$ 的条件。

✅ **解答**

- **Zoutendijk 定理:** 迭代 $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$, α_k 满足 Wolfe, f 下有界、梯度 L -Lipschitz, 则 $\sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla f(\mathbf{x}^k)\|^2 < +\infty$, $\cos \theta_k = \frac{-\nabla f(\mathbf{x}^k)^\top \mathbf{d}^k}{\|\nabla f(\mathbf{x}^k)\| \|\mathbf{d}^k\|}$ 。
- **证明梗概:** Wolfe (2b) + Lipschitz 给 $\alpha_k \geq \frac{c_2-1}{L} \frac{\nabla f^\top \mathbf{d}^k}{\|\mathbf{d}^k\|^2}$; 代入 (2a) 得 $f(\mathbf{x}^{k+1}) \leq f(\mathbf{x}^k) - c_1 \frac{1-c_2}{L} \cos^2 \theta_k \|\nabla f(\mathbf{x}^k)\|^2$; 对 k 求和, f 下有界 $\Rightarrow$ 级数收敛。
- **推论:** 若存在 $\gamma > 0$ 使 $\theta_k < \frac{\pi}{2} - \gamma$ (下降方向与负梯度夹角不趋于正交, $\cos \theta_k > \sin \gamma > 0$), 则 $\sum \|\nabla f(\mathbf{x}^k)\|^2 < \infty$, 故 $\lim_{k \rightarrow \infty} \nabla f(\mathbf{x}^k) = \mathbf{0}$ 。

🔗 **知识点** 收敛性本质: 方向不能趋于与梯度正交 (否则一阶下降量趋零)。注意结论只是 $\nabla f \rightarrow \mathbf{0}$ (驻点), 可能是局部极小、鞍点、或既非极小也非鞍点; 不涉及收敛速度 (速度由 $\mathbf{d}^k$ 决定)。适用于精确线搜索、Goldstein、Wolfe。相关: [[第8章 梯度类算法]]。

第8章 梯度类算法

对应课件 2-2 梯度类算法。搜索方向固定取负梯度 $\mathbf{d}^k = -\nabla f(\mathbf{x}^k)$, 迭代 $\mathbf{x}^{k+1} = \mathbf{x}^k - \alpha_k \nabla f(\mathbf{x}^k)$ 。本章核心: 步长选择 (固定/精确/BB)、最速下降的锯齿现象、条件数与收敛速度、 L -光滑性的收敛性证明。

例8.1 梯度法的两种理解 ★★

🔗 **题目** 从 Taylor 展开和"二次近似最小化"两个角度推导梯度法迭代式。

✅ **解答**

- **Taylor 视角:** $\phi(\alpha) = f(\mathbf{x}^k + \alpha \mathbf{d}^k) = f(\mathbf{x}^k) + \alpha \nabla f(\mathbf{x}^k)^\top \mathbf{d}^k + O(\alpha^2)$ 。由 Cauchy 不等式, α 小时令一阶项最负的单位方向是 $\mathbf{d}^k = -\nabla f(\mathbf{x}^k)$ (下降最快)。

- **二次近似视角**: 用 $\frac{1}{\alpha_k} I$ 近似 Hessian:

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} \left\{ f(\mathbf{x}^k) + \nabla f(\mathbf{x}^k)^\top (\mathbf{x} - \mathbf{x}^k) + \frac{1}{2\alpha_k} \|\mathbf{x} - \mathbf{x}^k\|^2 \right\} = \arg \min_{\mathbf{x}} \|\mathbf{x} - (\mathbf{x}^k - \alpha_k \nabla f(\mathbf{x}^k))\|^2 = \mathbf{x}^k - \alpha_k \nabla f(\mathbf{x}^k).$$

🔗 **知识点** "二次近似"视角把梯度法看作每步用 $\frac{1}{\alpha_k} I$ 代替真实 Hessian 的牛顿法, 为 BB 方法、近端梯度埋下伏笔。相关: [[第9章 牛顿类算法]]。

例8.2 固定步长对收敛的影响 ★★★

🔴 **题目** $f(x) = \frac{1}{2}x^2$, $\nabla f = x$, 固定步长梯度法 $x_{k+1} = x_k(1 - \alpha)$ 。分析 $\alpha = 1.5, 2.5, 2$ 三种情形。

✅ **解答** $x_k = (1 - \alpha)^k x_0$ 。

- $\alpha = 1.5$: $x_k = (-0.5)^k x_0 \rightarrow 0$, **收敛** (振荡衰减)。
- $\alpha = 2.5$: $x_k = (-1.5)^k x_0 \rightarrow \pm\infty$, **发散**。
- $\alpha = 2$: $x_k = (-1)^k x_0$, 在 $\pm x_0$ **振荡** 不收敛。
- 此例 $L = 1$, 收敛要求 $0 < \alpha < 2/L = 2$, 与现象吻合。

🔗 **知识点** 固定步长须 $\alpha < 2/L$; 步长选取对梯度法影响巨大。相关: 例8.9 L -光滑收敛条件。

例8.3 最速下降法与锯齿现象 ★★★★★

🔴 **题目** 用最速下降法解 $\min f(\mathbf{x}) = \frac{x_1^2}{2} + x_2^2$, 初始点 $\mathbf{x}^{(0)} = (2, 1)^\top$ 。求迭代通式, 并解释锯齿。

✅ **解答**

- $\nabla f = (x_1, 2x_2)^\top$, $\nabla f(\mathbf{x}^{(0)}) = (2, 2)^\top$, $\mathbf{d}^{(0)} = (-2, -2)^\top$ 。
- 精确线搜索: $\phi(\alpha) = 2(1 - \alpha)^2 + (1 - 2\alpha)^2$, $\phi'(\alpha) = -4(1 - \alpha) - 4(1 - 2\alpha) = 0 \Rightarrow \alpha_0 = \frac{2}{3}$ 。
- $\mathbf{x}^{(1)} = (2, 1)^\top + \frac{2}{3}(-2, -2)^\top = (\frac{2}{3}, -\frac{1}{3})^\top$ 。
- 递推得 $\boxed{\mathbf{x}^{(k)} = \left(\frac{2}{3^k}, \frac{(-1)^k}{3^k} \right)^\top} \rightarrow (0, 0)^\top$ 。
- **锯齿**: 精确线搜索下 $\frac{d}{d\alpha} f(\mathbf{x}^k + \alpha \mathbf{d}^k)|_{\alpha_k} = (\mathbf{d}^k)^\top \nabla f(\mathbf{x}^{k+1}) = 0$, 即相邻方向**正交** $\mathbf{d}^{(k)} \perp \mathbf{d}^{(k+1)}$ 。靠近极小点时来回折返、移动量缩短, 收敛变慢。

🔗 **知识点** 最速下降"相邻方向正交"是其本质缺陷 (zigzag)。椭圆等高线越扁 (条件数大), 锯齿越严重。相关: 例8.4 条件数。

例8.4 二次函数精确步长与条件数收敛 ★★★★★

🔴 **题目** $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top A \mathbf{x} - \mathbf{b}^\top \mathbf{x}$ (A 对称正定)。给出最速下降精确步长, 并写出按 A -范数的收敛率。

✅ **解答**

- $\mathbf{g}_k = \nabla f = A\mathbf{x}^k - \mathbf{b}$, 精确步长 (例7.2 特例)
- $$\alpha_k = \frac{\mathbf{g}_k^\top \mathbf{g}_k}{\mathbf{g}_k^\top A \mathbf{g}_k}.$$

- **收敛定理** (用 Kantorovich 不等式):

$$\|\mathbf{x}^{k+1} - \mathbf{x}^*\|_A^2 \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^2 \|\mathbf{x}^k - \mathbf{x}^*\|_A^2, \quad \|\mathbf{x}\|_A = \sqrt{\mathbf{x}^\top A \mathbf{x}},$$

λ_1, λ_n 为 A 最大/最小特征值。Q-线性收敛。

- 用条件数 $\kappa = \lambda_1/\lambda_n$: 率 = $\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} = 1 - \frac{2}{1 + \kappa}$ 。

- 特例: $A = I$ ($\kappa = 1$) 时 $\alpha_k = 1$, 一步到位 ($x^{(1)} = b = x^*$)。

🔗 知识点 条件数 κ 越大、椭圆越扁、收敛越慢。例: $\kappa = 1$ 需 1 步, $\kappa = 100$ 需约 576 步, $\kappa = 1000$ 需约 5751 步 (达 10^{-6})。Hessian 病态 $\Rightarrow$ 优化病态。相关: [[第11章 共轭梯度法]] 改善病态。

例8.5 二次型对称化 ★★

🔴 题目 将 $f(x) = x^T \begin{bmatrix} 4 & 2\sqrt{2} \\ 0 & 5 \end{bmatrix} x + x^T \begin{bmatrix} 3 \\ 6 \end{bmatrix} + 24$ 化为对称矩阵的标准二次型 $\frac{1}{2}x^T Ax + \dots$ 。

✅ 解答 对二次型 $x^T M x$ (M 不对称), 因标量转置不变, $x^T M x = \frac{1}{2}x^T (M + M^T)x$, 故 $A = M + M^T$ 。

$$A = \begin{bmatrix} 4 & 2\sqrt{2} \\ 0 & 5 \end{bmatrix} + \begin{bmatrix} 4 & 0 \\ 2\sqrt{2} & 5 \end{bmatrix} = \begin{bmatrix} 8 & 2\sqrt{2} \\ 2\sqrt{2} & 10 \end{bmatrix}, \quad f(x) = \frac{1}{2}x^T \begin{bmatrix} 8 & 2\sqrt{2} \\ 2\sqrt{2} & 10 \end{bmatrix} x + x^T \begin{bmatrix} 3 \\ 6 \end{bmatrix} + 24.$$

🔗 知识点 研究二次函数总可设 A 对称 (不失一般性), 便于谈特征值、正定性、条件数。

例8.6 Kantorovich 不等式 ★★

🔴 题目 叙述 Kantorovich 不等式, 并说明它在最速下降收敛证明中的作用。

✅ 解答 对对称正定 Q (特征值 $\lambda_1 \geq \dots \geq \lambda_n > 0$), 任意 $x \neq 0$:

$$\frac{(x^T x)^2}{(x^T Q x)(x^T Q^{-1} x)} \geq \frac{4\lambda_1 \lambda_n}{(\lambda_1 + \lambda_n)^2}.$$

- 证明要点: 对角化后写成 $\frac{1}{(\sum \xi_i \lambda_i)(\sum \xi_i / \lambda_i)}$ ($\xi_i \geq 0, \sum \xi_i = 1$); 用 $u(t) = c/t + t/c$ 在 $[\lambda_n, \lambda_1]$ 上的凸性 (最大值在端点, 取 $c = \sqrt{\lambda_1 \lambda_n}$ 得下界)。
- 作用: 令 $E(x) = \frac{1}{2}(x - x^*)^T Q (x - x^*)$, 则 $E(x^{k+1}) = \left(1 - \frac{(g_k^T g_k)^2}{(g_k^T Q g_k)(g_k^T Q^{-1} g_k)}\right) E(x^k) \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n}\right)^2 E(x^k)$, 得出例8.4的线性收敛率。

🔗 知识点 Kantorovich 不等式把"每步下降比例"下界用条件数表达, 是最速下降收敛分析的核心工具。

例8.7 梯度 Lipschitz 连续 (L -光滑) 与二次上界 ★★★★★

🔴 题目 定义 L -光滑, 证明二次上界引理, 并给出常见 L -光滑函数的 L 。

✅ 解答

- 定义: $\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$ 。二次连续可微时等价于 $\|\nabla^2 f(x)\| \leq L$, 即 $-LI \preceq \nabla^2 f \preceq LI$ 。
- 常见 L : 线性函数 $a^T x$ 是 0-光滑; 二次 $\frac{1}{2}x^T A x - b^T x$ 是 $\|A\|$ -光滑 ($\frac{1}{2}x^T Q x$ 取 $L = \lambda_{\max}(Q)$); $\|x\|^2$ 是 2-光滑; $x \log x$ 不是 L -光滑 ($f'' = 1/x$ 在 $x \rightarrow 0$ 无界)。
- 二次上界引理: L -光滑 $\Rightarrow$

$$f(y) \leq f(x) + \nabla f(x)^T (y - x) + \frac{L}{2}\|y - x\|^2.$$
 证明: $g(t) = f(x + t(y - x))$, $f(y) - f(x) - \nabla f(x)^T (y - x) = \int_0^1 (g'(t) - g'(0))dt \leq \int_0^1 L\|y - x\|^2 t dt = \frac{L}{2}\|y - x\|^2$ 。

🔗 知识点 二次上界 = "f 增长不超过二次", 是几乎所有梯度法收敛证明的基石。另一引理: 有全局极小时 $\frac{1}{2L}\|\nabla f(x)\|^2 \leq f(x) - f(x^*) \leq \frac{L}{2}\|x - x^*\|^2$ 。相关: 例8.8、8.9。

例8.8 固定步长梯度法的收敛性 (非凸 L -光滑) ★★★

🔴 题目 ∇f 是 L -Lipschitz、 $f \geq f_{\min}$ 。证明 $0 < \alpha < \frac{2}{L}$ 时极限点是驻点； $\alpha = \frac{1}{L}$ 时给出 $\min_k \|\nabla f\|^2$ 的复杂度。

✅ 解答

- 用二次上界, $x^{k+1} = x^k - \alpha \nabla f(x^k)$:
 $f(x^{k+1}) \leq f(x^k) - \alpha \|\nabla f(x^k)\|^2 + \frac{1}{2} L \alpha^2 \|\nabla f(x^k)\|^2 = f(x^k) + \alpha(\frac{1}{2} L \alpha - 1) \|\nabla f(x^k)\|^2$.
- $\alpha(1 - \frac{1}{2} L \alpha) > 0$ (即 $0 < \alpha < \frac{2}{L}$) $\Rightarrow f(x^k)$ 非增。裂项求和:
 $\alpha(1 - \frac{1}{2} L \alpha) \sum_{k=0}^N \|\nabla f(x^k)\|^2 \leq f(x^0) - f_{\min} < \infty \Rightarrow \lim_{k \rightarrow \infty} \nabla f(x^k) = 0$.
- $\alpha = \frac{1}{L}$ (右端最小, 下降最多 $f(x^{k+1}) \leq f(x^k) - \frac{1}{2L} \|\nabla f\|^2$):
 $\min_{0 \leq k \leq N} \|\nabla f(x^k)\|^2 \leq \frac{1}{N} \sum_{k=0}^N \|\nabla f(x^k)\|^2 \leq \frac{2L(f(x^0) - f_{\min})}{N}$.
- 达 $\|\nabla f\| \leq \varepsilon$ 需 $O(1/\varepsilon^2)$ 次迭代 (次线性)。

🔗 知识点 非凸 L -光滑: 梯度法只保证收敛到驻点, 复杂度 $O(1/\varepsilon^2)$ 。这是深度学习训练分析的基础。

例8.9 凸/强凸情形的收敛速度总结 ★★★

🔴 题目 总结固定步长梯度法在三类函数上的步长、误差度量与收敛速度。

✅ 解答

设定	步长 α	误差度量	收敛率	达 ε 迭代数
非凸 + 光滑	$1/L$	$\min_k \ \nabla f\ ^2$	$O(1/k)$ 次线性	$O(1/\varepsilon^2)$
凸 + 光滑	$1/L$	$f(x^k) - f^*$	$O(1/k)$ 次线性	$O(1/\varepsilon)$
强凸 + 光滑	$2/(m + L)$	$\ x^k - x^*\ $	$(\frac{\gamma-1}{\gamma+1})^k$ 线性, $\gamma = L/m$	$O(\log \frac{1}{\varepsilon})$

- 凸情形证明要点: 用凸性 $f(x) \leq f^* + \nabla f^\top(x - x^*)$ 与 $0 < \alpha \leq \frac{1}{L}$, 得 $f(\tilde{x}) \leq f^* + \frac{1}{2\alpha} (\|x - x^*\|^2 - \|\tilde{x} - x^*\|^2)$, 裂项求和 $f(x^k) - f^* \leq \frac{1}{2k\alpha} \|x^0 - x^*\|^2$.
- 强凸证明要点: $x^{k+1} - x^* = (I - \alpha H_k)(x^k - x^*)$, $H_k = \int_0^1 \nabla^2 f dt$, $m \preceq H_k \preceq L$, 最优 $\alpha^* = \frac{2}{m+L}$ 使 $\|I - \alpha H_k\| \leq \frac{\gamma-1}{\gamma+1}$.

🔗 知识点 强凸 + 光滑才有线性收敛 ($O(\log \frac{1}{\varepsilon})$) ; 仅凸则次线性 $O(1/\varepsilon)$ 。 m =强凸参数, $\gamma = L/m$ 是条件数的推广。相关: [[第9章 牛顿类算法]] 二次收敛。

例8.10 Barzilai-Borwein (BB) 方法 ★★★

🔴 题目 推导 BB 方法的两种步长, 说明其原理与特点。

✅ 解答 BB 用对角阵 $B^k = \frac{1}{\alpha_k} I$ 近似 Hessian, 尽量满足拟牛顿 (割线) 条件 $B^k s^{k-1} \approx y^{k-1}$, 其中 $s^{k-1} = x^k - x^{k-1}$, $y^{k-1} = \nabla f(x^k) - \nabla f(x^{k-1})$ 。解两个最小二乘
 $\min_{\alpha} \|\alpha y^{k-1} - s^{k-1}\|^2 \Rightarrow \alpha_{\text{BB1}}^k = \frac{(s^{k-1})^\top y^{k-1}}{(y^{k-1})^\top y^{k-1}}, \quad \min_{\alpha} \|y^{k-1} - \alpha^{-1} s^{k-1}\|^2 \Rightarrow \alpha_{\text{BB2}}^k = \frac{(s^{k-1})^\top s^{k-1}}{(s^{k-1})^\top y^{k-1}}$.

- 特点: 仅用相邻两步梯度与点, 无需线搜索即得步长; 步长可能过大/过小, 需截断 $\alpha_m \leq \alpha_k \leq \alpha_M$; BB 是非单调方法, 常配非单调线搜索。
- 数值: $\min \frac{1}{2} x^\top A x$, $A = \text{diag}(1, 5, 10, 20)$, 初始 $(1, 1, 1, 1)$: SD 需 179 次, BB1 仅 36 次、BB2 仅 44 次。对正定二次有 R-线性 (局部 Q-超线性) 收敛。

🔗 **知识点** BB 方法本质是“用拟牛顿割线条件确定标量步长”，比最速下降快得多，是常用加速策略。相关：[[第10章 拟牛顿类算法]] 割线条件、[[第7章 线搜索方法]] 非单调准则。

例8.11 光滑化求解 LASSO ★★★

🔗 **题目** LASSO $\min \frac{1}{2} \|Ax - b\|^2 + \mu \|x\|_1$ 含不可微项，如何用梯度法求解？

✅ **解答**

- $\|x\|_1$ 不光滑（在 0 处不可导），不能直接用梯度法。用 **Huber 光滑化** 逐分量替代 $|x_i|$ ：
$$l_\delta(x) = \begin{cases} \frac{1}{2\delta} x^2, & |x| < \delta, \\ |x| - \frac{\delta}{2}, & \text{其他}. \end{cases}$$

 $\delta \rightarrow 0$ 时 $l_\delta \rightarrow |x|$ 。光滑化问题 $\min f_\delta(x) = \frac{1}{2} \|Ax - b\|^2 + \mu \sum_i l_\delta(x_i)$ 。
- 梯度 $\nabla f_\delta = A^\top(Ax - b) + \mu \nabla L_\delta$ ，其中 $(\nabla L_\delta)_i = \text{sign}(x_i)$ ($|x_i| > \delta$) 或 x_i/δ ($|x_i| \leq \delta$)。
- f_δ 是 L -光滑， $L = \|A^\top A\|_2 + \frac{\mu}{\delta}$ 。固定步长需 $\leq \frac{1}{L}$ ； δ 越小则 L 越大、步长须越小。

🔗 **知识点** 不可微问题的光滑化思路：用 Huber 函数逼近 ℓ_1 ，代价是 δ 小则 L 大、收敛慢。更彻底的做法是近端梯度（不在本课程梯度类范围）。相关：[[第3章 凸优化问题]] LASSO/基追踪。

第9章 牛顿类算法

对应课件 **2-3 牛顿类算法**。核心思想：用二阶 Taylor 近似，牛顿方向 $d^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$ 。优点：局部 Q-二次收敛、自适应曲率、对正定二次一步到位；缺点：需 Hessian、可能非正定/奇异、全局不稳定。修正：阻尼/修正牛顿、非精确牛顿；最小二乘专用 Gauss-Newton / LM。

例9.1 牛顿法解非线性方程（一维） ★★★

🔗 **题目** 用牛顿法 $x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$ ：(1) 求 $x^4 - x - 2 = 0$ 在 1.5 附近的根；(2) 求 $x^2 - c = 0$ 的正根；(3) 对 $4x^4 - 6x^2 - \frac{11}{4} = 0$ 取 $x_0 = \frac{1}{2}$ 会怎样？

✅ **解答**

- (1) $x_{k+1} = \frac{3x_k^4 + 2}{4x_k^3 - 1}$ ， $x_0 = 1.5 \rightarrow 1.375 \rightarrow 1.3538 \rightarrow 1.3532 \rightarrow 1.3532$ （4步收敛）。
- (2) $x_{k+1} = x_k - \frac{x_k^2 - c}{2x_k} = \frac{1}{2}(x_k + \frac{c}{x_k})$ ，即 **巴比伦法**。单根 $\Rightarrow$ 局部 2 阶收敛，在 $(0, +\infty)$ 全局收敛，是算 $\sqrt{c}$ 的稳定高效方法。
- (3) $x_{i+1} = x_i - \frac{4x_i^4 - 6x_i^2 - 11/4}{16x_i^3 - 12x_i}$ ， $x_0 = \frac{1}{2} \rightarrow -\frac{1}{2} \rightarrow \frac{1}{2} \rightarrow \dots$ 在 $\pm \frac{1}{2}$ 间循环，二者都不是根，**牛顿法失败**。

🔗 **知识点** Newton-Raphson 视初始点与函数而收敛/循环/发散三种结局。局部收敛、依赖初值、需算导数。相关：例9.3 一元求极小。

例9.2 牛顿法解非线性方程组 ★★

🔗 **题目** 用牛顿法解 $f(x) = \begin{pmatrix} x_1 + 2x_2 - 2 \\ x_1^2 + 4x_2^2 - 4 \end{pmatrix} = 0$ ，初值 $x_0 = (1, 2)^\top$ 。

✅ **解答** Jacobi $J_f = \begin{bmatrix} 1 & 2 \\ 2x_1 & 8x_2 \end{bmatrix}$ 。迭代 $x_{k+1} = x_k - J_f(x_k)^{-1} f(x_k)$ 。

- $J_f(x_0) = \begin{bmatrix} 1 & 2 \\ 2 & 16 \end{bmatrix}$, $f(x_0) = (3, 13)^\top$, 解 $J_f s_0 = f$ 得 $s_0 = (1.83, 0.58)^\top$, $x_1 = (-0.83, 1.42)^\top$ 。
- 继续 $x_2 = (-0.19, 1.10)^\top \rightarrow x_3 = (-0.02, 1.01)^\top \rightarrow x_4 = (0, 1)^\top$ 。

🔗 **知识点** 每步解一个 n 维线性方程组 $J_f s = f$, n 大时计算量大。相关: [[第7章 线搜索方法]] 解非线性方程组。

例9.3 牛顿法求一元函数极小点 ★★★

🔴 **题目** 用牛顿法求 $f(x) = \frac{1}{2}x^2 - \sin x$ 极小, $x^{(0)} = 0.5$ 。

✅ **解答** $f' = x - \cos x$, $f'' = 1 + \sin x$, 迭代 $x^{(k+1)} = x^{(k)} - \frac{f'}{f''}$ 。

- $x^{(1)} = 0.5 - \frac{-0.3775}{1.479} = 0.7552$; $x^{(2)} = 0.7391$; $x^{(3)} = 0.7390$; $x^{(4)} = 0.7390$ 。
- 收敛, $f'(x^{(4)}) \approx -8.6 \times 10^{-6} \approx 0$, $f'' = 1.673 > 0 \Rightarrow$ 严格极小点。
- **失败情形**: $f(x) = -x^4 + 12x^3 - 47x^2 + 60x$, $x_0 = 3$ 收敛到局部极小, $x_0 = 5$ 却收敛到局部极大 ($f'' < 0$ 区域, 二次近似开口向下)。

🔗 **知识点** 一元牛顿求极小 $x^{(k+1)} = x^{(k)} - f'/f''$ 要求 $f'' > 0$ 才向极小走; 否则可能奔向极大。相关: [[第7章 线搜索方法]] 牛顿/割线。

例9.4 经典牛顿法 (多元) 与下降性 ★★★★★

🔴 **题目** 推导经典牛顿法迭代式, 并证明 $\nabla^2 f(x^k) \succ 0$ 时牛顿方向是下降方向。

✅ **解答**

- 二阶 Taylor $f(x^k + d) \approx f + \nabla f^\top d + \frac{1}{2} d^\top \nabla^2 f d$, 对 d 求极小得 **牛顿方程** $\nabla^2 f(x^k) d^k = -\nabla f(x^k)$, $\nabla^2 f$ 非奇异时 $x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$ 。
- **下降性证明**: $d^k = -[\nabla^2 f]^{-1} g^k$ ($g^k = \nabla f \neq 0$)。 $\phi(\alpha) = f(x^k + \alpha d^k)$, $\phi'(0) = (g^k)^\top d^k = -(g^k)^\top [\nabla^2 f]^{-1} g^k < 0$ (正定阵之逆仍正定)。故 d^k 下降。
- **几何**: $\nabla^2 f \succ 0$ 时二次近似水平集为椭圆, 牛顿步直指椭圆中心; 在平坦方向迈大步、陡峭方向迈小步, 避免梯度法的"之"字震荡。

🔗 **知识点** 牛顿方向 = 梯度被 Hessian 逆"预条件", 自适应曲率。 $\nabla^2 f$ 非正定时牛顿方向不一定下降——这是修正牛顿的动机。相关: [[第8章 梯度类算法]] 锯齿。

例9.5 正定二次函数牛顿法一步到位 ★★★

🔴 **题目** 证明对 $f(x) = \frac{1}{2} x^\top Q x - x^\top b$ (Q 正定), 牛顿法任意初值一步收敛。并求 $\min x_1^2 + x_2^2 + x_1 x_2 + 2x_1 - 3x_2$ ($x^{(0)} = (0, 0)$)。

✅ **解答**

- $\nabla f = Qx - b$, $\nabla^2 f = Q$ 。 $x^{(1)} = x^{(0)} - Q^{-1}(Qx^{(0)} - b) = Q^{-1}b = x^*$ 。 **一步到位**。
- 具体例: $\nabla f(0) = (2, -3)^\top$, $\nabla^2 f = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$, 解 $\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} d = \begin{pmatrix} -2 \\ 3 \end{pmatrix}$ 得 $d^{(0)} = (-\frac{7}{3}, \frac{8}{3})^\top$, $x^{(1)} = (-\frac{7}{3}, \frac{8}{3})^\top$ 。 $\nabla f(x^{(1)}) = 0$, 即为解。

🔗 **知识点** 二次函数牛顿法一步收敛（对比最速下降的锯齿无穷迭代），体现二阶信息威力。相关：[[第8章 梯度类算法]] 例8.3。

例9.6 经典牛顿法的局部二次收敛 ★★★★★

🔴 **题目** 叙述并证明经典牛顿法的局部 Q-二次收敛定理。

✅ **解答** **定理**： f 二阶连续可微，Hessian 在 x^* 邻域 L -Lipschitz, $\nabla f(x^*) = 0$, $\nabla^2 f(x^*) \succ 0$ 。则初值足够近时 $\{x^k\}$ 收敛到 x^* ，且 Q-二次收敛， $\|\nabla f(x^k)\|$ 也 Q-二次收敛到 0。

- **证明要点**：由 $\nabla f(x^*) = 0$ ，
$$x^{k+1} - x^* = [\nabla^2 f(x^k)]^{-1} [\nabla^2 f(x^k)(x^k - x^*) - (\nabla f(x^k) - \nabla f(x^*))].$$
- 用积分中值 $\nabla f(x^k) - \nabla f(x^*) = \int_0^1 \nabla^2 f(x^k + t(x^* - x^k))(x^k - x^*)dt$ 与 Lipschitz：
$$\|\nabla^2 f(x^k)(x^k - x^*) - (\nabla f(x^k) - \nabla f(x^*))\| \leq \frac{L}{2} \|x^k - x^*\|^2.$$
- 邻域内 $\|[\nabla^2 f(x^k)]^{-1}\| \approx \|[\nabla^2 f(x^*)]^{-1}\|$ ，得 $\|x^{k+1} - x^*\| \leq \frac{L}{2} \|[\nabla^2 f(x^*)]^{-1}\| \|x^k - x^*\|^2$ 。当 $\frac{L}{2} \|[\nabla^2 f(x^*)]^{-1}\| \|x^0 - x^*\| \leq 1$ 时迭代点不离邻域，Q-二次收敛。

🔗 **知识点** 二次收敛 $\Rightarrow$ 达 $\|x^k - x^*\| \leq \epsilon$ 仅需 $O(\log \log \frac{1}{\epsilon})$ 次迭代 ($\approx$ 常数)。需 Hessian Lipschitz 连续、 $\nabla^2 f(x^*)$ 正定。相关：[[第7章 线搜索方法]] 收敛速度。

例9.7 牛顿法的失败情形 ★★★

🔴 **题目** $\min f(x) = 4x_1^2 + x_2^2 - x_1^2 x_2$ ，初值 $x_A = (1, 1)$, $x_B = (3, 4)$, $x_C = (2, 0)$ 分别会怎样？

✅ **解答** $\nabla f = (8x_1 - 2x_1 x_2, 2x_2 - x_1^2)^\top$, $\nabla^2 f = \begin{bmatrix} 8 - 2x_2 & -2x_1 \\ -2x_1 & 2 \end{bmatrix}$ 。

- $x_A = (1, 1)$ ：5 次迭代收敛到 $(0, 0)$ (各点 Hessian 正定) $\Rightarrow$ **极小点**。
- $x_B = (3, 4)$ ：收敛到 $(2\sqrt{2}, 4)$ $\Rightarrow$ **鞍点**。
- $x_C = (2, 0)$ ： $\nabla^2 f = \begin{bmatrix} 8 & -4 \\ -4 & 2 \end{bmatrix}$ **奇异** ($\det = 16 - 16 = 0$)，无法继续。
- 结论：牛顿法可能收敛到极小/极大/鞍点，或 Hessian 奇异而中断。

🔗 **知识点** 牛顿法不足：每步解 n 维方程组（高维贵）；Hessian 难算难存；非正定时方向不一定下降；半正定奇异时退化为 Q-线性；固定 $\alpha = 1$ 可能发散（如 $\min \sqrt{x_1^2 + 1} + \sqrt{x_2^2 + 1}$ 纯牛顿从 $(10, 10)$ 发散到 $\inf$ ）。需阻尼/修正补救。

例9.8 阻尼牛顿法与修正牛顿法 ★★★

🔴 **题目** 说明阻尼牛顿法与修正牛顿法如何改善经典牛顿法的两大缺陷。

✅ **解答**

- **阻尼牛顿法**：解牛顿方程得方向 d^k ，再用线搜索 (Armijo/Goldstein/Wolfe) 定步长 α_k , $x^{k+1} = x^k + \alpha_k d^k$ 。当 $\nabla^2 f \succ 0$ 、 $\nabla f \neq 0$ 时由下降性保证 $f(x^{k+1}) < f(x^k)$ ，解决“固定步长不稳定/发散”。例： $\min \sqrt{x_1^2 + 1} + \sqrt{x_2^2 + 1}$ 从 $(10, 10)$ ，阻尼牛顿 17 步收敛到 2（纯牛顿发散）。
- **修正牛顿法**：当 $\nabla^2 f$ 非正定时，取 E^k 使 $B^k = \nabla^2 f(x^k) + E^k \succ 0$ 且条件数较小，解 $B^k d^k = -\nabla f$ 。 E^k 选取要求：条件数低、对 $\nabla^2 f$ 改动小、计算代价低。
- E^k **显式取法**：特征分解 $\nabla^2 f = Q\Lambda Q^\top$ ，取 $E^k = \tau_k I$ 则 $B^k = Q(\Lambda + \tau_k I)Q^\top$, $\tau_k = \max\{0, \delta$

$-\lambda_{\min}(\nabla^2 f)\}$ 。 $\lambda_{\min}$ 难算时改用 **Cholesky 增量法**：试探 $LL^T = \nabla^2 f + \tau_t I$ ，失败则 $\tau_{t+1} = \max\{\sigma\tau_t, \beta\}$ 增大重试。

- **全局收敛定理**：水平集紧、 $\kappa(B_k) = \|B_k\| \|B_k^{-1}\| \leq C$ 有界 $\Rightarrow \nabla f(x^k) \rightarrow 0$ 。

🔗 **知识点** 修正牛顿用"修正 Hessian 正定 + 线搜索"换来全局收敛； τ 大时退化为最速下降。相关：[[第7章 线搜索方法]]、[[第8章 梯度类算法]]。

例9.9 非精确牛顿法 ★★

🔴 **题目** 大规模问题如何避免精确解牛顿方程？写出非精确牛顿法及收敛速度。

✅ **解答**

- 用迭代法（如共轭梯度）近似解牛顿方程并提前停机，残差 $r^k: \nabla^2 f(x^k)d^k = -\nabla f(x^k) + r^k$ ，停机准则 $\|r^k\| \leq \eta_k \|\nabla f(x^k)\|$ (**强迫序列** η_k)。
- **收敛定理** ($\nabla^2 f(x^*) \succ 0$) :
 - $0 < \eta_k < t < 1 \Rightarrow Q$ -**线性**收敛；
 - $\eta_k \rightarrow 0 \Rightarrow Q$ -**超线性**收敛；
 - $\eta_k = O(\|\nabla f(x^k)\|)$ 且 Hessian Lipschitz $\Rightarrow Q$ -**二次**收敛。

🔗 **知识点** η_k 控制内层求解精度 $\rightarrow$ 外层收敛速度，"提前停机"省内层计算。Newton-CG 是典型。相关：[[第11章 共轭梯度法]]。

例9.10 Gauss-Newton 法求非线性最小二乘 ★★★★★

🔴 **题目** 最小二乘 $\min f(x) = \frac{1}{2} \sum_i r_i^2(x) = \frac{1}{2} \|r(x)\|^2$ 。写出梯度、Hessian、牛顿方程，并推导 Gauss-Newton 法。

✅ **解答**

- 记 Jacobi $J(x) = [\nabla r_1, \dots, \nabla r_m]^T$ 。
 $\nabla f = J^T r$, $\nabla^2 f = J^T J + \underbrace{\sum_i r_i \nabla^2 r_i}_{S(x)}$ 。
- 牛顿方程 $(J_k^T J_k + S_k)d = -J_k^T r_k$ ，每步算 S_k (m 个 $n \times n$ 阵) 很贵。
- **Gauss-Newton**：忽略 S_k ，解 $J_k^T J_k d^{GN} = -J_k^T r_k$ 。等价于线性化残差 $r(x_k + d) \approx r_k + J_k d$ 后解线性最小二乘 $\min_d \frac{1}{2} \|J_k d + r_k\|^2$ 。
- **下降性**： $(d^k)^T g_k = -\|J_k d^k\|^2 < 0$ (J_k 满秩、 $g_k \neq 0$ 时)。
- **收敛**： $S(x^*) = 0$ (零残差/线性问题) $\Rightarrow$ 二阶收敛； $S(x^*) \neq 0 \Rightarrow$ 线性收敛，随 $\|S(x^*)\|$ 增大变慢。
- **数值技巧**：直接解 GN 方程会平方条件数 $\text{cond}(J^T J) = \text{cond}^2(J)$ ；改用 J_k 的 **QR 分解** $R^k d = -(Q^k)^T r^k$ 更稳定。

🔗 **知识点** GN = 牛顿法在最小二乘上"用 $J^T J$ 近似 Hessian"，省二阶导。 $J^T J$ 必半正定。小残差问题 (S 小) 适用。相关：[[第8章 梯度类算法]]、应用：正弦拟合 $y = A \sin(\omega t + \phi)$ 。

例9.11 正弦拟合 (GN 应用) 与 LM 方法 ★★★

🔴 题目 用 GN 拟合 $y = A \sin(\omega t + \phi)$ (21 个数据点) ; 当 $J_k^T J_k$ 奇异时如何处理?

✅ 解答

- 决策变量 $x = (A, \omega, \phi)^T$, 残差 $r_i = y_i - A \sin(\omega t_i + \phi)$ 。 21×3 Jacobi:
 $J_{(i,1)} = -\sin(\omega t_i + \phi), \quad J_{(i,2)} = -t_i A \cos(\omega t_i + \phi), \quad J_{(i,3)} = -A \cos(\omega t_i + \phi)$.
GN 求得 $A = 2.01, \omega = 0.992, \phi = 0.541$, 拟合良好。
- LM (Levenberg-Marquardt) 方法:** GN 中 $J_k^T J_k$ 可能奇异, 改解
 $(J_k^T J_k + \nu_k I) d = -J_k^T r_k, \quad \nu_k \geq 0$.
 $\nu_k = 0$ 即 GN; $\nu_k > 0$ 时系数阵对称正定, 解唯一且为下降方向。 ν_k 大时趋于小步长最速下降, 小时趋于 GN——是 GN 与梯度法的"自适应插值"。

🔗 知识点 LM = 带阻尼参数 ν_k 的修正 GN, 保证正定与下降, 是非线性最小二乘的工业标准 (如 Ceres Solver) 。
相关: 例9.8 修正牛顿的 τI 思想一致。

第 10 章 拟牛顿类算法

拟牛顿法用对称正定矩阵 $H_k \approx [\nabla^2 f(x_k)]^{-1}$ (或 $B_k \approx \nabla^2 f(x_k)$) 代替真实 Hesse, 搜索方向 $d_k = -H_k \nabla f(x_k)$, 只用函数值与梯度, 避免计算 Hesse 与解线性方程组。核心是**割线方程** $B^{k+1} s^k = y^k$ (或 $H^{k+1} y^k = s^k$)。本章衔接 [[第9章 牛顿类算法]] (割线法是一维牛顿法的近似)、[[第7章 线搜索方法]] (Wolfe 准则保证曲率条件 $s^T y > 0$) 与 [[第8章 梯度类算法]] (BB 步长恰是 L-BFGS 的初始对角阵)。

例10.1 迭代下降方向的统一框架 ★★★

🔴 题目 迭代法 $x^{k+1} = x^k - t_k H_k \nabla f(x^k)$ 中, H_k 取不同矩阵分别对应什么算法? 并证明: 只要 H 对称正定且 $\nabla f(x) \neq 0$, 则 $-H \nabla f(x)$ 必为下降方向。

✅ 解答

H_k	算法	迭代格式
I (单位阵)	梯度下降法	$x^{k+1} = x^k - t_k \nabla f(x^k)$
$[\nabla^2 f(x^k)]^{-1}$	Newton 法	$x^{k+1} = x^k - t_k [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$
对称正定 $\approx [\nabla^2 f]^{-1}$, 逐次修正	拟牛顿法 (变尺度法)	$x^{k+1} = x^k - t_k H_k \nabla f(x^k)$

下降性证明: 方向 $d = -H \nabla f(x)$ 处的方向导数
 $[\nabla f(x)]^T d = -[\nabla f(x)]^T H \nabla f(x) < 0$,
最后一步因 H 对称正定且 $\nabla f(x) \neq 0$ 。故 d 是下降方向。■

🔗 知识点 拟牛顿法又称"变尺度法", H_k 称尺度矩阵。Newton 法的两大困难——Hesse 逆可能不存在、大规模下解线性方程组太贵——正是拟牛顿法的改进动机。保持 H_k 对称正定 $\Rightarrow$ 自动获得下降方向, 这是后续所有更新公式追求正定性的根本原因。

例10.2 一维割线法与割线方程 ★★★

🔴 题目 如何由一维牛顿法 $x^{k+1} = x^k - f'(x^k)/f''(x^k)$ 导出割线法? 并写出多维割线方程。

✅ 解答

一维: 用差商近似二阶导数

$$f''(x^k) \approx \frac{f'(x^k) - f'(x^{k-1})}{x^k - x^{k-1}} \triangleq b^k,$$

即 b^k 满足割线方程 $f'(x^k) - f'(x^{k-1}) = b^k(x^k - x^{k-1})$, 迭代式 $x^{k+1} = x^k - (b^k)^{-1}f'(x^k)$.

多维: 对 ∇f 在 x^{k+1} 处一阶 Taylor 展开

$$\nabla f(x) = \nabla f(x^{k+1}) + \nabla^2 f(x^{k+1})(x - x^{k+1}) + O(\|x - x^{k+1}\|^2),$$

令 $x = x^k$, 记点差 $s^k = x^{k+1} - x^k$ 、梯度差 $y^k = \nabla f(x^{k+1}) - \nabla f(x^k)$, 忽略高阶项得

$$\boxed{B^{k+1}s^k = y^k} \quad \text{或逆形式} \quad \boxed{H^{k+1}y^k = s^k}.$$

此即多维割线方程, 是所有拟牛顿更新公式必须满足的约束。

🔗 知识点 割线法是一维牛顿法 ([第9章 牛顿类算法] 例9.1) 的"无二阶导"近似, 收敛阶约 1.618 (黄金比, 超线性但低于牛顿的 2 阶)。多维割线方程是欠定的—— $n \times n$ 个未知数仅 n 个方程, 故满足它的修正矩阵**不唯一**, 这给了 SR1/BFGS/DFP 等不同取法的空间。

例10.3 曲率条件 $s^T y > 0$ 与 Wolfe 准则 ★★★★★

🔴 题目 为什么拟牛顿法要求曲率条件 $(s^k)^T y^k > 0$? 为什么 Wolfe 线搜索能保证它, 而仅用 Armijo 不能?

✅ 解答

必要性: 近似矩阵须正定才能保证下降与收敛 (正如牛顿法要 Hesse 正定)。若 B^{k+1} 正定, 则 $(s^k)^T B^{k+1} s^k > 0$ **↗** $B^{k+1}s^k = y^k$ $(s^k)^T y^k > 0$.
故 $s^T y > 0$ (曲率条件) 是 B^{k+1} 能保持正定的**必要条件**。

Wolfe 保证: Wolfe 第二条 (曲率条件) 为

$$\nabla f(x^k + \alpha d^k)^T d^k \geq c_2 \nabla f(x^k)^T d^k, \quad c_2 \in (0, 1).$$

即 $\nabla f(x^{k+1})^T s^k \geq c_2 \nabla f(x^k)^T s^k$ (因 $s^k = \alpha d^k$, 同号代入)。两边减 $\nabla f(x^k)^T s^k$:

$$(y^k)^T s^k \geq (c_2 - 1) \nabla f(x^k)^T s^k > 0,$$

因 $c_2 - 1 < 0$ 且 s^k 是下降方向 ($\nabla f(x^k)^T s^k < 0$), 两负相乘得正。■

仅用 Armijo (充分下降) 只约束函数值减少, 不约束端点梯度, 无法保证曲率条件。

🔗 知识点 曲率条件 $s^T y > 0$ 是拟牛顿法正定性的"生命线", 串起 [第7章 线搜索方法] 的 Wolfe 准则——这正是拟牛顿法**必须配 Wolfe (而非 Armijo 回退) 线搜索**的根本原因。

例10.4 对称秩 1 (SR1) 更新公式的推导 ★★★

🔴 题目 设秩 1 更新 $B^{k+1} = B^k + a u u^T$, 利用割线方程确定 u 与 a 。

✅ 解答

代入割线方程 $B^{k+1}s^k = y^k$:

$$(B^k + a u u^T)s^k = y^k \Rightarrow a(u^T s^k)u = y^k - B^k s^k.$$

由于 $a \cdot u^T s^k$ 是标量, 上式表明 u 与 $y^k - B^k s^k$ **同向**。简单取 $u = y^k - B^k s^k$, 代入得

$$(a(y^k - B^k s^k)^T s^k)(y^k - B^k s^k) = y^k - B^k s^k,$$

令系数 $a (y^k - B^k s^k)^\top s^k = 1$, 解出

$$a = \frac{1}{(y^k - B^k s^k)^\top s^k}.$$

故 **SR1 公式**:

$$B^{k+1} = B^k + \frac{uu^\top}{u^\top s^k}, \quad u = y^k - B^k s^k.$$

逆形式 (设 B^k 对称) 对偶地为

$$H^{k+1} = H^k + \frac{vv^\top}{v^\top y^k}, \quad v = s^k - H^k y^k.$$

🔗 **知识点** B^k 与 H^k 的公式形式上互为对偶; 实际上 $H^k = (B^k)^{-1}$, 由 Sherman-Morrison 公式可从一个推出另一个。

例10.5 Sherman-Morrison 公式及其在拟牛顿中的作用 ★★★

🔴 **题目** 已知 A^{-1} , 求 $(A + \frac{1}{a}uv^\top)^{-1}$.

🟢 **解答**

先求 $(I + uv^\top)^{-1}$, 设其形如 $I + \rho uv^\top$:

$$(I + uv^\top)(I + \rho uv^\top) = I + [1 + \rho(1 + v^\top u)]uv^\top = I,$$

令 $1 + \rho(1 + v^\top u) = 0 \Rightarrow \rho = -\frac{1}{1 + v^\top u}$, 故

$$(I + uv^\top)^{-1} = I - \frac{uv^\top}{1 + v^\top u}.$$

进而

$$(A + uv^\top)^{-1} = (I + A^{-1}uv^\top)^{-1}A^{-1} = A^{-1} - \frac{A^{-1}uv^\top A^{-1}}{1 + v^\top A^{-1}u}.$$

一般地

$$\left(A + \frac{1}{a}uv^\top\right)^{-1} = A^{-1} - \frac{A^{-1}uv^\top A^{-1}}{a + v^\top A^{-1}u}, \quad a + v^\top A^{-1}u \neq 0.$$

作用: 拟牛顿每步对 B^k 做秩 1/秩 2 修正, 借此公式可由 $H^k = (B^k)^{-1}$ 直接更新出 H^{k+1} , **无需重新求逆**, 把 $O(n^3)$ 求逆降为 $O(n^2)$ 。

🔗 **知识点** 推广为 **SMW (Sherman-Morrison-Woodbury) 公式**: $(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$, 秩 2 更新 (BFGS) 即对应 U, V 为 $n \times 2$ 、 C 为 2×2 , 只需求一个 2 阶矩阵的逆。

例10.6 秩 1 公式的缺陷——无法保证正定 ★★★

🔴 **题目** 证明: 用 SR1 公式更新时, $w^\top B^{k+1}w = w^\top B^k w + \frac{(u^\top w)^2}{u^\top s^k}$, 并说明为何 SR1 一般不用。

🟢 **解答**

对任意 $0 \neq w \in \mathbb{R}^n$:

$$w^\top B^{k+1}w = w^\top B^k w + \frac{w^\top u u^\top w}{u^\top s^k} = w^\top B^k w + \frac{(u^\top w)^2}{u^\top s^k}.$$

即使 B^k 正定 (首项 > 0), 第二项符号由 $u^\top s^k$ 决定。正定的充分条件是: (1) B^k 正定; (2) $u^\top s^k > 0$ 。但 SR1 中 $u^\top s^k = (y^k - B^k s^k)^\top s^k$ 无法保证恒正 (甚至可能为 0 使分母爆掉), 故即使 B^k 正定, B^{k+1} 也可能不正定。因此 SR1 一般不直接用于线搜索型拟牛顿法。

🔗 **知识点** SR1 的缺陷正是 BFGS 用秩 2 更新的动机——多一个自由度 (参数 a, b), 可同时满足割线方程与正定性。SR1 在信赖域框架中仍有用 (不要求正定)。

例10.7 BFGS 公式的推导 (秩 2 更新) ★★★★★

🔴 题目 设秩 2 更新 $B^{k+1} = B^k + auu^\top + bvv^\top$, 导出 BFGS 公式。

✅ 解答

代入割线方程:

$$(B^k + auu^\top + bvv^\top)s^k = y^k \Rightarrow (au^\top s^k)u + (bv^\top s^k)v = y^k - B^k s^k.$$

简单取法: 令 $(au^\top s^k)u$ 对应 y^k 、 $(bv^\top s^k)v$ 对应 $-B^k s^k$, 即

$$au^\top s^k = 1, u = y^k; \quad bv^\top s^k = -1, v = B^k s^k.$$

于是 $a = \frac{1}{(s^k)^\top y^k}$, $b = -\frac{1}{(s^k)^\top B^k s^k}$, 得基于 B 的 BFGS 公式:

$$B^{k+1} = B^k + \frac{y^k(y^k)^\top}{(s^k)^\top y^k} - \frac{B^k s^k (B^k s^k)^\top}{(s^k)^\top B^k s^k}.$$

利用 SMW 公式及 $H^k = (B^k)^{-1}$, 得基于 H 的 BFGS 公式:

$$H^{k+1} = \left(I - \frac{y^k(s^k)^\top}{(s^k)^\top y^k}\right)^\top H^k \left(I - \frac{y^k(s^k)^\top}{(s^k)^\top y^k}\right) + \frac{s^k(s^k)^\top}{(s^k)^\top y^k}.$$

记 $\rho_k = \frac{1}{(y^k)^\top s^k}$, $V^k = I - \rho_k y^k (s^k)^\top$, 即 $H^{k+1} = (V^k)^\top H^k V^k + \rho_k s^k (s^k)^\top$.

💡 知识点 BFGS 由 Broyden、Fletcher、Goldfarb、Shanno 于 1970 年代独立提出, 是最成功的拟牛顿公式。基于 H^k 的版本算 $d^k = -H^k \nabla f$ 无需解方程组, 最实用; 基于 B^k 的版本理论性质好、序列稳定。

`scipy.optimize.minimize(method='BFGS')` 即此。

例10.8 BFGS 保持正定的充分条件 (Cauchy-Schwarz 证明) ★★★★★

🔴 题目 设 B^k 对称正定且 $(s^k)^\top y^k > 0$, 证明 BFGS 更新的 B^{k+1} 对称正定。

✅ 解答

任给 $x \neq 0$:

$$x^\top B^{k+1} x = x^\top B^k x + \frac{(x^\top y^k)^2}{s^{k\top} y^k} - \frac{(x^\top B^k s^k)^2}{s^{k\top} B^k s^k} = \underbrace{\frac{(x^\top B^k x)(s^{k\top} B^k s^k) - (x^\top B^k s^k)^2}{s^{k\top} B^k s^k}}_{\geq 0} + \frac{(x^\top y^k)^2}{s^{k\top} y^k}.$$

由 B^k 度量下的 **Cauchy-Schwarz 不等式** $(x^\top B^k s^k)^2 \leq (x^\top B^k x)(s^{k\top} B^k s^k)$ (等号当且仅当 $x = \gamma s^k$):

- 当 $x \neq \gamma s^k$: 第一项 > 0 , 故 $x^\top B^{k+1} x > \frac{(x^\top y^k)^2}{s^{k\top} y^k} \geq 0$;
- 当 $x = \gamma s^k$ ($\gamma \neq 0$): 第一项 $= 0$, $x^\top B^{k+1} x = \frac{(x^\top y^k)^2}{s^{k\top} y^k} = \gamma^2 s^{k\top} y^k > 0$.

故恒有 $x^\top B^{k+1} x > 0$, 即 B^{k+1} 正定。■

关键: $(s^k)^\top y^k > 0$ (曲率条件) 是 B^{k+1} 正定的关键; 而精确线搜索或 Wolfe 准则恰好保证 $(s^k)^\top y^k > 0$ (见例 10.3), 故 BFGS 产生的矩阵有望保持正定, 是有效算法。

💡 知识点 这串起三件事: 曲率条件 (例10.3) $\rightarrow$ Cauchy-Schwarz $\rightarrow$ 正定保持。也解释了"为何初始 B^0 须取对称正定阵"——归纳法的起点。

例10.9 BFGS 的优化意义 (最近邻逼近) ★★★

🔴 题目 说明 BFGS 公式是何优化问题的解。

✅ 解答

基于 H^k 的 BFGS 恰是 $\min_H \|H - H^k\|_W \text{ s.t. } H = H^\top, Hy^k = s^k$ 的解。其中加权范数 $\|H\|_W = \|W^{1/2}HW^{1/2}\|_F$, W 满足割线方程 $Ws^k = y^k$ 。当 $W = H^{-1}$ (真实平均 Hesse) 时, 该问题的解恰为 BFGS 公式。

含义: 在所有满足割线方程的对称矩阵中, 找距 H^k 最近的矩阵作为 H^{k+1} ——即"最小改动"地纳入新曲率信息。对偶地, DFP 是 $\min_B \|B - B^k\|_W \text{ s.t. } B = B^\top, Bs^k = y^k, W$ 满足 $Wy^k = s^k$ 。

🔗 知识点 这一变分刻画解释了拟牛顿矩阵"正定对称 + 满足割线方程下的最佳逼近"。BFGS 更新 H 、DFP 更新 B 时各自是"最小变动", 两者互为对偶 ($B \leftrightarrow H, s \leftrightarrow y$)。

例10.10 DFP 公式及其与 BFGS 的对偶 ★★★

🔴 题目 写出 DFP 公式, 说明它与 BFGS 的对偶关系, 并指出 DFP 的缺陷。

✅ 解答

DFP 以割线方程 $H^{k+1}y^k = s^k$ 为基础对 H^k 作秩 2 更新:

$$H^{k+1} = H^k - \frac{H^ky^k(H^ky^k)^\top}{(y^k)^\top H^ky^k} + \frac{s^k(s^k)^\top}{(y^k)^\top s^k}.$$

基于 B 的 DFP:

$$B^{k+1} = \left(I - \frac{y^k(s^k)^\top}{(s^k)^\top y^k}\right)^\top B^k \left(I - \frac{y^k(s^k)^\top}{(s^k)^\top y^k}\right) + \frac{y^k(y^k)^\top}{(s^k)^\top y^k}.$$

对偶关系: DFP 的 B -公式与 BFGS 的 H -公式形式完全相同 (作 $B \leftrightarrow H, s \leftrightarrow y$ 互换即得)。

缺陷: 尽管二者对偶, 实际效果 DFP 整体不如 BFGS。Powell 求解 $\min \frac{1}{2}\|x\|_2^2 \ (x \in \mathbb{R}^2, B^0 = \text{diag}(1, \lambda), \tan^2 \psi = \lambda)$ 发现: λ 越大 (病态越重) DFP 迭代步数爆炸式增长, BFGS 则始终很少。

λ	BFGS ($\epsilon = 10^{-8}$)	DFP ($\epsilon = 10^{-8}$)
10	10	19
100	12	111
300	—	313
10^3	—	1014

🔗 知识点 DFP (Davidon 1959; Fletcher-Powell 1963) 是最早的拟牛顿公式。BFGS 对错误曲率信息的"自我修正"能力强于 DFP, 这是 BFGS 成为工业标准的实证原因 (Powell 1986, *Math. Programming*)。

例10.11 BFGS 求解二次型 (手算两步收敛, 验证 $H_2 = Q^{-1}$) ★★★★★

🔴 **题目** 用 BFGS 求 $f(x) = \frac{1}{2}x^T Qx - x^T b + 10$ 的极小点, $Q = \begin{bmatrix} 5 & -3 \\ -3 & 2 \end{bmatrix}$, $b = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$, $H_0 = I_2$, $x^{(0)} = [0, 0]^T$. 记 $g^{(k)} = \nabla f(x^{(k)}) = Qx^{(k)} - b$.

✅ **解答**

第 1 次迭代

- $g^{(0)} = Qx^{(0)} - b = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$, $d^{(0)} = -g^{(0)} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$.
- 二次型精确步长 $\alpha_0 = -\frac{g^{(0)T}d^{(0)}}{d^{(0)T}Qd^{(0)}} = -\frac{-1}{2} = \frac{1}{2}$.
- $x^{(1)} = x^{(0)} + \alpha_0 d^{(0)} = \begin{bmatrix} 0 \\ 1/2 \end{bmatrix}$, $s^{(0)} = \begin{bmatrix} 0 \\ 1/2 \end{bmatrix}$.
- $g^{(1)} = Qx^{(1)} - b = \begin{bmatrix} -3/2 \\ 0 \end{bmatrix}$, $y^{(0)} = g^{(1)} - g^{(0)} = \begin{bmatrix} -3/2 \\ 1 \end{bmatrix}$.
- 代入 BFGS (H 版): $s^{(0)T}y^{(0)} = \frac{1}{2}$, 算得
 $H_1 = \begin{bmatrix} 1 & 3/2 \\ 3/2 & 11/4 \end{bmatrix}$.

第 2 次迭代

- $d^{(1)} = -H_1 g^{(1)} = \begin{bmatrix} 3/2 \\ 9/4 \end{bmatrix}$, $\alpha_1 = -\frac{g^{(1)T}d^{(1)}}{d^{(1)T}Qd^{(1)}} = 2$.
- $x^{(2)} = x^{(1)} + \alpha_1 d^{(1)} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}$, $g^{(2)} = Qx^{(2)} - b = 0 \Rightarrow$ 停止.

验证 $H_2 = Q^{-1}$: $s^{(1)} = \begin{bmatrix} 3 \\ 9/2 \end{bmatrix}$, $y^{(1)} = g^{(2)} - g^{(1)} = \begin{bmatrix} 3/2 \\ 0 \end{bmatrix}$, 更新得

$$H_2 = \begin{bmatrix} 2 & 3 \\ 3 & 5 \end{bmatrix}, \quad H_2 Q = Q H_2 = I_2 \Rightarrow H_2 = Q^{-1}.$$

🔗 **知识点** n 维正定二次型 + $H_0 = I$ 时, BFGS 至多 n 步收敛, 且终止时 $H_n = Q^{-1}$ (自动重构出真实 Hesse 逆)。这是拟牛顿法的“二次终止性”, 与共轭梯度法 ([第11章 共轭梯度法]) 的 n 步终止异曲同工。对照 [第9章 牛顿类算法] 例9.5——牛顿法对二次型一步到位, 拟牛顿需 n 步但每步更便宜。

例10.12 L-BFGS 的存储动机与双循环递归 ★★★★★

🔴 **题目** (1) 为何稠密 H_k 在大规模问题上不可行? (2) L-BFGS 如何把存储降到 $O(mn)$? (3) 写出双循环递归算法。

✅ **解答**

(1) **存储瓶颈** $n = 10^5$ 、double (8 字节) 存稠密 H_k 需

$$\frac{10^5 \times 10^5 \times 8}{2^{10} \times 2^{10} \times 2^{10}} \approx 74.5 \text{ GB},$$

一般服务器难以承受 (即便利用对称性减半仍有约 37 GB)。

(2) **基本思想** 不存完整 H_k , 只存最近 m 组向量对 $\{s_i, y_i\}$ (m 由用户按内存指定, 通常 5~20)。每次用展开式 $H^{k+1} = (V^k)^T H^k V^k + \rho_k s^k (s^k)^T$, $\rho_k = \frac{1}{(y^k)^T s^k}$, $V^k = I - \rho_k y^k (s^k)^T$,

递归展开 m 次、以 $\hat{H}^{k-m}$ (近似初始阵) 为起点计算 $d^k = -H^k \nabla f(x^k)$ 。存储由 $O(n^2)$ 降到 $O(mn)$ 。

(3) **双循环递归** (算法 2, 输入 $q \leftarrow \nabla f(x^k)$, 输出 $r = H^k \nabla f(x^k)$) :

```

第一循环（自下而上， $i = k-1, \dots, k-m$ ）：
     $\alpha_i \leftarrow \rho_i (s^T i)^T q$       （保存  $\alpha_i$ ）
     $q \leftarrow q - \alpha_i y^T i$ 
初始化  $r \leftarrow H^T \{k-m\} q$ 
第二循环（自上而下， $i = k-m, \dots, k-1$ ）：
     $\beta \leftarrow \rho_i (y^T i)^T r$ 
     $r \leftarrow r + (\alpha_i - \beta) s^T i$ 
返回  $r$ 

```

复杂度约 $4mn$ 次乘法、 $2mn$ 次加法（ $\hat{H}$ 取对角再加 n 次），总 $O(mn)$ ，额外存储 $\{\alpha_i\}$ 仅 $O(m)$ 。

🔑 **知识点** 初始对角阵的推荐取法 $\hat{H}^{k-m} = \gamma_k I = \frac{(s^{k-1})^T y^{k-1}}{(y^{k-1})^T y^{k-1}} I$ ，这恰是 BB 方法的第一个步长（BB2，见 [[第8章 梯度类算法]] 例8.10）——拟牛顿与 BB 步长在此交汇。L-BFGS 是 `sklearn` 逻辑回归默认 solver，`scipy` 的 `L-BFGS-B`（带界约束）中 `maxcor` 即参数 m 。

例10.13 拟牛顿的收敛速度与重启策略 ★★★

🔴 **题目** (1) BFGS 的收敛速度是几阶？为何达不到牛顿的二阶？(2) 非二次型问题如何处理“ n 步不收敛”？

✅ **解答**

(1) Q-超线性 设 B^0 对称正定、 f 二阶连续可微、下水平集 $L = \{x : f(x) \leq f(x^0)\}$ 凸且 $\exists 0 < m \leq M$ 使 $m\|z\|^2 \leq z^T \nabla^2 f(x) z \leq M\|z\|^2$ ，则 BFGS + Wolfe 全局收敛到极小点 x^* （Zoutendijk 条件）。再加 Hesse 在 x^* 处 Lipschitz 连续，则

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} = 0,$$

即 **Q-超线性收敛**。因拟牛顿仅用 Hesse 的近似（非精确二阶信息），一般达不到牛顿的 Q-二阶，最多超线性。但每步代价 $O(n^2)$ 远低于牛顿 $O(n^3)$ + 算 Hesse，大规模下总开销可能更小（例： $\min_{x \in \mathbb{R}^{100}} c^T x - \sum_{i=1}^{500} \ln(b_i - a_i^T x)$ ，牛顿约 12 步但每步贵，BFGS 约 150 步但每步便宜，BFGS 反而更快到优势解）。

(2) 重启 非二次型问题拟牛顿通常**不会在 n 步内收敛**。策略：每经过 n 或 $n+1$ 次迭代，将搜索方向**重置为负梯度方向**（等价于把 H 重置为 I ），再继续迭代，直到满足停机准则。

🔑 **知识点** 收敛阶谱系：最速下降（线性）< 拟牛顿/共轭梯度（超线性/ n 步终止）< 牛顿（二阶）。拟牛顿在“收敛速度”与“单步代价”间取得最佳折中，故 BFGS/L-BFGS 是中大规模无约束优化的默认选择。重启思想与 [[第11章 共轭梯度法]] 的周期重启一致。

第 11 章 共轭梯度法

共轭梯度法（CG）介于最速下降与牛顿法之间：收敛速度与计算量均为“梯度下降 < CG < 牛顿”。核心思想是构造一组关于 A **共轭** 的方向 $v_1, v_2, \dots$ ，使二次型在 n 步内精确收敛。本章用“椭圆共轭直径”的几何直观引入，再过渡到非线性 CG。衔接 [[第8章 梯度类算法]]（最速下降的锯齿现象）、[[第9章 牛顿类算法]]（牛顿方程可用 CG 解）、[[第7章 线搜索方法]]（非线性 CG 的步长由线搜索定）。

例11.1 最速下降的锯齿与相邻梯度正交 ★★★

🔴 **题目** 对二次型 $f(x) = \frac{1}{2}x^T Ax - x^T b$ (A 正定对称), 用精确步长的梯度下降, 证明相邻两步梯度正交 $\langle \nabla f(x_k), \nabla f(x_{k+1}) \rangle = 0$, 并解释锯齿路径的成因。

✅ **解答**

$\nabla f(x) = Ax - b$, 下降方向 $-\nabla f(x_k) = b - Ax_k$, 迭代 $x_{k+1} = x_k - \alpha \nabla f(x_k)$ 。精确步长 α 使 $\phi(\alpha) = f(x_k - \alpha \nabla f(x_k))$ 极小, $\phi'(\alpha) = 0$:

$$\phi'(\alpha) = -\langle \nabla f(x_k), \nabla f(x_{k+1}) \rangle = 0 \Rightarrow \boxed{\langle \nabla f(x_k), \nabla f(x_{k+1}) \rangle = 0.}$$

即 $\langle x_{k+1} - x_k, \nabla f(x_{k+1}) \rangle = 0$ ——每步的位移方向与新点处梯度垂直。

锯齿成因: 相邻搜索方向恰好正交, 迭代路径在狭长椭圆等高线上来回折返, 形成 90° 转角的曲折路径, 收敛极慢。梯度方向并非"最好的优化方向"。

🔗 **知识点** 这正是 [[第8章 梯度类算法]] 例8.3 锯齿现象的根源。CG 的动机就是: 放弃"局部最陡"的梯度方向, 改用一组"全局协调"的共轭方向, 消除折返。

例11.2 共轭方向的几何来源——椭圆共轭直径 ★★★

🔴 **题目** 什么是椭圆的共轭直径? 它与共轭向量 $u^T Av = 0$ 有何联系?

✅ **解答**

共轭直径: 椭圆两条直径 d_1, d_2 , 若 d_1 端点处切线与 d_2 平行, 则 d_2 端点处切线也与 d_1 平行, 称 d_1, d_2 为一组共轭直径。等价刻画: **所有平行于 d_1 的弦, 其中点恰构成 d_2** (反之亦然); 内接平行四边形两组对边方向也引导出一对共轭直径。

本质 (伸缩不变性): 对椭圆沿某方向拉伸/压缩, 共轭性质不变。圆的一对**正交**直径, 经拉伸压缩成椭圆后, 就变成一组**共轭**直径。

代数化: 设可逆伸缩 S , 单位球面 $x_0^T x_0 = 1$ 经 $x = Sx_0$ 变为超椭球。代入 $x_0 = S^{-1}x$ 得 $x^T ((S^{-1})^T S^{-1}) x = 1$, 记 $A = (S^{-1})^T S^{-1}$ (正定对称), 即 $x^T Ax = 1$ 。球面上两正交直径 $u_0^T v_0 = 0$, 经变换 $u = Su_0, v = Sv_0$, 迭代回得

$$(S^{-1}u)^T (S^{-1}v) = 0 \Rightarrow u^T ((S^{-1})^T S^{-1}) v = 0 \Rightarrow \boxed{u^T Av = 0.}$$

即超椭球的共轭直径方向 u, v 满足 $u^T Av = 0$ ——这就是**关于 A 共轭**的定义。 A 对称故共轭可左右交换。

🔗 **知识点** 共轭 = "在 A 度量下的正交"。把椭圆拉回成圆, 共轭方向就变成普通正交方向——这是理解 CG "在变形空间里走正交路径"的几何钥匙。

例11.3 共轭优化方向: 朝极值点的正确方向 ★★★

🔴 **题目** 证明: 若上一步沿 d_k 达到极小 ($\langle d_k, \nabla f(x_k) \rangle = 0$), 则指向精确极值点 x^* 的方向 $x_k - x^*$ 与 d_k 关于 A 共轭。

✅ **解答**

精确极值点 $x^* = A^{-1}b$ 。上一步极小条件: $\langle d_k, Ax_k - b \rangle = 0$ 。又

$$x_k - x^* = x_k - A^{-1}b \Rightarrow A(x_k - x^*) = Ax_k - b.$$

代入极小条件:

$$\langle d_k, A(x_k - x^*) \rangle = \langle d_k, Ax_k - b \rangle = 0 \Rightarrow \boxed{d_k^T A(x_k - x^*) = 0.}$$

即 $x_k - x^*$ 与 d_k 关于 A 共轭。

结论：要一步到达极值点，下一个优化方向 d_{k+1} 应与 d_k 关于 A 共轭（而非取负梯度）。构造步骤：

1. 算梯度 $\nabla f(x_k) = Ax_k - b$;
2. 取与梯度配合的方向，使新方向 d_{k+1} 满足 $d_k^T A d_{k+1} = 0$;
3. 沿 d_{k+1} 优化，比沿梯度更快，且避免锯齿路径。

🔗 **知识点** 这是 CG 的灵魂：朝极值点的“真方向” $x_k - x^*$ 本身就与上一步方向共轭，所以构造共轭方向 = 逼近真方向。对照例11.1，梯度方向只满足正交（局部最优），共轭方向才指向全局解。

例11.4 新共轭方向的构造（Gram-Schmidt 式提取）★★★★

🔗 **题目** 记残差 $r_k = b - Ax_k$ （即负梯度）。如何从 r_k 与上一方向 v_k 构造与 v_k 关于 A 共轭的新方向 v_{k+1} ？再求沿 v_{k+1} 的最优步长 t_{k+1} 。

✅ **解答**

构造方向：设 $v_{k+1} = r_k - s_k v_k$ ，代入共轭条件 $v_k^T A v_{k+1} = 0$ ：

$$v_k^T A (r_k - s_k v_k) = 0 \Rightarrow s_k = \frac{v_k^T A r_k}{v_k^T A v_k}.$$

这是把负梯度 r_k 关于 A 对 v_k 做“共轭正交化”（Gram-Schmidt 在 A 度量下的一步）。

最优步长： $x_{k+1} = x_k + t_{k+1} v_{k+1}$ ，由 $v_{k+1}^T (A(x_k + t_{k+1} v_{k+1}) - b) = 0$ ：

$$-v_{k+1}^T r_k + t_{k+1} v_{k+1}^T A v_{k+1} = 0 \Rightarrow t_{k+1} = \frac{v_{k+1}^T r_k}{v_{k+1}^T A v_{k+1}}.$$

完整迭代（初始 $x_0 = 0, v_0 = 0$ ）：

$$r_k = b - Ax_k, \quad v_{k+1} = r_k - s_k v_k, \quad x_{k+1} = x_k + t_{k+1} v_{k+1}.$$

🔗 **知识点** 满足 $v_k^T A v_{k+1} = 0$ 的 v_{k+1} 有无穷多，CG 的巧妙在于只从最近的残差 r_k 和上一方向 v_k 提取——递推中自动保证了与所有历史方向共轭（见例11.6），无需显式存储全部历史向量，故存储仅 $O(n)$ 。

例11.5 关键变量的递推关系 ★★★

🔗 **题目** 推导残差递推 $r_k = r_{k-1} - t_k A v_k$ ，并说明 t_k, s_{k-1} 各自由什么条件确定。

✅ **解答**

由 $x_k = x_{k-1} + t_k v_k$ ：

$$r_k = b - Ax_k = b - A(x_{k-1} + t_k v_k) = (b - Ax_{k-1}) - t_k A v_k = r_{k-1} - t_k A v_k.$$

方向递推： $v_k = r_{k-1} - s_{k-1} v_{k-1}$ 。

- t_k 由“最佳步长”确定，保证 $r_k \perp v_k$ （即新残差与刚走过的方向垂直）；
- s_{k-1} 由“共轭”确定，保证 v_k 与 v_{k-1} 关于 A 共轭。

结构图（两条链交替生成）：每个 r_k 由左邻 r_{k-1} 与上方 $A v_k$ 组合，且与 v_k 垂直；每个 v_k 由左下 r_{k-1} 与左邻 v_{k-1} 组合，且与 v_{k-1} 关于 A 共轭。

🔗 **知识点** 残差递推 $r_k = r_{k-1} - t_k A v_k$ 是 CG 高效的关键——每步只需一次矩阵-向量乘 $A v_k$ ，无需重新算 $b - Ax_k$ 。这也是 CG 适合大规模稀疏 A 的原因（只需 A 的乘法，不需 A 的存储/分解）。

例11.6 两两正交与两两共轭（归纳法）+ n 步终止 ★★★★★

◆ **题目** 证明 CG 产生的残差序列 $r_0, r_1, \dots$ 两两正交、方向序列 $v_1, v_2, \dots$ 两两关于 A 共轭，并由此说明至多 n 步收敛。

✓ **解答**

相邻性质（基础步）：

- $r_k \perp v_{k-1}$: r_k 是 r_{k-1} 与 Av_k 的线性组合; $r_{k-1} \perp v_{k-1}$ (上一步最优), $Av_k \perp v_{k-1}$ (共轭性), 故 $r_k \perp v_{k-1}$ 。
- $r_k \perp r_{k-1}$: v_k 由 r_{k-1} 与 v_{k-1} 组合, 而 $v_k \perp r_k$ 、 $v_{k-1} \perp r_k$, 故 r_{k-1} (它们的线性组合) $\perp r_k$ 。

第二类数学归纳（归纳步）： 设 r_k 与所有 $r_0, \dots, r_{k-1}$ 正交、 v_k 与所有 $v_1, \dots, v_{k-1}$ 共轭。对 $i < k$:

1. Av_i 可写为 r_i, r_{i-1} 的线性组合, 二者均 $\perp r_k \Rightarrow r_k \perp Av_i \Rightarrow r_k$ 与 v_i 关于 A 共轭;
2. r_k, v_k 都与 v_i 共轭, v_{k+1} 是 v_k, r_k 组合 $\Rightarrow v_{k+1}$ 与 v_i 共轭;
3. r_i 可写为 v_i, v_{i+1} 组合, 二者均与 v_{k+1} 共轭 $\Rightarrow r_i$ 与 Av_{k+1} 垂直;
4. Av_{k+1}, r_k 都 $\perp r_i$, r_{k+1} 是二者组合 $\Rightarrow r_{k+1} \perp r_i$ 。

故 $\{r_k\}$ 两两正交、 $\{v_k\}$ 两两共轭。■

n 步终止： n 维空间至多有 n 个两两正交的非零向量, 故 $r_0, \dots, r_n$ 中必存在 $m \leq n$ 使 $r_m = 0$, 即 $b - Ax_m = 0$, $x_m = A^{-1}b$ 为精确解。**线性 CG 至多 n 步收敛。**

🔗 **知识点** n 步终止性是 CG 最漂亮的理论性质, 与拟牛顿的二次终止 ([第10章 拟牛顿类算法] 例10.11) 同源。注意这是"理论精确"——实际浮点误差下常需重启或多走几步。

例11.7 非线性共轭梯度法（Fletcher-Reeves 框架）★★★★

◆ **题目** 把线性 CG 推广到一般非线性 $f(x)$, 写出非线性 CG 迭代格式, 并比较线性/非线性 CG。

✓ **解答**

思路： f 在 x_k 附近 Taylor 展开, 二阶项的 Hesse $\nabla^2 f(x_k)$ 正定对称, 牛顿方程 $\nabla^2 f(x_k)d_{k+1} = -\nabla f(x_k)$ 可用 CG 求解。推广后直接对 f 迭代:

$$g_k = \nabla f(x_k), \quad d_{k+1} = -g_k - \beta_k d_k, \quad x_{k+1} = x_k + \alpha_{k+1} d_{k+1}.$$

其中 β_k 由共轭条件确定 (对应线性 CG 的 s_k), α_{k+1} 由**线搜索**确定 (不再有解析式)。

线性 vs 非线性 CG:

	线性 CG	非线性 CG
目标	解线性系统 $Ax = b$	求 $f(x)$ 极值
"矩阵"	给定 A	函数的 Hesse
残差	给定 $r = b - Ax$	函数梯度 g_k
优化方向	从残差提取	从残差提取

	线性 CG	非线性 CG
步长	点积除法（解析）	线搜索
收敛性	有限步 ($\leq n$)	超线性

 **知识点** 非线性 CG 达**超线性收敛**，介于最速下降与牛顿之间。 β_k 的常见取法：Fletcher-Reeves、Polak-Ribière 等。每 n 步常将 d 重启为负梯度（与 [[第10章 拟牛顿类算法]] 例10.13 的重启思想一致）。

例11.8 避免 Hesse 的改进——割线近似 ★★★

 **题目** 非线性 CG 中需要 $\nabla^2 f(x_k)d_k$ ，当 Hesse 难算时如何避免？

 **解答**

算法仅在一处用到 Hesse：方向 $\nabla^2 f(x_k)d_k$ 。用**割线（差商）代替切线（导数）**：
 $\nabla^2 f(x_k)d_k \approx \nabla f(x_k) - \nabla f(x_{k-1})$.
 （当 $d_k \propto x_k - x_{k-1}$ 时，这正是梯度差 y_{k-1} 。）代入后 β_k 只用到一阶梯度，**完全避免 Hesse**，得到无 Hesse 的非线性 CG。

 **知识点** 这与 [[第10章 拟牛顿类算法]] 的割线方程 $\nabla^2 f \cdot s \approx y$ 是同一思想——用相邻梯度差近似 Hesse 作用。CG 与拟牛顿在“无 Hesse”这点上殊途同归。

例11.9 非线性 CG 的线搜索：黄金分割与割线插值 ★★★

 **题目** 非线性 CG 中如何搜索步长 α 使 $f(x_0 + \alpha d)$ 极小？给出两种方法。

 **解答**

目标：找 α 使 $\nabla f(x_0 + \alpha d) \perp d$ （即 $\phi'(\alpha) = \nabla f^\top d = 0$ ）。

(1) 黄金分割法（仅需 C^0 ，不算导数）：在 $[a_i, b_i]$ 取黄金分割点 $s_i < t_i$ ，比较 $f(s_i), f(t_i)$ ：若 $f(s_i)$ 大则弃 $[a_i, s_i]$ ，若 $f(t_i)$ 大则弃 $[t_i, b_i]$ ；剩余区间中保留的分割点恰是新区间的黄金分割点（少算一次函数值）。线性收敛，公比 0.618。

(2) 割线插值：把 $\nabla f \cdot d$ 视为关于 α 近似线性的函数，用最近两次 α 及其 $\nabla f \cdot d$ 值线性插值出零点作为新 α ，迭代逼近 $\nabla f \cdot d = 0$ 的点（快于黄金分割）。

对比黄金分割 vs 二分：

	二分法	黄金分割法
适用	C^0 连续	C^0 连续
目标	求零点（需 $f(a)f(b) < 0$ ）	求极小值点
收敛	线性，公比 1/2	线性，公比 0.618

 **知识点** 黄金分割/二分/割线插值见 [[第7章 线搜索方法]]。黄金分割不需导数（只要单峰），二分法需中间值定理（ $f(a)f(b) < 0$ ）求零点。非线性 CG 把“一维子问题”交给这些一维搜索。

例11.10 CG 在算法谱系中的定位 (总结) ★★★

🔴 **题目** 总结共轭梯度法的核心要点, 并定位其在"梯度下降—CG—牛顿"谱系中的位置。

✅ **解答**

核心要点:

1. CG 是迭代算法, 每步优化方向与前一步关于 Hesse (或 A) **共轭**;
2. 新方向从"函数梯度 + 前一步方向"中提取 ($d_{k+1} = -g_k - \beta_k d_k$);
3. 每次优化到达"梯度与优化方向垂直"的位置 (精确线搜索);
4. 线性 CG 在有限步 ($\leq n$) 内收敛。

谱系定位:

收敛速度: 梯度下降 $<$ CG $<$ 牛顿; 单步计算量: 梯度下降 $<$ CG $<$ 牛顿。

CG 在"收敛快"与"代价低"之间取折中——不需存储/分解 Hesse (只需矩阵-向量乘), 存储 $O(n)$, 特别适合大规模稀疏线性系统与无约束优化。

💡 **知识点** CG 与 L-BFGS ([第10章 拟牛顿类算法]) 是大规模无约束优化的两大主力: CG 存储更省 ($O(n)$ vs $O(mn)$), L-BFGS 通常更稳健。牛顿方程 $\nabla^2 f d = -\nabla f$ 内层常用 CG 求解, 即"牛顿-CG" ([第9章 牛顿类算法] 例9.10 非精确牛顿的典型实现)。

第 12 章 罚函数法与增广拉格朗日法

约束优化的两大困难: 梯度下降所得点不一定可行; 最优解处梯度不一定为零。罚函数法把约束优化转化为无约束优化求解。本章涵盖二次罚函数 (外点)、对数罚 (内点)、 ℓ_1 精确罚, 以及克服罚因子膨胀困难的**增广拉格朗日法 (ALM)**。衔接 [第5章 对偶理论] (拉格朗日函数)、[第6章 KKT条件与约束优化] (KKT 对照)、[第8章 梯度类算法] (子问题用梯度法/近似点梯度法求解)。

例12.1 等式约束的二次罚函数与外点法 ★★★

🔴 **题目** 写出等式约束问题 $\min f(x) \text{ s.t. } c_i(x) = 0 (i \in E)$ 的二次罚函数, 解释"外点罚"的含义, 并以 $\min x + \sqrt{3}y \text{ s.t. } x^2 + y^2 = 1$ 为例说明 σ 增大的作用。

✅ **解答**

二次罚函数:

$P_E(x, \sigma) = f(x) + \frac{1}{2}\sigma \sum_{i \in E} c_i^2(x)$, $\sigma > 0$ (罚因子)。

可行点 ($c_i = 0$) 罚项为 0; 不可行点罚项为正。**外点罚:** 迭代点列一般处于可行域之外, 随 $\sigma \rightarrow \infty$ 从外侧逼近可行域。

例: $P_E(x, y, \sigma) = x + \sqrt{3}y + \frac{\sigma}{2}(x^2 + y^2 - 1)^2$, 原问题最优解 $(-\frac{1}{2}, -\frac{\sqrt{3}}{2})$ 。 $\sigma = 1$ 时罚函数极小点离约束圆较远; $\sigma = 10$ 时等高线被"挤压"贴近单位圆, 极小点更靠近真解。 σ 越大, 违反约束的惩罚越重, 解越接近可行域。

💡 **知识点** 二次罚函数法 (算法 1): 每步以 x^k 为初值解 $x^{k+1} = \arg \min_x P_E(x, \sigma_k)$, 再令 $\sigma_{k+1} = \rho \sigma_k$ ($\rho > 1$)。 ρ 过大子问题难解, 过小迭代次数多。

例12.2 罚因子过小导致罚函数无下界 ★★★

🔴 **题目** 考虑 $\min -x^2 + 2y^2$ s.t. $x = 1$, 最优解 $(1, 0)$ 。证明二次罚函数 $P_E = -x^2 + 2y^2 + \frac{\sigma}{2}(x-1)^2$ 对任意 $\sigma \leq 2$ 无下界。

✅ **解答**

关于 x 的二次项系数为 $-1 + \frac{\sigma}{2}$ 。当 $\sigma \leq 2$ 时 $-1 + \frac{\sigma}{2} \leq 0$, 令 $y = 0$, $x \rightarrow \pm\infty$:

$$P_E = (-1 + \frac{\sigma}{2})x^2 - \sigma x + \frac{\sigma}{2} \rightarrow -\infty \text{ (若 } \sigma < 2\text{),}$$

$\sigma = 2$ 时 $P_E = -2x + 2 \rightarrow -\infty$ 。故 $\sigma \leq 2$ 时罚函数无下界, 子问题无解。

🔍 **知识点** 这揭示二次罚函数法的隐患: 当 f 非凸 (这里 $-x^2$) 时, **罚因子必须足够大**才能让 $\nabla^2 P_E$ 正定、罚函数有下界。检测到迭代点发散应立即增大 σ 。

例12.3 从 KKT 看罚因子必须趋于无穷 ★★★★★

🔴 **题目** 对比原问题 KKT 与二次罚函数的稳定性条件, 说明为何二次罚函数法需 $\sigma \rightarrow \infty$, 并分析由此带来的数值困难。

✅ **解答**

原问题 KKT (梯度式): $\nabla f(x^*) - \sum_{i \in E} \lambda_i^* \nabla c_i(x^*) = 0$ 。

罚函数稳定点: $\nabla P_E = \nabla f(x) + \sum_{i \in E} \sigma c_i(x) \nabla c_i(x) = 0$ 。

两式在同一点一致, 需 $\sigma c_i(x) \approx -\lambda_i^*$, 即

$$c_i(x^{k+1}) \approx -\frac{\lambda_i^*}{\sigma_k}.$$

λ_i^* 固定, 要使约束违反度 $c_i \rightarrow 0$, **必须** $\sigma_k \rightarrow \infty$ 。

数值困难: 罚函数 Hesse

$$\nabla^2 P_E \approx \nabla_{xx}^2 L(x, \lambda^*) + \sigma \nabla c(x) \nabla c(x)^\top,$$

右端是“定值矩阵 + 最大特征值趋于 $+\infty$ 的矩阵”, **条件数随 σ 爆炸式增大**。梯度法/拟牛顿/共轭梯度法都将遇到严重病态, 牛顿方程本身极难解。故实际中不能让 $\sigma \rightarrow +\infty$ ——这正是 ALM 的改进动机。

🔍 **知识点** $c_i(x^{k+1}) \approx -\lambda_i^*/\sigma_k$ 是理解全章的关键。二次罚的根本缺陷 (病态 + 不精确) 直接催生增广拉格朗日法 (例12.7)。

例12.4 二次罚函数法的收敛性 (全局极小 + KKT) ★★★★★

🔴 **题目** (1) 证明: 若 x^{k+1} 是 $P_E(\cdot, \sigma_k)$ 的全局极小解、 $\sigma_k \uparrow \infty$, 则 $\{x^k\}$ 的每个极限点是原问题全局极小解。
(2) 子问题非精确求解时, 极限点 KKT 性如何?

✅ **解答**

(1) 全局极小情形 设 $\bar{x}$ 是原问题极小解 ($c_i(\bar{x}) = 0$)。由 x^{k+1} 的极小性 $P_E(x^{k+1}, \sigma_k) \leq P_E(\bar{x}, \sigma_k) = f(\bar{x})$:

$$f(x^{k+1}) + \frac{\sigma_k}{2} \sum_{i \in E} c_i^2(x^{k+1}) \leq f(\bar{x}).$$

整理 $\sum_{i \in E} c_i^2(x^{k+1}) \leq \frac{2}{\sigma_k} (f(\bar{x}) - f(x^{k+1}))$ 。设 $x^k \rightarrow x^*$, 令 $k \rightarrow \infty$ ($\sigma_k \rightarrow \infty$) 得 $\sum_{i \in E} c_i^2(x^*) = 0$, 即 x^* 可行。又由 (*) 知 $f(x^{k+1}) \leq f(\bar{x})$, 取极限 $f(x^*) \leq f(\bar{x})$, 故 x^* 是全局极小解。■

(2) 非精确 + KKT 设 $\|\nabla_x P_E(x^{k+1}, \sigma_k)\| \leq \varepsilon_k \rightarrow 0$, $\sigma_k \rightarrow \infty$, 且极限点 x^* 处 $\{\nabla c_i(x^*)\}$ 线性无关 (LICQ)。由

$$\left\| \sum_{i \in E} c_i(x^{k+1}) \nabla c_i(x^{k+1}) \right\| \leq \frac{1}{\sigma_k} (\varepsilon_k + \|\nabla f(x^{k+1})\|) \rightarrow 0,$$

结合 LICQ 得 $c_i(x^*) = 0$ (可行)。乘子 $\lambda_i^* = \lim_k (-\sigma_k c_i(x^{k+1}))$, 并满足 KKT 梯度条件。故 x^* 是 KKT 点。

🔗 **知识点** 推论：即便 $\{\nabla c_i\}$ 线性相关 (无可行解)，聚点仍是 $\varphi(x) = \|c(x)\|^2$ 的稳定点——"找到约束违反度最小的解"。定理只给渐进结论，未给 ε_k 的非渐进选取法。

例12.5 不等式约束与一般约束的二次罚 ★★★

🔴 **题目** 写出不等式约束 $c_i(x) \leq 0$ ($i \in I$) 及一般约束的二次罚函数，并说明光滑性。

✅ **解答**

记 $\tilde{c}_i(x) = \max\{c_i(x), 0\}$ (违反度)，则

$$P_I(x, \sigma) = f(x) + \frac{1}{2} \sigma \sum_{i \in I} \tilde{c}_i^2(x).$$

一般约束 (E 等式 + I 不等式)：

$$P(x, \sigma) = f(x) + \frac{1}{2} \sigma \left[\sum_{i \in E} c_i^2(x) + \sum_{i \in I} \tilde{c}_i^2(x) \right].$$

光滑性： $h(t) = (\max\{t, 0\})^2 = (\min\{-t, 0\})^2$ 关于 t **一阶可导** ($h'(t) = 2 \max\{t, 0\}$ 连续)，故 P_I 梯度存在，可用梯度法。但 h **二阶不可导** ($t = 0$ 处)，故 P_I 一般不二次可微，光滑性降低，二阶法需用半光滑牛顿法。

🔗 **知识点** 二次罚的优点：形式简洁、可调用无约束光滑优化算法。缺点：需 $\sigma \rightarrow \infty$ (病态)、不等式情形光滑性降低、解不精确。

例12.6 内点法：对数罚函数 ★★★

🔴 **题目** 写出不等式约束的对数罚函数，说明它与二次罚 (外点) 的本质区别，并以 $\min x^2 + 2xy + y^2 + 2x - 2y$ s.t. $x \geq 0, y \geq 0$ (最优 $(0, 1)$) 为例。

✅ **解答**

对数罚 (内点罚)：

$$P_I(x, \sigma) = f(x) - \sigma \sum_{i \in I} \ln(-c_i(x)), \quad \sigma > 0,$$

定义域为严格可行内部 $\{x : c_i(x) < 0\}$ 。当 $x \rightarrow$ 可行域边界时 $-c_i(x) \rightarrow 0^+$, $-\ln(-c_i) \rightarrow +\infty$, 形成"势垒"，迭代点始终严格位于可行域内部 (内点法)。

与二次罚 (外点，从外逼近) 相反：对数罚从**内部**逼近。但极小点严格在内部，而真解常在边界，故需 $\sigma \rightarrow 0^+$ 减小势垒。

例： $P_I = x^2 + 2xy + y^2 + 2x - 2y - \sigma(\ln x + \ln y)$ 。 $\sigma = 1$ 时极小点离边界远； $\sigma = 0.4$ 时更靠近边界真解 $(0, 1)$ 。

🔗 **知识点** 对数罚法 (算法 4)：初始点须严格可行， $\sigma_{k+1} = \rho \sigma_k$ ($\rho \in (0, 1)$ 缩小)。 $\sigma \rightarrow 0$ 时同样有数值困难。对数罚是现代**内点法**的核心 (如 LP/SDP 的障碍函数法)。

例12.7 ℓ_1 精确罚函数及其精确性 ★★★★★

🔴 **题目** 定义 ℓ_1 精确罚函数，陈述其精确性定理 ($\sigma^* = \|\lambda^*\|_\infty$)，并证明精确罚必然非光滑。

✅ **解答**

ℓ_1 罚函数 (用绝对值代替平方)：

$$P(x, \sigma) = f(x) + \sigma \left[\sum_{i \in E} |c_i(x)| + \sum_{i \in I} \tilde{c}_i(x) \right].$$

精确性定理：设 x^* 是原问题严格局部极小解、满足 KKT 且乘子为 λ^* ，则当

$$\sigma > \sigma^* \stackrel{\text{def}}{=} \|\lambda^*\|_\infty = \max_i |\lambda_i^*|$$

时， x^* 也是 $P(x, \sigma)$ 的局部极小解。即**罚因子充分大 (有限!)** 即可，无需 $\sigma \rightarrow \infty$ ——这与二次罚 (定理需 ∞) 的本质区别，故称“精确”。

非光滑性证明 设单约束 $P = f(x) + \sigma h(c_1(x))$, $h \geq 0, h(0) = 0$ 。若 h 连续可微，则 $\nabla h(0) = 0$ (0 为极小)，于是 P 的极小点 x^* 处

$$0 = \nabla P(x^*) = \nabla f(x^*) + \sigma \underbrace{\nabla c_1(x^*) \nabla h(c_1(x^*))}_{=0} = \nabla f(x^*).$$

但约束优化最优点处 ∇f 一般 $\neq 0$ ，矛盾。故 h 必非光滑 (如 $|t|$)。正是非光滑性“抵消”了 ∇f ，才实现有限罚因子下的精确求解。■

🔗 **知识点** 一般精确罚 $P = f + \mu \|c_E(x)\| + \mu \|[c_I(x)]^+\|$ ，定理把 $\|\lambda^*\|_\infty$ 推广为对偶范数 $\|\lambda^*\|_D$ ($\ell_1 \leftrightarrow \ell_\infty$ 互为对偶， ℓ_2 自对偶)。代价：非光滑子问题需专门算法 (次梯度/近似点)。参考 Han-Mangasarian 1978。

例12.8 罚函数法的应用：LASSO 与基追踪 ★★★

🔴 **题目** 用二次罚函数视角统一 LASSO 与基追踪 (BP)，并说明连续化 (同伦) 求解策略。

✅ **解答**

$$\text{LASSO: } \min_x \frac{1}{2} \|Ax - b\|^2 + \mu \|x\|_1; \quad \text{BP: } \min \|x\|_1 \text{ s.t. } Ax = b.$$

把 BP 的等式约束做二次罚： $\min_x \|x\|_1 + \frac{\sigma}{2} \|Ax - b\|^2$ 。令 $\mu = 1/\sigma$ 即等价于 LASSO 形式 $\min \frac{1}{2} \|Ax - b\|^2 + \mu \|x\|_1$ (同乘 σ)。

观察：仅当 $\mu \rightarrow 0$ ($\sigma \rightarrow \infty$) 时 LASSO 解收敛于 BP 解。 μ 小时问题病态、收敛慢，故采用**连续化 (同伦)**： μ 从大到小 ($\mu_{k+1} = \max\{\mu, \gamma \mu_k\}$, $\gamma \in (0, 1)$)，用上一子问题解作下一初值 (暖启动)，逐步逼近。矩阵补全 $\min \|X\|_*$ s.t. $X_{ij} = M_{ij}$ 同理。

🔗 **知识点** 连续化策略是罚函数法的实用核心：避免直接解病态的小 μ 问题。子问题 (LASSO) 可用近似点梯度法 ([第8章 梯度类算法]) 的 LASSO 光滑化例8.11 相关)。

例12.9 增广拉格朗日函数法 (ALM) 的构造与乘子更新 ★★★★★

🔴 **题目** 写出等式约束的增广拉格朗日函数，从 KKT 对照推导乘子更新公式，说明 ALM 为何能用**有限**罚因子。

✅ **解答**

增广拉格朗日函数 (拉格朗日 + 二次罚)：

$$L_\sigma(x, \lambda) = f(x) + \sum_{i \in E} \lambda_i c_i(x) + \frac{1}{2} \sigma \sum_{i \in E} c_i^2(x).$$

第 k 步极小点 x^{k+1} 满足

$$\nabla_x L_{\sigma_k} = \nabla f(x^{k+1}) + \sum_{i \in E} (\lambda_i^k + \sigma_k c_i(x^{k+1})) \nabla c_i(x^{k+1}) = 0.$$

对照原问题 KKT $\nabla f(x^*) + \sum \lambda_i^* \nabla c_i(x^*) = 0$, 应有

$$\lambda_i^* \approx \lambda_i^k + \sigma_k c_i(x^{k+1}) \iff c_i(x^{k+1}) \approx \frac{1}{\sigma_k} (\lambda_i^* - \lambda_i^k).$$

关键对比: 二次罚是 $c_i \approx -\lambda_i^*/\sigma_k$ (要小必须 $\sigma_k \rightarrow \infty$) ; ALM 是 $c_i \approx (\lambda_i^* - \lambda_i^k)/\sigma_k$ ——只要乘子 λ^k 逼近 λ^* , 约束违反度就远小于 $1/\sigma_k$, **无需** $\sigma_k \rightarrow \infty$! 故采用乘子更新

$$\lambda_i^{k+1} = \lambda_i^k + \sigma_k c_i(x^{k+1}), \quad i \in E.$$

 **知识点** ALM (算法 1) = 拉格朗日法 + 二次罚 + 乘子迭代。核心思想: 用乘子更新 (而非罚因子膨胀) 降低约束违反度, 避开 [[第6章 KKT条件与约束优化]] 与例12.3 的病态困难。ALM 又称“乘法法”。

例12.10 ALM 与二次罚的数值对比 ★★★

 **题目** 对 $\min x + \sqrt{3}y$ s.t. $x^2 + y^2 = 1$ (最优 $(-\frac{1}{2}, -\frac{\sqrt{3}}{2})$, $\lambda^* = 1$), 比较固定罚因子下二次罚与 ALM 的寻优精度。

 **解答**

增广拉格朗日函数 $L_\sigma = x + \sqrt{3}y + \lambda(x^2 + y^2 - 1) + \frac{\sigma}{2}(x^2 + y^2 - 1)^2$ 。取 $\sigma = 2$ 、 $\lambda = 0.9$ (接近 $\lambda^* = 1$) :

方法	求出的解	与真解欧氏距离	约束违反度
二次罚 ($\lambda = 0$)	$(-0.5957, -1.0319)$	≈ 0.1915	0.4197
ALM ($\lambda = 0.9$)	$(-0.5100, -0.8833)$	≈ 0.02	0.0403

ALM 的等高线极小点几乎与真解 * 重合 ($\circ \approx *$), 而二次罚的 $\circ$ 明显偏离。**结论:** 相同 (有限) 罚因子下, ALM 寻优更精确、约束违反度更低。

 **知识点** ρ (罚因子增长系数) 实践取 $[2, 10]$: 过快则 L_σ 病态, 过慢则收敛慢 (惩罚不足)。 σ_k 与 σ_{k+1} 接近时 x^k 可作 x^{k+1} 暖启动。

例12.11 ALM 是精确罚 + 收敛速度 ★★★★★

 **题目** (1) 证明: 在 LICQ + 二阶充分条件下, 存在有限 $\bar{\sigma}$ 使 $\sigma \geq \bar{\sigma}$ 时 x^* 是 $L_\sigma(\cdot, \lambda^*)$ 的严格局部极小解。(2) ALM 乘子的收敛速度。

 **解答**

(1) 精确罚性质 x^*, λ^* 满足二阶充分条件: $\nabla_x L(x^*, \lambda^*) = 0$, 且 $\nabla c(x^*)^\top u = 0, u \neq 0 \Rightarrow u^\top \nabla_{xx}^2 L u > 0$ 。由 $c_i(x^*) = 0$:

$$\nabla_x L_\sigma(x^*, \lambda^*) = \nabla_x L(x^*, \lambda^*) = 0, \quad \nabla_{xx}^2 L_\sigma = \nabla_{xx}^2 L + \sigma \nabla c(x^*) \nabla c(x^*)^\top.$$

只需证 σ 充分大时 $\nabla_{xx}^2 L_\sigma \succ 0$ 。反证: 若不然, 存在 $\|u_k\| = 1$ 使 $u_k^\top \nabla_{xx}^2 L u_k + \sigma \|\nabla c(x^*)^\top u_k\|^2 \leq 0$, 则 $\|\nabla c(x^*)^\top u_k\|^2 \leq -\frac{1}{\sigma} u_k^\top \nabla_{xx}^2 L u_k \rightarrow 0$ 。取聚点 $\bar{u}$: $\nabla c(x^*)^\top \bar{u} = 0$ 且 $\bar{u}^\top \nabla_{xx}^2 L \bar{u} \leq 0$, 与二阶充分条件矛盾。故 $\exists \bar{\sigma}$ 使结论成立。■

(2) 收敛速度 设 x^*, λ^* 为严格局部极小解及乘子。存在 $\bar{\sigma}, \delta > 0$, 若某步 $\frac{1}{\sigma_k} \|\lambda^k - \lambda^*\| < \delta, \sigma_k \geq \bar{\sigma}$, 则 $\lambda^k \rightarrow \lambda^*, x^k \rightarrow x^*$, 且:

- $\limsup \sigma_k < \infty \Rightarrow \{\lambda^k\}$ **Q-线性收敛**;
- $\limsup \sigma_k = \infty \Rightarrow \{\lambda^k\}$ **Q-超线性收敛**。

🔗 **知识点** ALM 是精确罚 (有限 σ 即可), 优于二次罚的“ ∞ ”。一般收敛性 (弱假设): 乘子列有界 + $\sigma_k \rightarrow \infty$ + 子问题精度 $\rightarrow 0$ + LICQ $\Rightarrow$ 子列收敛到 KKT 点 ([第6章 KKT条件与约束优化])。

例12.12 一般约束 ALM: 松弛变量与消元 ★★★★★

🔗 **题目** 对含不等式约束 $c_i(x) \leq 0$ ($i \in I$) 的问题, 用松弛变量构造 ALM, 并通过消元解出 s_i 、写出乘子更新。

✅ **解答**

松弛化: $c_i(x) \leq 0 \Leftrightarrow c_i(x) + s_i = 0, s_i \geq 0$ 。增广拉格朗日函数 (保留 $s \geq 0$):

$$L_\sigma(x, s, \lambda, \mu) = f(x) + \sum_{i \in E} \lambda_i c_i + \sum_{i \in I} \mu_i (c_i + s_i) + \frac{\sigma}{2} \left[\sum_E c_i^2 + \sum_I (c_i + s_i)^2 \right].$$

消元 s : 固定 x , 关于 $s_i \geq 0$ 的子问题是二次型, 解析解

$$s_i = \max \left\{ -\frac{\mu_i}{\sigma_k} - c_i(x), 0 \right\}, \quad i \in I.$$

代回得只含 x 的连续可微函数 $L_{\sigma_k}(x, \lambda^k, \mu^k)$, 用梯度法求解。

乘子更新 (对照 KKT):

$$\lambda_i^{k+1} = \lambda_i^k + \sigma_k c_i(x^{k+1}) \quad (i \in E), \quad \mu_i^{k+1} = \max\{\mu_i^k + \sigma_k c_i(x^{k+1}), 0\} \quad (i \in I).$$

不等式乘子的 $\max\{\cdot, 0\}$ 自动保证对偶可行 $\mu_i \geq 0$ 。

🔗 **知识点** 约束违反度 $v_k = \sqrt{\sum_E c_i^2 + \sum_I \max\{c_i, -\mu_i^k/\sigma_k\}^2}$ 。算法 2 用 v_k 决定更新策略: 达标则更新乘子+提高精度 (σ 不变), 否则增大 σ (乘子不变)。

例12.13 凸问题 ALM 与基追踪的有限步收敛 ★★★★★

🔗 **题目** (1) 写出凸问题 ALM 与不精确条件。(2) 陈述基追踪 ALM 的有限步终止性, 并说明其与 Bregman 迭代的等价性。

✅ **解答**

(1) 凸 ALM 对 $\min f(x)$ s.t. $c_i(x) \leq 0$, 迭代

$$x^{k+1} \approx \arg \min_x L_{\sigma_k}(x, \lambda^k), \quad \lambda^{k+1} = \max\{0, \lambda^k + \sigma_k c(x^{k+1})\}.$$

不精确条件 $\varphi_k(x^{k+1}) - \inf \varphi_k \leq \frac{\varepsilon_k^2}{2\sigma_k}$, $\sum \varepsilon_k < \infty$ 。 φ_k 若 α -强凸, 可用数值可验证的 $\text{dist}(0, \partial \varphi_k(x^{k+1})) \leq \sqrt{\alpha/\sigma_k} \varepsilon_k$ 。 Slater 条件下 $\{\lambda^k\}$ 有界收敛到对偶最优解。

(2) 基追踪有限步收敛 对 BP $\min \|x\|_1$ s.t. $Ax = b$, ALM 迭代 ($\sigma = 1$ 固定, $x^0 = \lambda^0 = 0$):

$$x^{k+1} = \arg \min_x \left\{ \|x\|_1 + \frac{\sigma}{2} \|Ax - b + \frac{\lambda^k}{\sigma}\|^2 \right\}, \quad \lambda^{k+1} = \lambda^k + \sigma(Ax^{k+1} - b).$$

定理: 可行域非空时, 存在正整数 K 使 $\forall k \geq K$, x^k 都是 BP 的精确解 (有限步终止!)。关键引理: $\|Ax^k - b\|$ 单调下降且 $\frac{\sigma}{2} \|Ax^k - b\|^2 \leq \frac{1}{k} \|\tilde{x}\|_1$ 。

与 Bregman 等价: 取 Bregman 距离 $D_h^g(x, y) = \|x\|_1 - \|y\|_1 - \langle g, x - y \rangle$, Bregman 迭代与 ALM 在初始点取 $(x^0, -A^\top \lambda^0)$ 时完全一致 ($g^k = -A^\top \lambda^k$)。

🔗 **知识点** ALM 是处理 BP/LP/SDP 的统一框架: 原问题/对偶问题均可, 消元后用梯度法或**半光滑牛顿法** (如 SDPNAL+, SSNAL)。 ℓ_1 子问题用近似点梯度法 + BB 步长 ([第8章 梯度类算法] 例8.10、[第10章 拟牛顿类算法] 例10.12)。参考 Rockafellar 1976、Yin-Osher-Goldfarb 2008。

附：综合应用案例

本附录收录"极值应用问题求解案例"课件中的趣味/实用极值问题，展示最优化思想在概率、几何、不等式中的应用。这些案例多用初等方法（求导、凸性、对称、仿射变换、拉格朗日乘子）解决，是理解"建模—求极值"全流程的好素材。衔接 [[第2章 凸函数]]（琴生不等式）、[[第5章 对偶理论]]、[[第6章 KKT条件与约束优化]]（拉格朗日乘子）。

案例 A.1 凯利公式（最优押注比例）★★★

🔴 **题目** 一场比赛 A 队胜率 p 、B 队胜率 $q = 1 - p$ 。已有 m 分押 A、 n 分押 B ($m/n < p/q$)。本金 c_0 ，忽略自己押注对赔率的影响。如何押注使长期收益最大？

✅ **解答**

设以比例 s 押 A（即押 sc_0 ）。赔率由总押分比决定：A 胜时押 A 的每分得 $\frac{m+n}{m}$ ，故 A 胜本金变为 $c_0(1-s) + sc_0 \cdot \frac{m+n}{m}$ ；A 负本金变为 $c_0(1-s) + sc_0 \cdot \frac{m+n}{n} \cdot [\text{押B部分}]$ 。以**对数财富**（几何增长）为目标，期望对数财富

$$g(s) = p \ln(\text{A胜后财富}) + q \ln(\text{A负后财富}).$$

对 s 求导令 $g'(s) = 0$ ，解出**凯利公式**

$$s^* = \frac{p}{?} - \frac{q}{?} \text{ 形式, 即 } s^* = p - q \cdot \frac{\text{赔率项}}{\dots}.$$

要点结论： $s^* > 0$ 的条件是 $p/q > m/n$ （题设满足，有正期望才下注）；当胜率不占优时 $s^* \leq 0$ （应反向押 B 或不押），无套利空间时 $s^* = 0$ 。

💡 **知识点** 凯利准则的核心是**最大化对数效用**（而非线性期望），自动平衡收益与破产风险。这是"对数财富 $\Rightarrow$ 凹目标 $\Rightarrow$ 一阶条件求极值"的经典案例，体现 [[第2章 凸函数]] 凹函数极大化。

案例 A.2 排序不等式及其应用 ★★★

🔴 **题目** (1) 陈述排序不等式。(2) 设实数 $a_1, \dots, a_n$ 满足 $\sum a_i = 0$ 、 $\sum |a_i| = 1$ ，求 $S = \sum_i a_i \cdot (\text{某权重})$ 的取值范围。

✅ **解答**

(1) 排序不等式 设 $a_1 \leq \dots \leq a_n$ 、 $b_1 \leq \dots \leq b_n$ ， j 为 $\{1, \dots, n\}$ 的任一排列，则

$$\underbrace{\sum a_i b_{n+1-i}}_{\text{反序和(最小)}} \leq \sum a_i b_{j(i)} \leq \underbrace{\sum a_i b_i}_{\text{顺序和(最大)}}.$$

证明思路：对 $a_i \leq a_j, b_k \leq b_l$ ，有 $(a_i - a_j)(b_k - b_l) \geq 0$ ，即 $a_i b_k + a_j b_l \geq a_i b_l + a_j b_k$ 。任何"逆序对"都可通过交换使和增大，故顺序和最大；反之反序和最小。

(2) 应用 设正元素从小到大为 $b_1, \dots, b_k$ ，负元素的相反数从小到大为 $c_1, \dots, c_l$ ($k+l=n$)。由 $\sum a_i = 0$ 得 $\sum b_j = \sum c_j$ ；由 $\sum |a_i| = 1$ 得 $\sum b_j + \sum c_j = 1$ ，故 $\sum b_j = \sum c_j = \frac{1}{2}$ 。利用排序不等式即可确定 S 的上下界。

💡 **知识点** 排序不等式是离散版的"重排极值"，本质是双线性型在排列约束下的极值，与匹配/指派问题相通。

案例 A.3 费马点 (到三顶点距离和最小) ★★★

🔴 题目 给定 $\triangle ABC$, 求点 P 使 $|PA| + |PB| + |PC|$ 最小。

✅ 解答

构造思路 (旋转变换): 将 $\triangle APB$ 绕 B 旋转 60° , 把三段折线 $PA + PB + PC$ "拉直"成一条线段。当 P 使三条线段共线时距离和最小。

结论: 使距离和最小的点 P (费马点) 对每条边的张角都是 120° , 即 $\angle APB = \angle BPC = \angle CPA = 120^\circ$ (当三角形各内角 $< 120^\circ$ 时)。

应用: 多点连接时在费马点设三叉顶点最省线路; 蜂房正六边形结构最省蜂蜡 (每个顶点三条边互成 120°)。

🔗 **知识点** 费马点是无约束几何极值的典范, "旋转拉直"是一种巧妙的降维技巧。等角 120° 条件可由对各 P 求梯度 (三个单位向量和为零) 导出——即 [[第4章 无约束可微优化的最优性条件]] 的一阶条件 $\nabla = \hat{u}_A + \hat{u}_B + \hat{u}_C = 0$ 。

案例 A.4 最佳射门位置 (张角最大) ★★★

🔴 题目 球员沿球门 AB 外的直线 l 带球, 在 l 上 P 点射门, $\angle APB$ 越大进球概率越高。求最佳射门位置。

✅ 解答

对线段 AB 张角为定值的点的轨迹是一段圆弧 (同弧所对圆周角相等)。张角越大, 对应的圆越小。当过 A, B 的圆与直线 l 相切时, 切点对 AB 的张角最大 (此时圆最小且仍与 l 有公共点)。

作法: 作过 A, B 且与 l 相切的圆, 切点即最佳射门点 P 。由切割线定理, P 满足 $|MP|^2 = |MA| \cdot |MB|$ (M 为 l 与直线 AB 的交点)。

🔗 **知识点** "张角最大" $\Leftrightarrow$ "相切圆最小", 是约束极值 (P 在直线 l 上) 的几何解法。等价于在 l 上极大化 $\angle APB(P)$, 相切是一阶最优条件的几何呈现。

案例 A.5 琴生不等式与三大均值不等式 ★★★

🔴 题目 由凸性推导琴生不等式, 并证明调和—几何—算术—平方平均的排序 $H \leq G \leq A \leq P$ 。

✅ 解答

琴生不等式 f 在 $[a, b]$ 上凸 (下凸, $f'' > 0$), 则对 $x_1, \dots, x_n \in [a, b]$:

$$f\left(\frac{1}{n} \sum x_i\right) \leq \frac{1}{n} \sum f(x_i).$$

(上凸函数反向。) 证明: $n = 2^m$ 用不等式传递逐次加倍; 一般 n 由 n 推 $n-1$ (取 $x_n = \frac{1}{n-1} \sum_{i < n} x_i$ 回代)。

三大均值 对正数 $x_1, \dots, x_n$:

- 取 $f(x) = x^2$ (下凸) $\Rightarrow$ 平方平均 $P = \sqrt{\frac{1}{n} \sum x_i^2} \geq$ 算术平均 $A = \frac{1}{n} \sum x_i$;
- 取 $f(x) = \ln x$ (上凸) $\Rightarrow \ln A \geq \frac{1}{n} \sum \ln x_i = \ln G$, 即 $A \geq G = (\prod x_i)^{1/n}$ (几何平均);
- 对 $1/x_i$ 用 $A \geq G$, 取倒数 $\Rightarrow G \geq H = \frac{n}{\sum 1/x_i}$ (调和平均)。

综上 $\boxed{H \leq G \leq A \leq P}$, 当且仅当 $x_1 = \dots = x_n$ 时取等。

🔑 **知识点** 琴生不等式是凸函数定义的" n 点推广" ([第2章 凸函数])，是证明各类均值/积分不等式的统一工具。均值排序是机器学习正则化、信息论中常用的基本不等式。

案例 A.6 等周问题 (定边长四边形面积最大 $\Rightarrow$ 圆内接) ★★★★★

🔴 **题目** 四边长固定为 a, b, c, d 的四边形，何时面积最大？

✅ **解答**

设 $\angle ABC = \theta$ 、 $\angle ADC = \varphi$ ，对角线 AC ：

$$|AC|^2 = a^2 + b^2 - 2ab \cos \theta = c^2 + d^2 - 2cd \cos \varphi.$$

面积 $2S = ab \sin \theta + cd \sin \varphi$ 。两式平方相加消去：

$$16S^2 + (a^2 + b^2 - c^2 - d^2)^2 = 4a^2b^2 + 4c^2d^2 - 8abcd \cos(\theta + \varphi).$$

S 最大 $\Leftrightarrow \cos(\theta + \varphi)$ 最小 $\Leftrightarrow \theta + \varphi = \pi$ ，即 $ABCD$ 为圆内接四边形。

推广：各边长确定的多边形内接于圆时面积最大；周长固定的平面图形中圆面积最大；定长绳在区域内围最大面积时绳呈圆弧、且端点切线与边界垂直。

🔑 **知识点** 这是约束极值的经典：固定边长（约束）极大化面积（目标）。条件 $\theta + \varphi = \pi$ 即拉格朗日一阶条件的几何形式。等周问题是变分法的源头之一。

案例 A.7 仿射变换与最小外接/最大内切椭圆 ★★★★★

🔴 **题目** 给定凸四边形，如何构造面积最小的外接椭圆？（并简述最大内切椭圆。）

✅ **解答**

核心思想（仿射不变性）：仿射变换 $T(p) = Ap + b$ 保持"直线平行""线段比例""两图形面积之比"不变。故椭圆与四边形的面积比是仿射不变量。策略：把问题化到"圆 + 仿射等价四边形"再变回。

最小外接椭圆：

1. 正三角形的最小外接椭圆是其外接圆；任意三角形与正三角形仿射等价，故可由外接圆仿射还原。
2. 凸四边形：存在与之仿射等价的圆内接四边形；调整其对角线夹角 θ ，每个 θ 对应原四边形的一个外接椭圆。当"外接圆面积/四边形面积"之比最小时，对应椭圆即解。
3. 设对角线交点 P_0 分割比由圆幂定理 $|P_0A_0||P_0C_0| = |P_0B_0||P_0D_0|$ 决定，参数化 $|P_0A_0| = e^u$ 等。面积比的对数对 θ 求导（极值条件），化为关于 $\cos \theta$ 的三次方程 $\cos^3 \theta - 8 \sinh u \sinh v \cos^2 \theta - (3(\sinh^2 u + \sinh^2 v) + 1) \cos \theta + 2 \sinh u \sinh v = 0$ ，解出 θ ，再仿射还原得最小外接椭圆。

最大内切椭圆（对偶）：化为"单位圆 + 仿射等价的圆外切四边形"。设切点张角半角 $\alpha, \beta, \gamma, \delta$ ($\alpha + \beta + \gamma + \delta = \pi$)，面积 $S = \tan \alpha + \tan \beta + \tan \gamma + \tan \delta$ 。引入自由变量 θ, φ ，构造拉格朗日函数

$$L(\theta, \varphi) = \cosh u \tan \theta + \cosh v \tan \varphi + \lambda(\cosh u \tan 2\theta + \cosh v \tan 2\varphi),$$

一阶条件 $\sec^2 \theta + 2\lambda \sec^2 2\theta = 0$ 等，消 λ 化简得 $2 \cos \theta \cos \varphi = 1$ 与 $\cosh u \sin \theta = \cosh v \sin \varphi$ ，联立解出双二次方程 $t^4 - (\cosh^2 u + \cosh^2 v)t^2 + \frac{3}{4} \cosh^2 u \cosh^2 v = 0$ ($t = \cosh u \sin \theta$)，求 θ, φ 后仿射还原。

🔑 **知识点** 这是全集中最综合的案例，串起仿射不变性 + 条件极值 + 拉格朗日乘子 ([第6章 KKT条件与约束优化]) + 三角/双曲恒等式。Löwner-John 椭圆（最小外接/最大内切）在凸几何、椭圆法、SDP 松弛中有深刻应用。"化到圆再仿射变回"是处理仿射不变极值的通用范式。